

统计机器学习基础

Foundations of Statistical Machine Learning

——隐马尔可夫模型

Kai Chen

kaichen6@csu.edu.cn

24th September 2025



中南大学
CENTRAL SOUTH UNIVERSITY

数学与统计学院
SCHOOL OF MATHEMATICS AND STATISTICS

Overview

1 背景

- 马尔可夫模型
- 贝叶斯网络

2 隐马尔可夫模型

- HMM 定义
- HMM 推导
- $P(q_t = A)$
- $P(Q | O)$
- $\operatorname{argmax}_Q P(Q)$

3 学习 HMM

- MLE: 状态可观测
- EM 算法
- 构建 HMM
- 因子 HMM
- 输入输出 HMM
- 动态贝叶斯网络 (DBN)

- 1 背景
 - 马尔可夫模型
 - 贝叶斯网络
- 2 隐马尔可夫模型
- 3 学习 HMM
- 4 模型选择

马尔可夫模型

模型：讨论观测序列 $X_1, \dots, X_T$ 的概率模型，其中 T 是任意长度。

应用：计算生物学、自然语言处理、时间序列预测等领域

马尔可夫链或马尔可夫模型：

$$p(X_{1:T}) = p(X_1)p(X_2|X_1)p(X_3|X_2)\dots = p(X_1)\prod_{t=2}^T p(X_t|X_{t-1})$$

平稳性： $p(X_t|X_{t-1})$ 与时间无关

马氏性：给定当前状态，未来状态与过去状态无关。

$$p(X_t \mid X_{t-1}, X_{t-2}, \dots, X_1) = p(X_t \mid X_{t-1})$$

转移矩阵

有限状态马尔可夫链：观测变量是离散的，那么 $X_t \in \{1, \dots, K\}$

转移矩阵 $\mathbf{A}$ ： $K \times K$ 的 $p(X_t|X_{t-1})$ 矩阵


n 步转移矩阵 $\mathbf{A}^{(n)}$ ：

$$A_{ij}(n) \triangleq p(X_{t+n} = j | X_t = i)$$

Chapman-Kolmogorov equations：

$$A_{ij}(m+n) = \sum_{k=1}^K A_{ik}(m) A_{kj}(n)$$

$$\mathbf{A} = \begin{pmatrix} 1-\alpha & \alpha \\ \beta & 1-\beta \end{pmatrix}$$



平稳分布

每个不可约（单连通）、非周期、有限状态马尔可夫链有一个极限分布，这等于 π ，其唯一平稳分布。

$$P(X_t = j) = \sum_i P(X_0 = i) A_{ij}(t) \rightarrow \pi_j \text{ as } t \rightarrow \infty$$

平稳分布的计算：


$$\pi = \pi \mathbf{A}$$

$$\sum_j \pi_j = 1$$

- 1 背景
 - 马尔可夫模型
 - 贝叶斯网络
- 2 隐马尔可夫模型
- 3 学习 HMM
- 4 模型选择

贝叶斯网络

- 贝叶斯网络在建模联合分布时非常有用
- 但它们有局限性：
 - 无法处理时间/序列模型
 - 有向无环图（不允许自环或其他环）



这不是一个有效的贝叶斯网络！

1 背景

2 隐马尔可夫模型

- HMM 定义
- HMM 推导
- $P(q_t = A)$
- $P(Q | O)$
- $\operatorname{argmax}_Q P(Q)$

3 学习 HMM

4 模型选择

隐马尔可夫模型

- 用来描述一个含有隐含未知参数的马尔可夫过程。
- 目标: 根据可观察的输出序列推断隐藏的状态序列; 根据已知的隐藏状态序列预测输出序列
- 由离散时间、离散状态马尔可夫链组成, 隐藏状态 $z_t \in \{1, \dots, K\}$, 加上一个观测模型 $p(\mathbf{x}_t|z_t)$.

相应的联合分布具有以下形式

$$p(\mathbf{z}_{1:T}, \mathbf{x}_{1:T}) = p(\mathbf{z}_{1:T})p(\mathbf{x}_{1:T}|\mathbf{z}_{1:T}) = \left[p(\mathbf{z}_1) \prod_{t=2}^T p(\mathbf{z}_t|\mathbf{z}_{t-1}) \right] \prod_{t=1}^T p(\mathbf{x}_t|\mathbf{z}_t)$$

隐马尔可夫模型

HMM 中的观测可以是离散的或连续的。

- 离散:

$$p(\mathbf{x}_t = l | z_t = k, \Theta) = B(k, l)$$

- 连续:

$$p(\mathbf{x}_t | z_t = k, \Theta) = \mathcal{N}(\mathbf{x}_t | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$


隐马尔可夫模型

- 可见状态是可以直接观测到的
- 隐藏状态是不可直接观测的，但它们是生成观测的潜在原因。
- 机器人运动
观测：距离传感器、视觉传感器
隐藏状态：地图上的位置
- 语音处理
观测：声音信号
隐藏状态：词性、单词
- 生物学
观测：DNA 碱基对
隐藏状态：基因

隐马尔可夫模型

- 用一组隐藏状态建模一组观测
- 隐藏状态生成观测
观测值是根据某种概率分布从隐藏状态生成的。
- 隐藏状态转移到其他隐藏状态
HMM 假设隐藏状态序列遵循马尔可夫性质，即一个状态的转移只依赖于其前一个状态，而与更早的状态无关。



示例：语音处理



sil	acht	negen	sil	drie	een
-----	------	-------	-----	------	-----

sil	spk	spk	sil	spk	spk
-----	-----	-----	-----	-----	-----


示例：生物数据



```
ATGAAGCTACTGTCTTCTATCGAACAAGCATGCG
ATATTTGCCGACTTAAAAAGCTCAAG
TGCTCCAAAGAAAAACCGAAGTGCGCCAAGTGT
CTGAAGAACAACCTGGGAGTGTCGCTAC
TCTCCCAAACCAAAGGTCTCCGCTGACTAGG
GCACATCTGACAGAAGTGGAATCAAGG
CTAGAAAGACTGGAACAGCTATTTCTACTGATTTT
TCCTCGAGAAGACCTTGACATGATT
```

示例：掷骰子赌博

- 两个骰子，都有偏差（骰子不是完全公平的）
- 可以继续使用同一个骰子，或者切换到第二个骰子（转移模型）




- 状态 A 和 B 之间的转移概率为 0.2，表示从状态 A（使用第一个骰子）转移到状态 B（使用第二个骰子）的概率是 20%。（状态 B 转移到状态 A 的概率也是 0.2）
- 继续使用 A/B 骰子的概率是 80%。

术语与定义

- 状态集合：所有可能的隐藏状态的集合。 $\{s_1, \dots, s_n\}$
每个时刻我们恰好处于其中某个状态，记为 q_t
- 观测集合：所有可能的可见状态的集合。 Σ
- 初始状态概率分布：在时间 $t=1$ 时，各个隐藏状态的概率分布。
 π_i ：初始处于状态 s_i 的概率
- 状态转移概率矩阵：描述从一个隐藏状态转移到另一个隐藏状态的概率。
 $P(q_{t+1} = s_j | q_t = s_i)$
- 观测概率矩阵（发射概率矩阵）：给定一个隐藏状态时，观测到某个可见状态的概率。
 $P(o_t = \sigma | s_i)$

HMM 性质：马尔科夫性

$$P(q_{t+1} = s_i | q_t = s_j, q_{t-1} = s_k) = P(q_{t+1} = s_i | q_t = s_j)$$



1 背景

2 隐马尔可夫模型

- HMM 定义
- HMM 推导
- $P(q_t = A)$
- $P(Q | O)$
- $\operatorname{argmax}_Q P(Q)$

3 学习 HMM


4 模型选择

隐马尔可夫模型

使用 HMM 时可以问哪些问题？

如：

- “现在在用哪个骰子？”
- “下一次掷出 6 的概率是多少？”
- “接下来三次任意一次掷出 6 的概率是多少？”



HMM 中的三类推导

- 计算 $P(Q)$ 与 $P(q_t = s_i)$
在没有观测数据的情况下, 隐藏状态序列 Q 的概率
只关心隐藏状态序列本身的概率分布, 而不关心观测序列。
- 计算 $P(Q | O)$ 与 $P(q_t = s_i | O)$
给定观测序列 O , 隐藏状态序列 Q 的概率
关心在观测序列出现的情况下, 隐藏状态序列或特定时间点的状态的概率。
- 计算 $\arg \max_Q P(Q | O)$
最有可能产生观测序列 O 的隐藏状态序列 Q
关心观测序列出现的概率, 还关心产生这些观测的最可能的隐藏状态序列。

1 背景

2 隐马尔可夫模型


- HMM 定义
- HMM 推导
- $P(q_t = A)$
- $P(Q | O)$
- $\operatorname{argmax}_Q P(Q)$

3 学习 HMM

4 模型选择

$$P(q_t = A)$$

- 到目前为止玩了 t 轮
- 目标 $P(q_t = A)$
- 假设我们看不到任何输出（被蒙眼）
- 现在在用哪个骰子？如何计算？



$$P(q_t = A)$$

简单思路：遍历法

- ① 确定以 A 结束的任意路径 Q 的概率 $P(Q)$

设 $Q = q_1, \dots, q_{t-1}, A$

$$\begin{aligned} P(Q) &= P(q_1, \dots, q_{t-1}, A) = P(A \mid q_1, \dots, q_{t-1})P(q_1, \dots, q_{t-1}) \\ &= P(A \mid q_{t-1})P(q_1, \dots, q_{t-1}) = \dots = P(A \mid q_{t-1}) \dots P(q_2 \mid q_1)P(q_1) \quad \text{马} \end{aligned}$$

- ② $P(q_t = A) = \sum P(Q)$

遍历所有长度为 t 并以 A 结尾的状态序列, 并求和

问：有多少这样的 Q ？

答：很多！ (2^{t-1}) ，不可行

$$P(q_t) = A$$

改进方法：动态规划

定义 $p_t(i)$ 为时刻 t 处于状态 i 的概率： $p_t(i) = P(q_t = s_i)$

可通过归纳计算：

- ① $p_1(i) = \pi_i$
- ② $p_t(i) = \sum_j P(q_t = s_i \mid q_{t-1} = s_j) p_{t-1}(j)$

这种计算方式称为动态规划，可以计算出任意时间步的隐藏状态概率分布。

复杂度： $O(n^2 t)$

Time / state	t
s1	
s2	

$$P(q_t = s_i)$$

马尔可夫转移极限定理:

如果转移矩阵严格正（即矩阵中所有元素都大于零），这意味着从任何一个状态转移到其他任何状态都是可能的。这样的马尔可夫链被称为不可约（irreducible）和非周期（aperiodic）的。对于这样的马尔可夫链，存在一个唯一的平稳分布（stationary distribution），在这个分布下，系统的长期行为是稳定的，并且不依赖于初始状态。

$$\lim_{k \rightarrow \infty} (P^k)_{ij} = \theta_j$$

换言之，极限下起点不再重要，每个状态有固定的稳态概率

1 背景

2 隐马尔可夫模型

- HMM 定义
- HMM 推导
- $P(q_t = A)$
- $P(Q | O)$
- $\operatorname{argmax}_Q P(Q)$


3 学习 HMM

4 模型选择

观测输出 O

- 之前的计算中我们假设看不到输出
- 但现实中几乎总能看到输出
- 如果观测序列 5, 6, 4, 5, 6, 6 , 会改变我们对状态的信念吗？

v	$P(v A)$	$P(v B)$
1	.3	.1
2	.2	.1
3	.2	.1
4	.1	.2
5	.1	.2
6	.1	.3



$$P(q_t = A \mid O_1, \dots, O_t)$$

计算

$$P(q_t = A \mid O_1, \dots, O_t)$$

为书写方便, 引入常见记号:

- $b_i(o_t) = P(o_t \mid s_i)$: 发射概率
- $a_{j,i} = P(q_t = s_i \mid q_{t-1} = s_j)$: 转移概率

让我们从一个更简单的问题开始。

给定一系列状态 Q , 求解

$$P(Q \mid O_1, \dots, O_t) = P(Q \mid O)$$

- 从 $P(Q)$ 到 $P(q_t = A)$ 的转换相当简单
- 在某些情况下, $P(Q)$ 是更重要的问题
 - 语音处理
 - 自然语言处理 (NLP)

我们可以使用贝叶斯规则：

$$P(Q \mid O) = \frac{P(O \mid Q)P(Q)}{P(O)}$$

- 容易计算 $P(O \mid Q)$ ：

$$P(O \mid Q) = P(o_1 \mid q_1)P(o_2 \mid q_2) \dots P(o_t \mid q_t)$$

- 容易计算 $P(Q)$ ：

$$P(Q) = P(q_1)P(q_2 \mid q_1) \dots P(q_t \mid q_{t-1})$$

- 困难： $P(O)$

- 看到一组观测的概率是多少
 - 验证模型是否合理
 - 在使用两个或多个 HMM 进行分类时，我们可以通过比较不同模型生成观测序列的概率来选择最佳模型。
 - 在训练 HMM 时，我们通常需要估计模型参数（如状态转移概率和观测概率）。通过最大化观测序列的概率，我们可以找到最优的参数设置。
- 定义 $\alpha_t(i) = P(o_1, o_2, \dots, o_t \wedge q_t = s_i)$
- $\alpha_t(i)$ 是我们：
 - ① 观测到 $o_1, o_2, \dots, o_t$
 - ② 最终处于状态 s_i

如何计算 $\alpha_t(i)$?

计算 $\alpha_t(i)$

$$\alpha_t(i) = P(O_1, O_2 \dots, O_t \wedge q_t = s_i)$$


- $\alpha_1(i) = P(O_1 \wedge q_1 = i) = P(O_1 \mid q_1 = s_i)\Pi_i$

$$\begin{aligned}\alpha_{t+1}(i) &= P(O_1 \dots O_{t+1} \wedge q_{t+1} = s_i) \\ &= \sum_j P(O_1 \dots O_t \wedge q_t = s_j \wedge O_{t+1} \wedge q_{t+1} = s_i) \\ &= \sum_j P(O_{t+1} \wedge q_{t+1} = s_i \mid O_1 \dots O_t \wedge q_t = s_j) P(O_1 \dots O_t \wedge q_t = s_j) \alpha_t(j) \\ &= \sum_j P(O_{t+1} \mid q_{t+1} = s_i) P(q_{t+1} = s_i \mid q_t = s_j) \alpha_t(j) \\ &= \sum_j b_i(O_{t+1}) a_{j,i} \alpha_t(j)\end{aligned}$$

示例：计算 $\alpha_3(B)$

- 我们观察到 2, 3, 6
- $\alpha_1(A) = P(2 \wedge q_1 = A) = P(2 \mid q_1 = A)\Pi_A = 0.2 \times 0.7 = 0.14$,
 $\alpha_1(B) = 0.1 \times 0.3 = 0.03$
- $\alpha_2(A) = \sum_{j=A,B} b_A(3) a_{j,A} \alpha_1(j) = 0.2 \times 0.8 \times 0.14 + 0.2 \times 0.2 \times 0.03 = 0.0236$,
 $\alpha_2(B) = 0.0052$
- $\alpha_3(B) = \sum_{j=A,B} b_B(6) a_{j,B} \alpha_2(j) = 0.3 \times 0.2 \times 0.0236 + 0.3 \times 0.8 \times 0.0052 = 0.00264$

v	P(v A)	P(v B)
1	.3	.1
2	.2	.1
3	.2	.1
4	.1	.2
5	.1	.2
6	.1	.3



$P(Q \mid O)$

- 我们想要计算 $P(Q \mid O)$
- 对此，我们只需要计算 $P(O)$
- 我们知道如何计算 $\alpha_t(i)$

从现在起就简单了：

$$\alpha_t(i) = P(O_1, O_2, \dots, O_t \wedge q_t = s_i)$$

所以

$$P(O) = P(O_1, O_2, \dots, O_t) = \sum_i P(O_1, O_2, \dots, O_t \wedge q_t = s_i) = \sum_i \alpha_t(i)$$

注意：因为：

$$P(A \mid B) = \frac{P(A \wedge B)}{P(B)}$$

$$p(q_t = s_i \mid O_1, O_2, \dots, O_t) = \frac{\alpha_t(i)}{\sum_j \alpha_t(j)}$$

$P(Q | O)$ 的计算复杂度

计算 $P(q | O)$ 的复杂度:

$$P(Q | O) = \frac{P(O | Q)P(Q)}{P(O)}$$

- $P(Q): O(t)$
我们需要考虑每个时间步的状态转移概率, $O(t)$
- $P(O | Q): O(t)$
由于每个观测值只依赖于当前的隐藏状态, 计算 $P(O | Q)$ 的复杂度也是 $O(t)$
- $P(O): O(n^2 t)$
 n^2 来自于状态转移概率矩阵的计算

1 背景

2 隐马尔可夫模型

- HMM 定义
- HMM 推导
- $P(q_t = A)$
- $P(Q | O)$
- $\operatorname{argmax}_Q P(Q)$

3 学习 HMM

4 模型选择

如何找到最可能路径 Q^* ，使得

$$P(Q^* | O) = \arg \max_Q P(Q | O)$$

这个过程被称为解码 ((Decoding))

- 语音处理:

观测序列 O 是音频信号，而隐藏状态序列 Q 代表音素或单词。

通过找到最有可能的隐藏状态序列，系统可以将音频信号转换为文本。

- 基因识别:

观测序列可能是 DNA、RNA 或蛋白质序列，而隐藏状态可能代表基因、转录因子或其他生物学实体。


通过解码，研究人员可以识别出哪些基因在特定条件下是活跃的

示例: $\operatorname{argmax}_Q P(Q)$

求观测序列对应的最可能状态序列

O : 1, 2, 2, 5, 6, 5, 1, 2, 3

v	$P(v A)$	$P(v B)$
1	.3	.1
2	.2	.1
3	.2	.1
4	.1	.2
5	.1	.2
6	.1	.3



$$\operatorname{argmax}_Q P(Q)$$

$$\operatorname{argmax}_Q P(Q \mid O) = \operatorname{argmax}_Q \frac{P(O \mid Q)P(Q)}{P(O)} = \operatorname{argmax}_Q P(O \mid Q)P(Q)$$

我们将使用以下定义：

$$\delta_t(i) = \max_{q_1 \dots q_{t-1}} p(q_1 \dots q_{t-1} \wedge q_t = s_i \wedge O_1 \dots O_t)$$

换句话说，我们感兴趣的是从 1 到 t 的最可能路径，该路径：

- 以 s_i 结束；
- 生成输出 $O_1 \dots O_t$ 。

计算 $\delta_t(i)$

$$\delta_t(i) = \max_{q_1 \dots q_{t-1}} p(q_1 \dots q_{t-1} \wedge q_t = s_i \wedge O_1 \dots O_t)$$

$$\delta_1(i) = p(q_1 = s_i \wedge O_1) = p(q_1 = s_i)p(O_1 \mid q_1 = s_i) = \pi_i b_i(O_1)$$

问题：给定 $\delta_t(i)$ ，我们如何计算 $\delta_{t+1}(i)$ ？

答案：要从 $\delta_t(i)$ 转换到 $\delta_{t+1}(i)$ ，我们需要：

- 为时间 $t+1$ 添加一个发射 (O_{t+1})
- 转移到状态 s_i

$$\begin{aligned}\delta_{t+1}(i) &= \max_{q_1 \dots q_t} p(q_1 \dots q_t \wedge q_{t+1} = s_i \wedge O_1 \dots O_{t+1}) \\ &= \max_j \delta_t(j) p(q_{t+1} = s_i \mid q_t = s_j) p(O_{t+1} \mid q_{t+1} = s_j) \\ &= \max_j \delta_t(j) a_{j,i} b_i(O_{t+1})\end{aligned}$$

$$\begin{aligned}\delta_{t+1}(i) &= \max_{q_1 \dots q_t} p(q_1 \dots q_t \wedge q_{t+1} = s_i \wedge O_1 \dots O_{t+1}) \\ &= \max_j \delta_t(j) p(q_{t+1} = s_i \mid q_t = s_j) p(O_{t+1} \mid q_{t+1} = s_j) \\ &= \max_j \delta_t(j) a_{j,i} b_i(O_{t+1})\end{aligned}$$

- 我们再次使用动态规划来求解 $\delta_t(i)$
- 一旦我们有了 $\delta_t(i)$, 我们就可以求解我们的 $P(Q^* \mid O)$
由 $\arg \max_j \delta_t(j)$ 定义路径


$$P(Q^* \mid O) = \arg \max_Q P(Q \mid O) =$$

Viterbi 算法

任务：在图中计算一条最短路径

复杂度：

- 时间复杂度是 $O(K^2 T)$
- 空间复杂度是 $O(KT)$



扩展：N-最佳列表

Viterbi 算法返回最可能路径之一。

扩展：返回前 N 条路径。这被称为 N-最佳列表。(Schwarz and Chow 1990; Nilsson and Goldberger 2000)

排序：使用基于从完全观察到的状态序列（以及可见特征）派生的全局特征的判别方法对路径进行重新排序。

- 基于后验概率的排序。
- 基于评分的排序。
- 基于模型置信度的排序。
- 基于多样性的排序。
- 基于用户反馈的排序。

前 N 条路径通常彼此非常相似。如果我们希望生成一组更多样化的路径，种方法是从后验中采样路径 (Yadollahpour et al. 2011; Kulesza and Taskar 2011)

- 为什么用 HMM ?
- 适合哪些应用 ?
- HMM 中的推导
 - 计算 $P(q)$ 与 $P(q_t = s_i)$, 无观测
 - 计算 $P(Q | O)$ 与 $P(q_t = s_i | O)$, 有观测时的状态概率
 - 计算 $\arg \max_q P(q | O)$, 最可能路径 (Viterbi)


- 到目前为止，我们假设发射概率 $P(o_t = \sigma \mid s_i)$ 和转移概率 $P(q_{t+1} = s_j \mid q_t = s_i)$ 是已知的
- 这通常不是实际情况，比如：
 - 不同的人如何发音 “AI” ?
 - 在 “AI” 之后听到 “class” 的概率是多少 ?
- 虽然我们将讨论学习转移和发射模型，但此处我们不会讨论如何学习状态集
- 状态集通常是领域知识的函数

示例

给定模型与观测序列：

1, 2, 2, 5, 6, 5, 1, 2, 3, 3, 5, 3, 3, 2

如何确定初始、转移与发射概率？



Outline

1 背景

2 隐马尔可夫模型

3 学习 HMM


- MLE: 状态可观测
- EM 算法
- 构建 HMM
- 因子 HMM
- 输入输出 HMM
- 动态贝叶斯网络 (DBN)

4 模型选择

当状态可观测时的 MLE

- 假设可以直接观察到状态本身。
- 显然，事实并非如此。在隐马尔可夫模型中，状态是不可直接观察的，我们只能观察到状态生成的观测值
- 为了推断推断状态和学习模型参数，我们需要放松假设

初始概率




- 问题：假设我们可以观察到以下状态集：
 - AABAAA
 - AABBBB
 - BAABBA
- 如何学习初始概率？
- 答案：最大似然估计
- 找到初始概率 π 使得

$$\pi^* = \arg \max_{\pi} \prod_k \pi(q_1) \prod_{i=2}^T p(q_i | q_{i-1}) \Rightarrow$$
$$\pi^* = \arg \max_{\pi} \prod_k \pi(q_1)$$

- k 是可用于训练的序列数量
- MLE 估计： $\pi_A = \#A / (\#A + \#B)$
其中， $\#A$ 表示在所有观测序列的开始位置，状态 A 出现的次数。

转移概率



- 问题：假设我们可以观察到状态集：
 - AAABBAABBBBAAABBBA
- 如何学习转移概率？
- 答案：最大似然估计
- 定义 $a_{ij} = p(q_t = s_i | q_{t-1} = s_j)$ 找到一个转移矩阵 a 使得

$$a^* = \arg \max_a \prod_k \pi(q_1) \prod_{i=2}^T p(q_i | q_{i-1}) \Rightarrow$$

$$a^* = \arg \max_a \prod_{i=2}^T p(q_t | q_{t-1})$$

- MLE 估计： $a_{A,B} = \#AB / (\#AB + \#AA)$
其中， $\#AB$ 表示在观测数据中，从状态 A 转移到状态 B 的次数。

- 问题：假设我们可以观察到以下状态集：

- AAABBAAAAABBBBAA

和骰子值集：

- 1 2 3 5 6 3 2 1 1 3 4 5 6 5 2 3

我们如何学习发射概率？

- 答案：最大似然估计

- MLE 估计： $b_A(5) = \#A5 / (\#A1 + \#A2 + \dots + \#A6)$

其中， $b_A(5)$ 表示从状态 A 发射出观测值 5 的发射概率， $\#A5$ 表示态 A 后观测值为 5 的次数。

Outline

1 背景

2 隐马尔可夫模型

3 学习 HMM

- MLE: 状态可观测
- **EM 算法**
- 构建 HMM
- 因子 HMM
- 输入输出 HMM
- 动态贝叶斯网络 (DBN)

4 模型选择


- 在大多数情况下，我们不知道每个输出生成了哪些状态（完全无监督）
- ... 但如果我们知道，那么确定发射和转移模型将非常容易！
- 另一方面，如果我们有这样的模型，我们可以使用我们讨论的推理方法来确定状态集

期望最大化 (EM)

- 适用于变量有“缺失值”的问题。
- 例如，在 HMMs 中，我们通常不观察状态

回顾：EM

- E 步：填补缺失变量期望值
使用当前参数估计值来计算隐藏变量的条件期望
- M 步：使用 E 步结果与已知变量做常规 MLE
最大化似然函数，即找到参数值，使得观测数据出现的概率最大
- 保证会收敛到似然函数的局部最小值



前向-后向算法

$$\begin{aligned} p(q_t = s_j \mid \mathbf{O}_{1:T}) &\propto p(q_t = s_j, \mathbf{O}_{t+1:T} \mid \mathbf{O}_{1:t}) \\ &\propto p(q_t = s_j \mid \mathbf{O}_{1:t}) p(\mathbf{O}_{t+1:T} \mid q_t = s_j, \mathbf{O}_{1:t}) \end{aligned}$$

前向变量

$$\alpha_t(i) = \Pr(O_1, \dots, O_t \wedge q_t = s_i)$$

后向变量

$$\beta_t(i) = \Pr(O_{t+1}, \dots, O_T \mid q_t = s_i)$$

利用 $\alpha_t(i), \beta_t(i)$ 可得

$$P(q_t = s_i \mid O_1, \dots, O_T) = \frac{\alpha_t(i) \beta_t(i)}{\sum_j \alpha_t(j) \beta_t(j)} \triangleq S_t(i)$$

状态与转移概率

- 状态概率

$$P(q_t = s_i \mid O_1, \dots, O_T) = \frac{\alpha_t(i)\beta_t(i)}{\sum_j \alpha_t(j)\beta_t(j)} \triangleq S_t(i)$$

- 转移概率

$$P(q_t = s_i, q_{t+1} = s_j \mid O_1, \dots, O_T) = S_t(i, j)$$

$$\begin{aligned} & P(q_t = s_i, q_{t+1} = s_j \mid o_1, \dots, o_T) \\ &= \frac{\alpha_t(i)P(q_{t+1} = s_j \mid q_t = s_i)P(o_{t+1} \mid q_{t+1} = s_j)\beta_{t+1}(j)}{\sum_k \alpha_t(k)\beta_t(k)} \\ &\triangleq S_t(i, j) \end{aligned}$$

- 计算 $S_t(i)$ 和 $S_t(i, j)$ 对于所有 t, i , 和 j ($1 \leq t \leq n, 1 \leq i \leq k, 2 \leq j \leq k$)

$$P(q_t = s_i \mid O_1, \dots, O_T) = S_t(i)$$

$$P(q_t = s_i, q_{t+1} = s_j \mid o_1, \dots, o_T) = S_t(i, j)$$

M 步

计算发射概率（这里我们假设多项分布）：

$$B_k(j) = \sum_{t: o_t=j} S_t(k)$$

然后

$$b_k(j) = \frac{B_k(j)}{\sum_i B_k(i)}$$

计算转移概率：

$$a_{i,j} = \frac{\hat{n}(i,j)}{\sum_k \hat{n}(i,k)}$$

其中

$$\hat{n}(i,j) = \sum_t S_t(i,j)$$

EM 算法 (Baum-Welch)

完整的 EM 算法用于学习 HMMs 的参数 (Baum-Welch)

- 输入: 1. 观测 $O_1 \cdots O_T$
- 2. 状态数, 模型
- 3. 猜测初始转移和发射参数
- 4. 计算 E 步: $S_t(i)$ 和 $S_t(i, j)$
- 5. 计算 M 步
- 6. 收敛? 若否, 则回到第 4 步
- 7. 输出完整模型

注: 我们没有讨论初始概率估计。这些可以从多组观察中推断出来 (例如, 用于语音处理的几个录制的客户)

Outline

1 背景


2 隐马尔可夫模型

3 学习 HMM

- MLE: 状态可观测
- EM 算法
- **构建 HMM**
- 因子 HMM
- 输入输出 HMM
- 动态贝叶斯网络 (DBN)


4 模型选择

构建 HMM——拓扑



- 匹配状态: 模型假设当前的观测值与隐藏状态相匹配, 即两个序列在该位置上的元素是对应的。
- 插入状态: 模型插入一个观测值, 而隐藏状态保持不变。
- 删除状态: 模型会跳过隐藏状态中的一个元素, 而观测序列保持不变。

构建 HMM——从现有路线



DNA 基序比对的 HMM 模型，过渡用箭头显示，其厚度表示其概率。在每种状态下，直方图显示四个碱基的概率

扩展的 HMM

- 因子 HMM

把“一个巨大的隐藏状态”拆成多个独立的隐藏子状态（因子），所有子状态共同决定观测分布。

- 输入输出 HMM

给标准 HMM 加入外部输入。

- 动态贝叶斯网络（DBN）

把贝叶斯网络随时间展开，构成有向图表示的马尔可夫过程。

Outline

1 背景

2 隐马尔可夫模型

3 学习 HMM

- MLE: 状态可观测
- EM 算法
- 构建 HMM
- **因子 HMM**
- 输入输出 HMM
- 动态贝叶斯网络 (DBN)


4 模型选择

示例：隐藏状态耦合

隐藏状态耦合指的是模型中不同隐藏状态之间的转移依赖于多个因素或属性。一个状态的转移不仅依赖于它自身的属性，还可能依赖于其他状态的属性


如何为一个具有以下特性的机器人设计 HMM？

- 游客机器人：机器人可以与游客互动。
- 位置：机器人在一个 $K \times K$ 的网格上移动。
- 语言机器人可以讲英语、西班牙语或法语。
- 交谈：机器人可以选择是否与游客交谈。



机器人导游 HMM

- 状态：由三元组位置, 语言, 交谈表示
- 发射概率：基于机器人的位置和是否有人交谈。
- 转移概率：描述三元组之间的转移。



转移概率示例：


$$P(\{Loc = (i, j), Lan = E, Tal = y\} \mid \{Loc = (i, j-1), Lan = E, Tal = n\})$$

状态解耦指的是模型中不同隐藏状态之间的转移只依赖于单个因素或属性，而不是多个因素

解耦可以简化模型，使其更容易训练和解释，但可能会牺牲一些表达能力

- 状态表示：状态通常由属性向量表示。
- 属性间转移：属性之间的转移不一定依赖于所有属性。
- 简化表示：如果当前位置决定下一位置独立于语言，则可以使用更简洁的表示方法。

因子 HMM




学习与推理: 因子 HMM

- M 步: 给定期望状态分配计算概率 (可耦合状态)
- E 步: 难, 观测耦合状态, 复杂度指数增长
- 实践中用 Monte Carlo 采样
采用 Monte Carlo 采样方法来近似 E 步期望值。

因子 HMM

也可用于表示不同类型状态之间的关系。同样，推理很困难，但如果状态是已知的（估计的），我们就可以计算转换和其他概率（但我们需要更多数据）



Outline

1 背景

2 隐马尔可夫模型


3 学习 HMM

- MLE: 状态可观测
- EM 算法
- 构建 HMM
- 因子 HMM
- **输入输出 HMM**
- 动态贝叶斯网络 (DBN)

4 模型选择

静态输入示例


- 场景：我们要做一个机器人位置跟踪器，它可以根据传感器读数判断机器人现在在哪里。
- 额外条件：现场共有三种不同型号的机器人，它们各自的速度范围、运动习惯（比如有的爱直线走，有的爱转弯）都不完全一样。
- 模型需求：为了让跟踪器对三种机器人都适用，我们需要在模型里显式输入“机器人型号”这一静态信息（即在整个跟踪过程中不会改变的输入），这样模型就能针对每种型号自动调整状态转移规律，从而提高定位精度。



处理机器人类型模型

- 单独建模：可以为 3 种机器人各建一个独立的 HMM
- 但这是一种浪费
参数重复、训练数据分散；
所有机器人都共享相同的输出概率
也许它们还共享其他属性（语言等）。
- 相反，如果我们能设计一个适合所有这些的模型，那就更好了
——把“机器人类型”作为静态输入（条件变量）嵌入到同一个模型里；
——共享共有的观测分布（甚至部分转移结构），仅让与类型相关的参数随输入变化。

输入输出 HMM



输入层仅影响转移概率

$$\Pr(Q, O \mid M) = \pi(q_1) p(o_1 \mid q_1) \prod_{t=2}^T \Pr(q_t \mid q_{t-1}, R) b(o_t \mid q_t)$$

学习与推理: 输入输出 HMM

- 取决于转换概率的建模方式。
- 由于给出了 R , 我们可以为每个 R 值学习一个新的转换表 (请注意, 无论 R 如何, 发射概率仍然相同)。
离散输入: 为每个 R 值单独建一张转移表。


$$P(q_{t+1} = s_j \mid q_t = s_i, R = r) = A_{ij}^{(r)}, \quad r \in \{1, \dots, M\}.$$

连续输入: 例如, 逻辑回归分类器。


$$P(q_{t+1} = s_j \mid q_t = s_i, R) = \frac{\exp(\mathbf{w}_{i,j}^\top R + b_{i,j})}{\sum_{k=1}^K \exp(\mathbf{w}_{i,k}^\top R + b_{i,k})}.$$

对于这样的过渡, 学习更难

更一般输入输出 HMM



更一般输入输出 HMM



Outline

1 背景

2 隐马尔可夫模型

3 学习 HMM

- MLE: 状态可观测
- EM 算法
- 构建 HMM
- 因子 HMM
- 输入输出 HMM
- 动态贝叶斯网络 (DBN)

4 模型选择


示例：股价预测示例

已知今日 MSFT、YHOO、EBAY 价格与昨日 GOOG 价格，能否预测 GOOG 今日价格？


即使没有显式的隐藏变量，时间序列之间的复杂依赖关系仍然可以用动态贝叶斯网络（DBN）来建模

动态贝叶斯网络 (DBN)

- DBN 是贝叶斯网络的扩展
- 他们遵循相同的语义
仍然使用条件概率表 (CPT) 表达父子节点关系;
仍然用联合概率 $= \prod$ 局部条件概率的乘积展开。
- 但它们会随着时间的推移而重复, 因此允许循环 (时间单位之间)。



动态贝叶斯网络 (DBN)



- 更接近 BN 而非 HMM
- 学习与推理 NP-hard
- 需近似方法
 - 爬山算法
启发式搜索算法，用于寻找函数的最大值。
从当前解出发，随机选择一个邻近解，如果新解更优，则接受新解。
 - 退火算法启发式随机搜索算法，用于全局优化。
随机扰动当前解，如果新解更优，则接受新解。
 - 贪婪算法
近似算法，每一步都选择当前最优解。

Outline

1 背景

- 马尔可夫模型
- 贝叶斯网络

2 隐马尔可夫模型

- HMM 定义
- HMM 推导
- $P(q_t = A)$
- $P(Q | O)$
- $\operatorname{argmax}_Q P(Q)$

3 学习 HMM

- MLE: 状态可观测
- EM 算法
- 构建 HMM
- 因子 HMM
- 输入输出 HMM
- 动态贝叶斯网络 (DBN)

- 有多少个状态?
状态的数量影响模型的复杂度和预测能力
- 使用什么拓扑结构来构建状态转移图?
拓扑结构决定了状态之间的转移可能性
常见的拓扑结构包括全连接图、带状图、树状图等

隐藏状态的数量

在隐马尔可夫模型中选择隐藏状态的数量 K 类似于选择混合成分的数量问题。以下是一些可能的解决方案：

- 使用网格搜索在一系列 K 上进行搜索，使用交叉验证似然、BIC 分数或对数边际似然的变分下界作为目标函数。
- 使用可逆跳跃 MCMC。详见（Fruhwirth-Schnatter 2007）了解详细信息。注意，这种方法非常慢且不常用。
- 使用变分贝叶斯“消灭”不需要的成分，类似于第 21.6.16 节中讨论的 GMM 案例。详见（MacKay 1997; Beal 2003）了解详细信息。
- 使用基于层次 Dirichlet 过程的“无限 HMM”。详见例如（Beal et al. 2002; Teh et al. 2006）了解详细信息。

识别出哪些状态转移是可能的，从而构建一个稀疏的、有意义的状态转移矩阵。希望学习状态转移图的结构，而不是图形模型的结构（这是固定的）

- 启发式方法：基于经验规则或领域知识
- 贝叶斯方法：引入先验分布来指导结构学习。例如，可以使用最小熵先验来偏好稀疏的转移矩阵。

- 为什么用 HMM ? 适用场景
- 学习 HMM: EM 算法 (Baum-Welch)
- HMM 扩展

Feedback welcome!

The End