

统计机器学习基础

Foundations of Statistical Machine Learning

——计算学习理论

Kai Chen

kaichen6@csu.edu.cn

24th September 2025



中南大学
CENTRAL SOUTH UNIVERSITY

数学与统计学院
SCHOOL OF MATHEMATICS AND STATISTICS

1 计算学习理论介绍

- 耗尽版本空间
- PAC 可学习性
- 不可知学习

2 VC 维和模型复杂度

- VC 维
- 样本复杂度
- 统计学习问题
- SRM 策略

3 总结

1 计算学习理论介绍

- 耗尽版本空间
- PAC 可学习性
- 不可知学习

2 VC 维和模型复杂度

- VC 维
- 样本复杂度
- 统计学习问题
- SRM 策略

3 总结

学习的可泛化性

- 机器学习真正关心的是泛化误差，但大多数算法仅在训练集上拟合模型
 - 泛化误差：指的是模型在新数据（测试集）上的平均误差
 - 过拟合：许多机器学习算法倾向于在训练数据上表现得很好，但这种表现并不总是能转移到新数据上。这种现象称为过拟合，即模型过于复杂，捕捉到了训练数据中的噪声而不是潜在的模式。
- 为什么训练集表现好能告诉我们泛化误差？
训练集上的性能与泛化误差之间的关系
- 能否证明学习算法在未见测试数据上表现良好的条件？
一些理论结果，如 VC 维（Vapnik-Chervonenkis 维）、Rademacher 复杂度等，提供了关于模型泛化能力的某些理论保证

学习复杂度

学习复杂度主要沿两条轴线衡量：信息复杂度和计算复杂度

- 信息复杂度：关注学习的泛化性能
 - 需要多少训练样本？
 - 学习器估计收敛到真实参数的速度？
- 计算复杂度：关注训练数据上提取学习器所需的计算资源
- 似乎当算法在其中一个度量方面有所改进时，它相对于另一个度量会恶化。

一般定律约束归纳学习

“一般定律约束归纳学习” (Generalization in Inductive Learning) 是指在机器学习中，模型从有限的训练数据中学习，并能够对未见过的新数据做出准确预测的能力。

- 样本复杂度：多少训练样本足以学习目标概念？
- 计算复杂度：学习目标概念所需的资源？
- 关联理论：
 - 训练样本数量与质量 m
 - 假设/概念空间 $\mathcal{H}$ 的复杂度
 - 对目标概念近似的精度 ε
 - 成功学习的概率 δ

典型概念学习任务

二元分类

- 我们在这里所说的一切都可以推广到其他问题，包括回归和多类分类问题。

给定：

- 实例 X ：可能的日子，每个日子由属性 Sky 、 $AirTemp$ 、 $Humidity$ 、 $Wind$ 、 $Water$ 、 $Forecast$ 描述。
- 目标函数 $c: EnjoySport: X \rightarrow \{0, 1\}$
- 假设空间 H ：文字的合取。例如， $(?, Cold, High, ?, ?, ?, EnjoySport)$ 。
- 训练样本 S ：标识目标函数的正例和负例 $(x_1, C(x_1)), \dots (x_m, C(x_m))$

确定：

- 一个假设 $h \in H$ ，使得 $h(x)$ 对于所有 $x \in S$ 相对于 $c(x)$ 是“好的”。
- 一个假设 $h \in H$ ，使得 $h(x)$ 对于所有 x 在真实分布 $\mathcal{D}$ 中相对于 $c(x)$ 是“好的”。

两种基本竞争框架

PAC (Probably Approximately Correct) 框架

- 样本标签一致性：在 PAC 框架中，假设样本标签与某个假设 h 在假设类 H 中是一致的。
- 绝对误差上界：学习器的假设需要满足一个绝对误差上界。也就是说，学习器的目标是找到一个假设，其在真实分布上的错误率有一个明确的上限。

不可知框架

- 无先验限制：在不可知框架中，不对样本标签施加任何先验限制。这意味着样本标签可能与任何假设都不完全一致
- 相对误差上界：在这种框架下，对假设错误率的上界要求是相对的，即相对于类中最佳假设的错误率。学习器的目标是找到一个假设，其错误率不会比类中最佳假设的错误率高太多。


样本复杂度

- 需要多少训练样本才能学习目标概念？
- 训练场景：
 - ① 如果学习者提出实例作为对教师的查询
 - 学习者提出实例 x ，教师提供 $c(x)$
 - ② 如果教师（知道 c ）提供训练样本
 - 教师提供形式为 $(x, c(x))$ 的示例序列
 - ③ 如果某个随机过程（例如，自然）提出实例
 - 随机生成实例 x ，教师提供 $c(x)$

协议

给定：

- 集合 X ：表示所有可能的样本点的集合。
- 固定（未知）分布 D ：表示样本点 X 遵循的分布，这个分布是固定的，但在学习过程中是未知的。
- 一组假设 H ：表示所有可能的分类器或模型的集合。
- 一组可能的目标概念 C ：表示所有可能的目标函数或标签函数的集合。



学习者观察样本 $S = \{\langle x_i, c(x_i) \rangle\}$

- 每个样本 x_i 从分布 D 中抽取, 并且由目标概念 $c \in C$ 标记
- 学习者不知道 c_i/D ,

学习者输出 $h \in H$ 估计 c

- 估计 c : 学习者从假设集合 H 中选择一个假设 h , 这个假设用来估计目标概念 c
- 通过后续从 D 中抽取的实例评估 h : 学习者选择的假设 h 将通过在分布 d 中抽取的新实例上的表现来评估。

目前假设:

- $C = H$ (所以 $c \in H$) 即学习者可以从 H 中找到一个与目标概念 c 完全匹配的假设。
- 无噪声数据: 假设样本标签是完全准确的, 没有噪声。

两种误差概念

训练误差（即，关于目标概念 c 的假设 h 的经验风险或经验误差）

- 在训练实例 S 上 $h(x) \neq c(x)$ 的频率

$$\hat{\epsilon}_S(h) \equiv \Pr_{x \in S}[c(x) \neq h(x)] \equiv \frac{1}{|S|} \sum_{x \in S} \delta(c(x) \neq h(x))$$


真实误差（即，泛化误差，测试误差）关于 c 的假设 h

- 在从 $\mathcal{D}$ 中抽取的未来随机实例上 $h(x) \neq c(x)$ 的频率

$$\epsilon_{\mathcal{D}}(h) \equiv \Pr_{x \in \mathcal{D}}[c(x) \neq h(x)]$$

我们能否将 $\hat{\epsilon}_{\mathcal{D}}(h)$ 限制为 $\hat{\epsilon}_S(h)$ 的函数？

假设的真实误差



定义：假设 h 关于目标概念 c 与分布 $\mathcal{D}$ 的真实误差为随机从 $\mathcal{D}$ 抽取实例被 h 误分类的概率。

$$\varepsilon_{\mathcal{D}}(h) = \Pr_{x \sim \mathcal{D}}[c(x) \neq h(x)]$$

并集界 (Union Bound)

引理 (并集界) :

设 $A_1; A_2, \dots, A_k$ 为 k 个不同的事件 (可能不独立)。则

$$P(A_1 \cup A_2 \cup \dots \cup A_k) \leq P(A_1) + P(A_2) + \dots + P(A_k)$$

在概率论中, 通常将并集界作为公理陈述 (因此我们不会尝试证明它), 但它也具有直观意义: 至少一个 k 个事件发生的概率最多是 k 个不同事件概率之和。

Hoeffding 不等式

引理 (Hoeffding 不等式) :

设 $Z_1, \dots, Z_m$ 为 m 个独立同分布的 (iid) 随机变量, 来自参数为 ϕ 的伯努利分布, 即 $P(Z_i = 1) = \phi$, $P(Z_i = 0) = 1 - \phi$ 。

令 $\hat{\phi} = (1/m) \sum_{i=1}^m Z_i$ 为这些随机变量的均值, 设任意 $\gamma > 0$ 为固定值。则

$$P(|\hat{\phi} - \phi| > \gamma) \leq 2 \exp(-2\gamma^2 m)$$

这个引理 (在机器学习理论中也称为 Chernoff 界) 表明, 如果我们取 $\hat{\phi}$ —— m 个伯努利 (ϕ) 随机变量的平均值——作为 ϕ 的估计, 那么我们偏离真实值的概率很小, 只要 m 足够大。

版本空间 (Version Space)

版本空间是指在给定的训练数据下，所有可能的假设（模型或分类器）的集合。

- 一个假设 h 与目标概念 c 的一组训练样本 S 一致，当且仅当对于每个训练样本 $\langle x_i, c(x_i) \rangle \in S$ ，有 $h(x) = c(x)$

$$\text{Consistent}(h, S) \models h(x) = c(x), \forall \langle x, c(x) \rangle \in S$$

- 版本空间 $VS_{H,S}$ ，相对于假设空间 H 和训练样本 S ，是 H 中与 S 中所有训练样本一致的假设的子集

$$VS_{H,S} \equiv \{h \in H \mid \text{Consistent}(h, S)\}$$

一致学习器

- 如果一个学习器输出的假设能够完美拟合训练数据，则称其为一致的。
- 这是一个相当合理的学习策略
它确保了学习器在已知数据上的表现是最优的
- 每个一致学习输出的假设都属于版本空间。
- 我们想知道这样的假设如何泛化。

可能近似正确 (PAC)

PAC (可能近似正确) 学习理论提供了一种评估学习算法性能的方法

目标: 确保学习器产生的假设不仅在训练数据上表现良好, 而且在未知数据上也能保持较好的性能。


- PAC-学习器产生一个假设 $\hat{h}$, 该假设近似正确, 即 $\epsilon_{\mathcal{D}}(\hat{h}) < 0$, 具有高概率 $P(\epsilon_{\mathcal{D}}(\hat{h}) < 0) \approx 1$ 。

双重模糊:

- 近似: 允许假设在分布 D 上的错误率接近于 0, 而不是严格等于 0
- 可能: 允许学习器在大多数情况下找到近似正确的假设, 而不是在所有情况下
- 需要两者!

- 1 计算学习理论介绍
 - 耗尽版本空间
 - PAC 可学习性
 - 不可知学习
- 2 VC 维和模型复杂度
- 3 总结

耗尽版本空间



(r = training error, $error$ = true error)

定义：版本空间 $VS_{H,S}$ 被称为关于 c 和 S 是 ϵ -耗尽的，如果 $VS_{H,S}$ 中的每个假设 h 关于 c 和 $\mathcal{D}$ 的真实误差小于 ϵ 。

$$\forall h \in VS_{H,S}, \quad \hat{\epsilon}_{\mathcal{D}}(h) < \epsilon$$

耗尽版本空间

多少样本耗尽版本空间？

定理：[Haussler, 1988]。

- 如果假设空间 H 是有限的， S 是某个目标概念 c 的 $m \geq 1$ 个独立随机样本的序列，那么对于任何 $0 \leq \epsilon \leq 1/2$ ，版本空间相对于 H 和 S 不是 ϵ -耗尽（相对于 δ ）的概率小于 $|H|e^{-\epsilon m}$ 。

$$|H|e^{-\epsilon m}$$

这限制了任何一致学习器输出一个 $\epsilon(\hat{h}) \geq \epsilon$ 的假设 h 的概率。

证明：

1. **定义错误率：** 对于一个假设 $h \in H$ ，其在目标概念 c 上的错误率定义为 $\varepsilon(h) = \Pr_{x \sim D}[h(x) \neq c(x)]$ 。
2. **计算单个假设的概率：** 对于一个特定的假设 h ，其错误率 $\varepsilon(h) \geq \varepsilon$ 的概率可以通过二项分布来计算。由于样本是独立同分布的，我们有：

$$\Pr[\varepsilon(h) \geq \varepsilon] \leq e^{-\varepsilon m}$$

这是因为错误率至少为 ε 相当于至少有 εm 个样本被错误分类，而每个样本被错误分类的概率是 ε 。

(续) 证明:

3. **应用联合界限**: 由于 H 是有限的, 我们可以使用联合界限 (Union Bound) 来计算所有假设都满足 $\varepsilon(h) \geq \varepsilon$ 的概率。联合界限表明:

$$\Pr[\exists h \in H, \varepsilon(h) \geq \varepsilon] \leq |H| \Pr[\varepsilon(h) \geq \varepsilon]$$

将步骤 2 中的结果代入, 得到:

$$\Pr[\exists h \in H, \varepsilon(h) \geq \varepsilon] \leq |H| e^{-\varepsilon m}$$

4. **结论**: 这表明版本空间相对于 H 和 S 不是 ε -穷尽的概率小于 $|H| e^{-\varepsilon m}$ 。

[Haussler, 1988]: 在经过 m 个训练样本后, 版本空间没有被 ϵ 耗尽的概率最多为 $|H|e^{-\epsilon m}$

$$\Pr(\exists h \in H, \text{ s.t. } (\text{error}_{\text{train}}(h) = 0) \wedge (\text{error}_{\text{true}}(h) > \epsilon)) \leq |H|e^{-\epsilon m}$$

- 假设我们希望这个概率最多为 δ
- 需要多少训练样本?

$$m \geq \frac{1}{\epsilon} (\ln |H| + \ln(1/\delta))$$

- 如果 $\text{error}_{\text{train}}(h) = 0$ 那么以至少 $1 - \delta$ 的概率:

$$\text{error}_{\text{true}} \leq \frac{1}{m} (\ln |H| + \ln(1/\delta))$$

学习布尔文字的合取

- 需要多少样本才能确保以至少 $1 - \delta$ 的概率, 每个 $h \in VHS_{H,S}$ 满足 $\varepsilon_D(h) \leq \varepsilon$?
- 使用我们的定理:

$$m \geq \frac{1}{\varepsilon} (\ln |H| + \ln(1/\delta))$$

- 假设 H 包含最多 n 个布尔属性的约束合取 (即, n 个布尔文字)。那么 $|H| = 3^n$, 且

$$m \geq \frac{1}{\varepsilon} (\ln 3^n + \ln(1/\delta))$$

或者

$$m \geq \frac{1}{\varepsilon} (n \ln 3 + \ln(1/\delta))$$

$$m \geq \frac{1}{\varepsilon} (\ln |H| + \ln(1/\delta))$$

- 如果 H 如 EnjoySport 中给出的 $|H| = 729$, 且

$$m \geq \frac{1}{\varepsilon} (\ln 729 + \ln(1/\delta))$$

- 如果我想确保以 95% 的概率, $\forall S$ 仅包含 $\varepsilon_s(h) \leq .1$ 的假设, 那么有 m 个样本, 其中

$$m \geq \frac{1}{.1} (\ln 729 + \ln(1/.05))$$

$$m \geq 10 (\ln 729 + \ln 20)$$

$$m \geq 10 (6.59 + 3.00)$$

$$m \geq 95.9$$

1 计算学习理论介绍

- 耗尽版本空间
- PAC 可学习性
- 不可知学习

2 VC 维和模型复杂度

3 总结

1 计算学习理论介绍

- 耗尽版本空间
- PAC 可学习性
- 不可知学习

2 VC 维和模型复杂度

- VC 维
- 样本复杂度
- 统计学习问题
- SRM 策略

3 总结

一个学习算法是 PAC 可学习的，如果它满足以下两个条件：

- 多项式计算复杂度
算法处理每个样本所需的计算资源（如时间或内存）不会随着样本复杂度的增加而指数级增长。
- 多项式样本复杂度
算法需要的样本数量不会随着样本特征数量的增加而指数级增长。

定理：布尔文字的合取是 PAC 可学习的。

- 学习器 L 可以在单位时间内抽取标记实例 $(x, c(x))$, $x \in X$ 的长度为 n 从分布 $\mathcal{D}$ 中抽取, 由目标概念 $c \in C$ 标记
- 定义:** 学习器 L 使用假设空间 H PAC-学习类 C 当且仅当:
 - 对于任何目标概念 $c \in C$, 任何分布 $\mathcal{D}$, 任何 ε 满足 $0 < \varepsilon < 1/2$, 任何 δ 满足 $0 < \delta < 1/2$, 学习器 L 返回一个 $h \in H$ 使得:

以概率 $\geq 1 - \delta$, 有 $\text{err}_{\mathcal{D}}(h) < \varepsilon$

- L 的运行时间 (因此, 样本复杂度) 是多项式级别的, 关于 $|x|$, $\text{size}(c)$, $1/\varepsilon$, $1/\delta$.
- 充分条件:**
 - 只有多项式数量的训练实例 ... $|H| = 2^{\text{poly}(|x|)}$
 - 只有多项式时间/实例 ...
 - 通常 $C = H$
 - $m \geq \frac{1}{\varepsilon} (\ln |H| + \ln(1/\delta))$

- 1 计算学习理论介绍
 - 耗尽版本空间
 - PAC 可学习性
 - 不可知学习
- 2 VC 维和模型复杂度
- 3 总结

1 计算学习理论介绍

- 耗尽版本空间
- PAC 可学习性
- 不可知学习

2 VC 维和模型复杂度

- VC 维
- 样本复杂度
- 统计学习问题
- SRM 策略

3 总结

到目前为止，假设 $c \in H$

- 不可知学习设置：不假设 $c \in H$
- 我们想要什么？
 - 在训练数据上犯最少错误的假设 h
- 在这种情况下样本复杂度是什么？
- $m \geq \frac{1}{2\epsilon^2}(\ln |H| + \ln(1/\delta))$
- 从 Hoeffding 界限得出：

$$Pr[error_{\mathcal{D}}(h) > error_S(h) + \epsilon] \leq e^{-2m\epsilon^2}$$

经验风险最小化范式

- 选择一个假设类 H 作为 X 的子集
- 对于输入样本 S , 找到一些 $h \in H$ 适合 S 良好
- 对于新点 x , 根据其在 h 中的成员资格预测标签

$$\hat{h} = \arg \min_{h \in H} \hat{\epsilon}_S(h)$$

- 示例:
 - 考虑线性分类, 并令 $h_\theta(x) = 1\{\theta^T x \geq 0\}$
 - 那么 $H = \{h_\theta : h_\theta(x) = 1\{\theta^T x \geq 0\}, \theta \in R^{n+1}\}$
 - $\hat{\theta} = \arg \min_{\theta} \hat{\epsilon}_S(h_\theta)$
- 我们认为 ERM 是最“基本”的学习算法, 它将是我们将在剩余部分中关注的算法
- 在我们的学习理论研究中, 从假设的具体参数化和我们是否使用线性分类器或 ANN 的问题中抽象出来将是有益的

有限 $\mathcal{H}$ 情形

- $H = \{h_1, \dots, h_k\}$ 由 k 个假设组成 (有限的候选模型集合)
- 我们希望对 $\hat{h}$ 的泛化误差给出保证
- 首先, 我们将展示 $\hat{\varepsilon}(\hat{h})$ 是所有 h 的 $\varepsilon(h)$ 的可靠估计
- 其次, 我们将展示这种可靠性意味着 $\hat{h}$ 的泛化误差的上界

误分类概率

- 二元分类器的结果可以看作是一个伯努利随机变量 Z :

$$Z = 1\{h_i(x) \neq c(x)\}$$

- 对于每个样本:

$$Z_j = 1\{h_i(x_j) \neq c(x_j)\}$$

$$\hat{\varepsilon}(h_i) = \frac{1}{m} \sum_{j=1}^m Z_j$$

- Hoeffding 不等式

$$\Pr(|\varepsilon(h_i) - \hat{\varepsilon}(h_i)| > \gamma) \leq 2 \exp(-2\gamma^2 m)$$

- 这表明, 对于我们特定的 h_i , 训练误差将与泛化误差非常接近, 假设 m 足够大。

一致收敛

- 但我们不仅仅想保证 $\hat{\epsilon}(h_i)$ 将接近 $\epsilon(h_i)$ (具有高概率) 对于一个特定的 h_i 。我们想证明这至少对一个 $h_i \in H$ 成立。
- 对于 k 个假设:

$$\begin{aligned}Pr(\exists h \in H, |\epsilon(h_i) - \hat{\epsilon}(h_i)| > \gamma) &= P(A_1 \cup \dots \cup A_k) \\&< \sum_{i=1}^k P(A_i) \\&= \sum_{i=1}^k 2 \exp(-2\gamma^2 m) \\&= 2k \exp(-2\gamma^2 m)\end{aligned}$$

- 这意味着:

$$\begin{aligned}P(\neg \exists h \in H, |\epsilon(h_i) - \hat{\epsilon}(h_i)| > \gamma) &= P(\forall h \in H, |\epsilon(h_i) - \hat{\epsilon}(h_i)| \leq \gamma) \\&= 1 - 2k \exp(-2\gamma^2 m)\end{aligned}$$

一致收敛

- 在上述讨论中，我们所做的是，对于特定的 m 和 γ 值，在给定概率的界限下：

$$|\epsilon(h_i) - \hat{\epsilon}(h_i)| > \gamma$$

对于某些 $h_i \in H$

- 这里有三个感兴趣的量： m 和 γ ，以及错误概率 δ ；我们可以根据其他两个量来界定任何一个量。

样本复杂度

- 我们需要多少训练样本才能做出保证？

$$P(\exists h \in H, |\varepsilon(h) - \hat{\varepsilon}(h)| > \gamma) = 2k \exp(-2\gamma^2 m) < \delta$$

- 我们发现如果

$$m \geq \frac{1}{2\gamma^2} \log \frac{2k}{\delta}$$

那么以至少 $1 - \delta$ 的概率，我们有对于所有 $h_i \in H$, $|\varepsilon(h_i) - \hat{\varepsilon}(h_i)| \leq \gamma$

- 上述界限的关键属性是，为了做出这种保证所需的训练样本数量仅对 k ，即假设空间 H 中的假设数量是对数增长的。这将在后面很重要。

泛化误差界

- 类似地，我们也可以固定 m 和 δ 并在之前的等式中求解 γ ，并再次证明 [再次说服自己这是正确的！] 以概率 $1 - \delta$ ，我们有对于所有 $h_i \in H$

$$|\hat{\varepsilon}(h) - \varepsilon(h)| \leq \sqrt{\frac{1}{m} \log \frac{2k}{\delta}}$$

- 定义 $h^* = \arg \min_{h \in H} \varepsilon(h)$ 为 H 中可能的最佳假设（回想一下，这不一定是 $\hat{h}$ ERM $\hat{h} = \arg \min_{h \in H} \hat{\varepsilon}_S(h)$ ）

$$\varepsilon(\hat{h}) \leq \hat{\varepsilon}(\hat{h}) + \gamma \leq \hat{\varepsilon}(h^*) + \gamma \leq \varepsilon(h^*) + 2\gamma$$

- 如果发生一致收敛，则 $\hat{h}$ 的泛化误差最多比 H 中可能的最佳假设差 2γ

总结

定理：设 $|\mathcal{H}| = k$ ，让任意 m, δ 固定。那么以至少 $1 - \delta$ 的概率，我们有

$$\varepsilon(\hat{h}) \leq \left(\min_{h \in \mathcal{H}} \varepsilon(h) \right) + 2\sqrt{\frac{1}{2m} \log \frac{2k}{\delta}}$$

推论：设 $|\mathcal{H}| = k$ ，让任意 δ, γ 固定。那么对于 $\varepsilon(\hat{h}) \leq \min_{h \in \mathcal{H}} \varepsilon(h) + 2\gamma$ 以至少 $1 - \delta$ 的概率成立，只需满足

$$m \geq \frac{1}{2\gamma^2} \log \frac{2k}{\delta} = O\left(\frac{1}{\gamma^2} \log \frac{k}{\delta}\right)$$

- 1 计算学习理论介绍
- 2 VC 维和模型复杂度
 - VC 维
 - 样本复杂度
 - 统计学习问题
 - SRM 策略
- 3 总结

回顾：PAC 与不可知学习

- 有限 $\mathcal{H}$, 假设目标函数 $c \in \mathcal{H}$:

$$\Pr(\exists h \in H, \text{ s.t. } (\text{error}_{\text{train}}(h) = 0) \wedge (\text{error}_{\text{true}}(h) > \epsilon)) \leq |H|e^{-\epsilon m}$$

- 若要求概率至多为 δ , 则样本数满足:

$$m \geq \frac{1}{\epsilon} (\ln |\mathcal{H}| + \ln \frac{1}{\delta})$$

- 有限 $\mathcal{H}$, 不可知学习:

$$P(\exists h \in H, |\epsilon(h) - \hat{\epsilon}(h)| > \gamma) = 2k \exp(-2\gamma^2 m)$$

$$m \geq \frac{1}{2\gamma^2} \log \frac{2k}{\delta}$$

- 以概率至少 $1 - \delta$,

$$\epsilon(\hat{h}) \leq \left(\min_{h \in H} \epsilon(h) \right) + 2\sqrt{\frac{1}{m} \log \frac{2k}{\delta}}$$

当 $\mathcal{H}$ 无限时怎么办？

- 无法使用有限假设空间的结果

当我们的假设空间是有限的时候，我们可以使用一些特定的结果来分析学习算法的性能，例如样本复杂度（即需要多少个样本来保证学习算法的性能）和泛化误差的界限

在实际应用中，我们经常遇到的假设空间是无限的，例如神经网络的权重空间

- 需要新的复杂度度量
——Vapnik-Chervonenkis (VC) 维

当 $\mathcal{H}$ 无限时怎么办？

- 非正式推导示例

- 假设我们有一个由 d 个实数参数化的 H 。由于我们使用计算机来表示实数，并且 IEEE 双精度浮点数（C 语言中的 `double` 类型）使用 64 位来表示一个浮点数，这意味着我们的学习算法，假设我们使用的是双精度浮点数，是由 $64d$ 位参数化的

- 参数化

如何刻画“能力”？


- 不同机器拥有不同的“能力”
- 权衡：
 - 更强能力：可建模更复杂分类器，但可能过拟合
 - 更弱能力：不会过拟合，但表达受限
- 如何量化“能力”？

打散一组实例

- **定义：** 给定一个集合 $S = \{x^{(1)}, \dots, x^{(m)}\}$ （与训练集无关）的点 $x^{(i)} \in X$ ，我们说 H 打散 S 如果 H 能在 S 上实现任何标记。
- 即，对于任何一组标签 $\{y^{(1)}, \dots, y^{(d)}\}$ ，存在某个 $h \in H$ 使得 $h(x^{(i)}) = y^{(i)}$ 对所有 $i = 1, \dots, m$ 成立。
- 有 2^m 种不同的方法将样本分成两个子样本（一个二分法）。


三实例被打散示例

Instance space X



Vapnik-Chervonenkis 维

定义：假设空间 $\mathcal{H}$ 在实例空间 X 上的 VC 维 $VC(\mathcal{H})$ 是 $\mathcal{H}$ 能打散的最大有限子集的大小；若 $\mathcal{H}$ 可打散任意大有限集，则 $VC(\mathcal{H}) = \infty$ 。




考虑 $X = \mathbb{R}$, 想要学习 $c: X \rightarrow \{0, 1\}$

- 开区间:
 - H_1 : 如果 $x > a$, 则 $y = 1$ 否则 $y = 0$
- 闭区间:
 - H_2 : 如果 $a < x < b$, 则 $y = 1$ 否则 $y = 0$

VC 维: 示例

考虑 $X = \mathbb{R}^2$, 想要学习 $c: X \rightarrow \{0, 1\}$

- 平面上直线的 VC 维是多少?
- $H = \{((wx + b) > 0 \Rightarrow y = 1)\}$




(a)





(b)

VC 维: 示例



- 对于这些点的八个可能标记中的任何一个，我们都可以找到一个线性分类器，它可以在它们上获得“零训练误差”


VC 维: 示例



- 这里 H 的 VC 维度是 3, 即使可能有尺寸为 3 的集合无法打散
- 在 VC 维度的定义下, 为了证明 $VC(H)$ 至少是 d , 我们只需要证明至少有一组大小 d 可以打散

- 定理：考虑 $\mathbb{R}^n$ 中的一组 m 个点。选择这些点中的任意一个作为原点。那么，只有当剩余点的位置向量线性无关时，这 m 个点才能被定向超平面打散。
- 推论：在 $\mathbb{R}^n$ 中，定向超平面集合的 VC 维是 $n + 1$ 。
证明：我们总是可以选择 $n + 1$ 个点，然后选择其中一个点作为原点，使得剩余 n 个点的位置向量线性无关，但我们永远不能选择 $n + 2$ 个这样的点（因为在 $\mathbb{R}^n$ 中，没有 $n + 2$ 个向量可以线性无关）。

VC 维与参数数量



- VC 维因此为给定的 h 集合的容量提供了具体性。
- 是否具有许多参数的学习机将具有高 VC 维，而具有少量参数的学习机将具有低 VC 维？

一个具有无限 VC 维的函数，但只有一个参数！

$$f(x, \alpha) \equiv \theta(\sin(\alpha x)), \quad x, \alpha \in \mathbb{R}$$

其中 θ 是指示函数

具有单一参数的无限 VC 函数

- 你选择一个数字 l , 并将任务交给我, 即找到可以被打散的点/点集。我选择它们为

$$x_i = 10^{-i} \quad i = 1, \dots, l.$$


- 你可以指定任何标签:

$$y_1, y_2, \dots, y_l, \quad y_i \in \{-1, 1\}$$

- 那么 $\alpha(\alpha)$ 给出这种标记, 如果我选择 α 为

$$\alpha = \pi \left(1 + \sum_{i=1}^l \frac{(1 - y_i)10^i}{2} \right)$$

- 因此, 该机器的 VC 维是无限的。



- 1 计算学习理论介绍
- 2 VC 维和模型复杂度
 - VC 维
 - **样本复杂度**
 - 统计学习问题
 - SRM 策略
- 3 总结

从 VC 维到样本复杂度

- 需要多少个随机抽取的样本足以以至少 $(1 - \delta)$ 的概率 ε -穷尽 $VS_{H,S}$?
- 即, 保证任何完美拟合训练数据的假设在相同分布的测试数据上大致正确的概率为 $(1 - \delta)$ 。

$$m \geq \frac{1}{\varepsilon} (4 \log_2(2/\delta) + 8 |VC(H)| \log_2(13/\varepsilon))$$

- 与我们基于 $|H|$ 的早期结果进行比较:

$$m \geq \frac{1}{2\varepsilon^2} (\ln |H| + \ln(1/\delta))$$

到目前为止：需要多少样本来学习？在收敛之前会犯多少错误？

让我们考虑类似的 PAC 学习设置：

- 从 X 根据分布 D 随机抽取实例
- 学习器必须在从教师那里获得正确分类之前对每个实例进行分类
- 我们能否限制学习器在收敛之前犯错误的次数？

- 1 计算学习理论介绍
- 2 VC 维和模型复杂度
 - VC 维
 - 样本复杂度
 - 统计学习问题
 - SRM 策略
- 3 总结

统计学习问题

- 一个模型计算一个函数: $h(X, w)$
- 问题: 最小化在 w 上的风险期望

$$R(w) = \int Q(z, w) dP(z)$$

- w : 指定所选模型的参数
- $z = (X, y)$: 属性 (变量) 的可能值
- Q : 衡量 (量化) 模型误差成本
- $P(z)$: 数据 z 的底层概率法则 (未知)

统计学习问题

- 我们从学习样本 $(z_1, \dots, z_m)$ 中获得 m 个数据，我们假设它们是从法则 $P(z)$ 中独立采样的。
- 为了最小化 $R(w)$ ，我们首先通过最小化该样本上的实证风险开始：

$$E(W) = \frac{1}{m} \sum_{i=1}^m Q(Z_i, W)$$



- 我们将使用这种方法：
 - 分类（例如， Q 可以是基于误分类点的成本函数）
 - 回归（例如， Q 可以是最小二乘类型的成本）

- 统计学习理论的核心问题：
 - 风险期望 $R(W)$ 和实证风险 $E(W)$ 之间的关系是什么？
 - 如何定义和测量模型的泛化能力（“鲁棒性”）？

统计学习理论的四大支柱

- 一致性（保证泛化）
 - 在什么条件下模型会是一致的？
- 模型收敛速度（泛化的度量）
 - 当样本大小 L 增加时，泛化能力如何提高？
- 泛化能力控制
 - 如何从仅有的给定信息：我们的样本数据，有效地控制模型泛化？
- 良好学习算法的策略
 - 是否存在一种策略可以保证、衡量和控制我们的学习模型的泛化能力？

泛化能力示例图



- 问：在什么条件下学习模型是一致的？
- 答：一个模型将是一致的，当且仅当定义模型的函数 h 来自具有有限 VC 维 d 的函数族 H 。
- 有限 VC 维 d 不仅保证了泛化能力（一致性），而且在有限 VC 维 d 的函数族 H 中选择 h 是构建泛化模型的唯一方法。

模型收敛速度（泛化能力）

- 问：学习数据（样本）和测试数据之间模型误差差异的性质是什么，对于有限大小 m 的样本？
- 答：这种差异不超过一个仅依赖于模型函数族 H 的 VC 维 d 和样本大小 m 之比 d/m 的极限。
- 该陈述是一个新的定理，属于 Kolmogorov-Smirnov 结果方式，即不依赖于数据底层概率法则的定理。

不可知学习：VC 界限

- 定理：设 H 已给定，令 $d = VC(H)$ 。那么以至少 $1 - \delta$ 的概率，我们有对于所有 $h \in H$,

$$|\hat{\epsilon}(h) - \epsilon(h)| \leq O\left(\sqrt{\frac{d}{m} \log \frac{m}{d} - \frac{1}{m} \log \delta}\right)$$


或者

$$\epsilon(h) \leq \hat{\epsilon}(h) + O\left(\sqrt{\frac{d}{m} \log \frac{m}{d} - \frac{1}{m} \log \delta}\right)$$

回忆在有限 H 的情况下，我们有：

$$|\hat{\epsilon}(h) - \epsilon(h)| \leq \sqrt{\frac{1}{m} \log 2k - \frac{1}{m} \log \delta}$$

模型收敛速度



如何控制模型泛化能力

风险期望 = 经验风险 + 置信区间

- 仅仅最小化经验风险并不总是能给出好的泛化能力：人们希望最小化经验风险和置信区间的和。
- 重要的不是 Vapnik 极限的数值大小，通常这个数值太大而没有实际用途，重要的是这个极限是模型族函数“丰富度”的非减函数。

经验风险最小化


- 以概率 $1 - \delta$, 以下不等式成立:

$$\int (y - f(x, w^0))^2 dP(x, y) < \frac{1}{m} \sum_{i=1}^m (y_i - f(x_i, w^0))^2 + \sqrt{\frac{d(\ln(2m/d) + 1) - \ln \delta}{m}}$$

- 其中 w^0 是最小化经验风险的参数 w 值:

$$E(W) = \frac{1}{m} \sum_{i=1}^m (y_i - f(x_i, w))^2$$

通过最小化 d 来最小化界限




- 给定一些学习机器，其经验风险为零，人们希望选择那些其相关函数集具有最小 VC 维度的学习机器。
- 通过这样做，我们可以获得实际风险的上界。这并不妨碍具有相同经验风险

结构风险最小化

- 我们应该选择哪个假设空间？
- 偏差/方差权衡
- SRM: 选择 H 来最小化真实误差的界限！

$$\epsilon(h) \leq \hat{\epsilon}(h) + O\left(\sqrt{\frac{d}{m} \log \frac{m}{d}} - \frac{1}{m} \log \delta\right)$$



- 1 计算学习理论介绍
- 2 VC 维和模型复杂度
 - VC 维
 - 样本复杂度
 - 统计学习问题
 - SRM 策略
- 3 总结

- 以概率 $1 - \delta$,

$$\epsilon(h) \leq \hat{\epsilon}(h) + O\left(\sqrt{\frac{d}{m} \log \frac{m}{d} - \frac{1}{m} \log \delta}\right)$$

- 当 m/d 较小 (d 太大) 时, 方程的第二项变得较大
- SRM 策略的基本思想是同时最小化上述主化方程右侧的两项
- 为此, 必须使 d 成为一个受控参数

- 考虑一个模型族函数序列 $H_1 < H_2 < \dots < H_n$, 其对应的 VC 维度分别为 $d_1 < d_2 < \dots < d_n$
- 对于序列中的每个族 H_i , 不等式


$$\epsilon(h) \leq \hat{\epsilon}(h) + O\left(\sqrt{\frac{d}{m} \log \frac{m}{d} - \frac{1}{m} \log \delta}\right)$$

是有效的

- 也就是说, 对于每个子集, 我们必须能够计算 d , 或者对 d 本身进行界定
- SRM 包括找到最小化实际风险界限的函数子集

SRM 策略

SRM: 找到 i 使得期望风险 $\epsilon(h)$ 在特定 $d^* = d_i$ 时达到最小, 相对于序列中的特定族 H_i ; 使用 h 从 H_i 构建模型



将 SRM 应用于线性模型

- 有许多基于 SRM 的策略来构建模型：
- 在线性模型的情况下

$$y = \langle w|x \rangle + b,$$

我们希望使 $\|w\|$ 成为一个受控参数：让我们称 H_C 为满足约束条件的线性模型函数族：

$$\|w\| < C$$

Vapnik 主要定理：

当 C 减小时， $d(H_C)$ 减小

$$\|x\| < R$$

将 SRM 应用于线性模型

- 为了控制 $\|w\|$ ，可以设想两种建模方法：
- 正则化/岭回归，即对 w 和 b 进行最小化

$$RG(w, b) = S((y_i - \langle w|x_i \rangle - b)^2 | i = 1, \dots, L) + \lambda \|w\|^2$$

- 支持向量机 (SVM)，即直接解决一个优化问题（分类 SVM，可分数据）


最小化 $\|w\|^2$,

满足 $(y_i = +1 / -1)$

和 $y_i(\langle w|x_i \rangle + b) \geq 1$ 对所有 $i = 1, \dots, L$

SVM 的 VC 维

- 支持向量机 (SVM) 在希尔伯特空间中找到一个线性分割器，其中原始数据 x 可以通过变换 $\phi(x)$ 映射到该空间
- 回顾 SVM 使用的核技巧，它减轻了找到 $\phi(\cdot)$ 的显式表达式以计算变换的需要。



- 回顾 SVM 优化问题

$$\begin{aligned} \max_{\alpha} \quad & g(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j (x_i^T x_j) \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C, \quad i = 1, \dots, k \\ & \sum_{i=1}^m \alpha_i y_i = 0. \end{aligned}$$

- 数据点仅作为内积出现
- 只要我们可以在特征空间中计算内积，我们就不需要显式地映射
- 通过定义核函数 K 来实现

Mercer 条件

- 对于哪些核存在一对 $[H; \phi(\cdot)]$ 具有有效的几何属性（例如，对于满足的变换的非负点积），哪些不满足？
- Mercer 核的条件
存在一个映射 $\phi(\cdot)$ 和一个展开

$$K(x, y) = \sum_i \phi_i(x) \phi_i(y)$$

如果对于任何 $g(x)$ 使得

$$\int g(x)^2 dx \text{ 是有限的}$$

那么


$$\int K(x, y) g(x) g(y) dx dy \geq 0$$

SVM 的 VC 维

- 我们将满足 Mercer 条件的任何核称为正核，相应的空间 H 称为嵌入空间
- 我们还将任何具有给定核的最小维度的嵌入空间称为“最小嵌入空间”
- 定理：设 K 是一个正核，它对应于最小嵌入空间 H 。那么，相应支持向量机的 VC 维度（其中误差惩罚 C 被允许取所有值）是 $\dim(H) + 1$

VC 与实际风险

令人惊讶的是，两条曲线在同一个地方具有最小值：因此，在这种情况下，VC 边界虽然松散，但似乎仍然是预测性的



1 计算学习理论介绍

- 耗尽版本空间
- PAC 可学习性
- 不可知学习

2 VC 维和模型复杂度

- VC 维
- 样本复杂度
- 统计学习问题
- SRM 策略

3 总结

总结

- 样本复杂度随学习环境而变化
 - 学习器主动查询训练者
 - 随机提供示例
- 在 PAC 学习环境中，我们可以限制学习器输出具有给定误差的假设的概率
 - 对于任何一致的学习器（其中 c 在 H 中）
 - 对于任何“最佳拟合”假设（不可知学习，其中可能 c 不在 H 中）
- VC 维度作为 H 复杂度的度量
- 描述选择 H 时偏差/方差权衡的定量界限
 - 但这些界限相当宽松...
- 学习中的错误界限
- 学习理论会议: <http://www.learningtheory.org>

Feedback welcome!

The End