

(1) 贝叶斯决策规则的数学原理

贝叶斯决策规则的数学原理：

基于后验概率最大化或风险最小化：

- 后验概率： $P(\omega_i | \mathbf{x}) = \frac{P(\mathbf{x}|\omega_i)P(\omega_i)}{P(\mathbf{x})}$
- 贝叶斯决策规则： $\omega^* = \arg \max_{\omega_i} P(\omega_i | \mathbf{x})$

最优分类的三种方法：

1. 最小错误率贝叶斯决策

$$\omega^* = \arg \max_{\omega_i} P(\omega_i | \mathbf{x}) = \arg \max_{\omega_i} P(\mathbf{x} | \omega_i)P(\omega_i)$$

2. 最小风险贝叶斯决策

$$\omega^* = \arg \min_{\omega_i} R(\omega_i | \mathbf{x}) = \arg \min_{\omega_i} \sum_{j=1}^c \lambda(\alpha_i | \omega_j)P(\omega_j | \mathbf{x})$$

其中 $\lambda(\alpha_i | \omega_j)$ 是将 ω_j 误判为 ω_i 的损失

3. 极小极大决策

在最不利的先验概率分布下，使得最大可能风险最小化


(2) 降低贝叶斯错误和风险的方法

贝叶斯错误率： $P(e) = \int P(e | \mathbf{x})p(\mathbf{x})d\mathbf{x}$

降低方法：

- 改进特征提取：选择更具判别性的特征
- 增加训练数据：更准确地估计类条件概率密度
- 优化分类器设计：采用更复杂的模型结构

图形描述：



(3) 损失函数对称性问题

损失函数不应该总是对称的

实际生活举例：

1. 医疗诊断

- 将患病判为健康：可能延误治疗，损失很大
- 将健康判为患病：可能只需进一步检查，损失较小
- 损失矩阵： $\lambda = \begin{bmatrix} 0 & 10 \\ 1 & 0 \end{bmatrix}$

2. 金融欺诈检测

- 将欺诈判为正常：直接经济损失
- 将正常判为欺诈：仅需人工复核

3. 自动驾驶

- 将行人判为背景：致命错误
- 将背景判为行人：仅需减速确认

(4) K 近邻算法中 K 的选择

K 值选择方法：

- 交叉验证：通过验证集选择最优 K
- 经验公式： $K = \sqrt{N}$ ，其中 N 为训练样本数
- 奇数选择：避免平票情况

K 近邻与贝叶斯算法的数学联系：

当样本服从高斯分布且 $K \rightarrow \infty$ 时：

$$P(\omega_i | \mathbf{x}) \approx \frac{K_i}{K}$$

其中 K_i 是邻域中属于类别 ω_i 的样本数

在贝叶斯框架下：

$$P(\omega_i | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_i)P(\omega_i)}{\sum_j p(\mathbf{x} | \omega_j)P(\omega_j)}$$

K 近邻通过局部样本频率来估计这些概率。

(5) 决策树 vs 朴素贝叶斯比较

特性	决策树	朴素贝叶斯
优点	1. 可解释性强 2. 无需特征标准化 3. 能处理混合类型特征	1. 训练速度快 2. 小样本表现好 3. 对缺失数据鲁棒
缺点	1. 容易过拟合 2. 对数据变化敏感 3. 可能产生偏斜树	1. 特征独立性假设过强 2. 对输入数据分布敏感 3. 概率估计可能不准确
适用范围	特征交互复杂、需要可解释性的场景	文本分类、高维数据、实时分类
计算复杂度	训练： $O(mn \log n)$ 预测： $O(\text{树深度})$	训练： $O(mn)$ 预测： $O(m)$

其中： m 为特征数， n 为样本数