

(1) 初等函数与激活函数

初等函数包括幂函数、指数函数、对数函数、三角函数、反三角函数，以及由它们经过有限次四则运算和复合运算得到的函数。

- 线性函数： $y = kx + b$ (k, b 为常数, 且 $k \neq 0$)
- 非线性函数：除线性函数外的所有初等函数均为非线性，基本初等函数及其复合函数
 - 幂函数： $y = x^k$ ($k \neq 1$ 时非线性)
 - 指数函数： $y = a^x$ ($a > 0, a \neq 1$)
 - 对数函数： $y = \log_a x$ ($a > 0, a \neq 1$)
 - 三角函数： $y = \sin x, \cos x, \tan x, \csc x, \sec x, \cot x$
 - 反三角函数： $y = \arcsin x, \arccos x, \arctan x, \operatorname{arccot} x$

线性函数 $y = kx + b$ 可通过复合、分段、变换形式等方式改造为非线性函数，例如：

- 分段：如 ReLU 函数
- 复合：如 sigmoid 函数, tanh 函数
- 绝对值：如 $|kx + b|$

适合作为神经网络激活函数的初等函数（从连续性、可微性分析）

神经网络激活函数需要具备非线性（否则多层网络退化为线性）、连续性（保证梯度稳定传递）、可微性（支持反向传播的梯度计算）。常见适配的初等函数及分析如下：

激活函数类型	初等函数	连续性	可微性	适配性分析
Sigmoid	$y = \frac{1}{1 + e^{-x}}$	全体	全体可微	非线性、连续可微, 曾用于二分类输出

激活函数类型	初等函数	连续性	可微性	适配性分析
		连续		层；但易出现梯度消失。
Tanh	$y = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ (双曲正切)	全体连续	全体可微	非线性、连续可微，输出范围(-1,1)，梯度消失问题比 Sigmoid 稍轻。
ReLU	$y = \max(0, x)$ (分段线性)	全体连续	除 x=0 外可微	非线性、计算高效，缓解梯度消失；x=0 处不可微但实际训练中影响较小。
对数函数衍生	$y = \ln(1 + e^x)$	全体连续	全体可微	非线性、连续可微，是 ReLU 的平滑版本。


综上，非线性初等函数因具备天然的非线性特性，且多数满足连续、可微的要求，成为神经网络激活函数的主要选择；而线性函数需经改造后才能用于激活函数场景。

(2) 初等函数与激活函数

激活函数及其图像


1.Sigmoid 函数

$$y = \frac{1}{1 + e^{-x}}$$




2.Tanh 函数

$$y = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$




3.ReLU 函数

$$y = \max(0, x)$$



4. Leaky ReLU 函数

$$y = \begin{cases} x, & x \geq 0 \\ \alpha x, & x < 0 \end{cases}$$




5. ELU 函数

$$y = \begin{cases} x, & x \geq 0 \\ \alpha(e^x - 1), & x < 0 \end{cases}$$

6. GELU 函数

$$y \approx 0.5x(1 + \tanh(\sqrt{\frac{2}{\pi}}(x + 0.044715x^3)))$$



(3) 卷积运算表达式

对于输入体积 $[W1, H1, D1]$ (宽度 $W1$ 、高度 $H1$ 、深度 $D1$ ，即输入通道数)，使用 K 个卷积核 (大小 $F \times F$ ，步长 S ，填充为 P)，卷积运算的表达式为：

$$Y(i, j, c) = \sum_{m=0}^{F-1} \sum_{n=0}^{F-1} \sum_{k=0}^{D1-1} X(i+m-P, j+n-P, k) \cdot K(m, n, k, c) + b(c)$$

其中 Y 是输出值， X 是输入值， K 是卷积核的权重。 i, j, c 分别是宽度、高度和深度的坐标， $b(c)$ 是第 c 个通道的偏置项。每个输出通道有 1 个偏置，全连接层中每个神经元有一个偏置。

在本题中， $W1=64$ ， $H1=64$ ， $D1=16$ ， $K=32$ ， $F=5$ ， $S=2$ ， $P=1$ 。

输入输出尺寸的关系：

$$W2 = \left\lfloor \frac{W1 + 2P - F}{S} \right\rfloor + 1$$

$$H2 = \left\lfloor \frac{H1 + 2P - F}{S} \right\rfloor + 1$$

$$D2 = K$$

代入题目中的条件：

$$W2 = \left\lfloor \frac{64 + 2 \times 1 - 5}{2} \right\rfloor + 1 = 31$$

$$H2 = \left\lfloor \frac{64 + 2 \times 1 - 5}{2} \right\rfloor + 1 = 31$$

$$D2 = 32$$


共享权重的情况：

$$F \times F \times K = 5 \times 5 \times 32 = 800$$


不共享权重的情况：

$$W1 \times H1 \times K = 64 \times 64 \times 32 = 131072$$

(4) LeNet 网络结构



上图是 LeNet-5 的经典结构，它一共有七层（不包含输入层），分别是两个卷积层，两个池化层，3 个全连接层（其中最后一个全连接层为输出层）。



只有全连接层和卷积层需要进行参数的训练，池化层和输入层是不需要训练参数的。

第一层卷积： $6 \times 5 \times 5 \times 6$ (6 个 5×5 矩阵) + 6(每个通道还有一个偏置项)

第二层卷积： $16 \times 5 \times 5 \times 6$ (16 个 $5 \times 5 \times 6$ 的卷积核) + 16(每个卷积核还有一个偏置项)

第三层卷积 (第一全连接层)： $120 \times 5 \times 5 \times 16$ (120 个 $5 \times 5 \times 16$ 的卷积核) + 120(每个卷积核还有一个偏置项)

第二全连接层： $120 \times 84 + 84$

第三全连接层(输出层)： $84 \times 10 + 10$

从这个分析我们可以看出，其实大部分的训练参数还是集中在全连接层上。

(5) DeepSeek V3 技术报告

1. 激活函数

DeepSeek V3 在关键模块中采用 SwiGLU 激活函数，这是一种基于 Swish 的改进型激活函数，在保持非线性表达能力的同时，提升了计算效率，适用于大模型的前馈网络（FFN）部分。

2. 最大层数

模型的最大层数为 61 层，通过多层 Transformer 结构堆叠，实现对复杂语义的深度建模。

3. 最大宽度（隐藏层维度）

最大宽度（隐藏层维度）为 7168，这一维度决定了模型对信息的表达能力，是衡量模型容量的关键指标之一。

4. 最大 Attention head 数量

最大 Attention head 数量为 128 个，每个头的维度为 128，通过多头注意力机制实现对不同语义信息的并行捕捉。

5. 注意力机制

采用多头潜在注意力（Multi-Head Latent Attention, MLA）。其核心是通过低秩联合压缩注意力的键（Key）和值（Value），减少推理期间的键值（KV）缓存占用，提升推理效率。具体来说，先将 Token 特征压缩到潜在空间，计算注意力时再还原扩展，同时对旋转位置编码（RoPE）等关键信息单独处理，保证时序和位置信息的保留。

6. 损失函数

采用多 token 预测（Multi-Token Prediction, MTP）损失与 **序列级别辅助损失（Sequence-Wise Auxiliary Loss）** 相结合的方式。

MTP 损失：通过额外预测多个 token 引入新的损失项，提升模型准确度，公式为对多个预测深度的交叉熵损失加权平均。

序列级别辅助损失：用于防止单序列内专家使用的极端不均衡，鼓励每个序列上的专家加载更均衡，公式中包含超参数 α 和序列 token 数量 T 的相关计算。