

第四章 回归算法

(1) 多元线性回归模型

数学定义：

设输入特征向量为 $\mathbf{x} = [x_1, x_2, \dots, x_d]^T$ ，输出为 y ，多元线性回归模型为：

$$y = \mathbf{w}^T \mathbf{x} + b + \epsilon$$

其中：

- $\mathbf{w} = [w_1, w_2, \dots, w_d]$ 是权重向量

- b 是偏置项

- $\epsilon \sim \mathcal{N}(0, \sigma^2)$ 是高斯噪声

目标函数（残差平方和）：

$$J(\mathbf{w}, b) = \frac{1}{2} \sum_{i=1}^n (y_i - \mathbf{w}^T \mathbf{x}_i - b)^2$$

(2) 最大似然估计求解步骤

步骤 1：构建似然函数

假设噪声独立同分布，似然函数为：

$$L(\mathbf{w}, b, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \mathbf{w}^T \mathbf{x}_i - b)^2}{2\sigma^2}\right)$$

步骤 2：对数似然函数

$$\ell(\mathbf{w}, b, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{w}^T \mathbf{x}_i - b)^2$$

步骤 3：求解回归系数

最大化 $\ell(\mathbf{w}, b, \sigma^2)$ 等价于最小化残差平方和 $J(\mathbf{w}, b)$ ，可以通过对 $\mathbf{w}$ 求偏导得到：

$$\hat{\mathbf{w}} = (X^T X)^{-1} X^T y$$

其中 $\mathbf{w}$ 包含常数项， $\mathbf{x}$ 是设计矩阵。

步骤 4：求解噪声方差

同样地，对 σ^2 求偏导可以得到：

$$\widehat{\sigma^2} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\mathbf{w}}^T \mathbf{x}_i)^2$$

(3) 常见非线性基函数及其特点

1. 多项式基函数：

$$\phi_j(x) = x^i$$

特点：简单易用，可以逼近任意连续函数，但容易过拟合

2. 高斯基函数：

$$\phi_j(x) = \exp\left(-\frac{(x_i - \mu_i)^2}{2\sigma^2}\right)$$

特点：局部响应特性，适用于局部模式识别

3. Sigmoid 基函数：

$$\phi_j(x) = \frac{1}{1 + \exp(-(w_j x + b_j))}$$

特点：S 型曲线，输出范围(0,1)，适用于神经网络

(4) 最大似然估计与最小二乘估计的区别

最小二乘估计：

- 目标：最小化残差平方和 $\sum_{i=1}^n (y_i - \hat{y}_i)^2$

- 不依赖概率分布假设

- 纯几何角度优化

最大似然估计：

- 目标：最大化似然函数 $L(\theta|X)$

- 需要假设误差分布（如高斯分布）

- 概率论角度优化

数学关系：

当误差服从高斯分布时，最大似然估计等价于最小二乘估计：

$$\arg \max_{\theta} L(\theta|X) = \arg \min_{\theta} \sum (y_i - \hat{y}_i)^2$$

(5) 腾讯游戏收入预测模型及复杂度分析

模型建立：

设收入 y 与各因素的关系为：

设 x_1 为年龄， x_2 为学历， x_3 为性别， x_4 为熬夜时间， x_5 是外卖次数， x_6 是手机使用时间。

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5 + \beta_6 x_6 + \epsilon$$

数据预处理：

- 学历：one-hot 编码（初中=0, 高中=1, 本科=2, 硕士=3, 博士=4）

- 性别：虚拟变量（男=1, 女=0）

- 连续变量：标准化处理

计算复杂度分析：

1. 模型训练复杂度：

- 使用正规方程法： $O(nd^2 + d^3)$
- 其中 n 是样本数， d 是特征数（包括偏置项）
- 矩阵乘法： $O(nd^2)$
- 矩阵求逆： $O(d^3)$

2. 预测复杂度：

- 单样本预测： $O(d)$ ，即常数时间
- 批量预测 m 个样本： $O(md)$

3. 存储复杂度：

- 存储模型参数： $O(d)$
- 存储设计矩阵（如需要）： $O(nd)$

优化建议：

- 对于大规模数据，使用梯度下降法：每次迭代 $O(nd)$
- 使用随机梯度下降：每次迭代 $O(d)$
- 特征选择降低 d ，提高模型泛化能力