

统计机器学习基础

Foundations of Statistical Machine Learning

——概率论概述

Kai Chen

kaichen6@csu.edu.cn

24th September 2025



1 概率基本理论

- 概率定义
- 概率分布函数
- 条件概率
- 联合概率
- 统计理论
- 统计模型

2 贝叶斯学习

3 密度估计:MAP,MLE

4 信息学理论

1 概率基本理论

- 概率定义
- 概率分布函数
- 条件概率
- 联合概率
- 统计理论
- 统计模型

2 贝叶斯学习

3 密度估计:MAP,MLE

4 信息学理论

一个概率空间由三大要素组成：样本空间、事件集以及概率分布。

- **样本空间** Ω ：一次试验所有可能的基本事件（或结果）的集合。
例如掷一枚公平骰子， $\Omega = \{1, 2, 3, 4, 5, 6\}$ 。

- **事件集** $\mathcal{F}$ ： Ω 上的一个 σ -代数，即满足以下条件的子集族

- ① $\Omega \in \mathcal{F}$;
- ② 若 $A \in \mathcal{F}$ ，则其补集 $A^c \in \mathcal{F}$;
- ③ 若 $\{A_i\}_{i=1}^{\infty} \subseteq \mathcal{F}$ ，则 $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$ 。

例如事件“骰子点数为奇数”可表示为 $A = \{1, 3, 5\}$ 。

概率分布

- 概率公理（科尔莫戈洛夫公理）：

$$1 \quad 0 \leq P(A) \leq 1$$

$$2 \quad P(\text{True}) = 1, P(\text{False}) = 0$$

$$3 \quad P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- 概率分布

P : 从 $\mathcal{F}$ 到 $[0, 1]$ 的映射, 满足

- ① $P[\Omega] = 1$;

- ② 对于可列个两两互斥的事件 $A_1, A_2, \dots$ 有

$$P\left[\bigcup_{i=1}^{\infty} A_i\right] = \sum_{i=1}^{\infty} P[A_i].$$

如：对公平骰子， $P[A_i] = \frac{1}{6}$ ，其中 A_i 表示骰子点数为 i 的事件， $i = \{1, 2, 3, 4, 5, 6\}$ 。

定义 (随机变量)

设 $(\Omega, \mathcal{F}, P)$ 为一概率空间。一个随机变量 X 是一个可测函数

$$X: \Omega \rightarrow \mathbb{R},$$

即对任意区间 $I \subseteq \mathbb{R}$, 集合

$$\{\omega \in \Omega : X(\omega) \in I\} \in \mathcal{F}.$$

如:

- "随机变量 $A =$ 今年股市会上涨"—— $\Omega = \{\text{是}, \text{否}\}$, 二元
- "随机变量 $A =$ 2019 年斯蒂尔斯队的胜利场次"—— $\Omega = \{0, 1, 2, \dots\}$, 离散
- "随机变量 $A =$ 2019 年谷歌股票的百分比变化"—— $\Omega = \mathcal{R}$, 连续

1 概率基本理论

- 概率定义
- 概率分布函数
- 条件概率
- 联合概率
- 统计理论
- 统计模型

2 贝叶斯学习

3 密度估计:MAP,MLE

4 信息学理论

- 离散情形：概率质量函数 (pmf)

$$P_X(x) = P[X = x].$$

若 (X, Y) 为离散随机向量，则联合 pmf 为


$$P_{X,Y}(x, y) = P[X = x \wedge Y = y].$$

- 连续情形：概率密度函数 (pdf) $f_X(x)$ 满足

$$P[a \leq X \leq b] = \int_a^b f_X(x) dx, \quad \forall a, b \in \mathbb{R}.$$


概率密度函数

- 离散分布



$$\sum_i P(X = x_i) = 1$$

- 连续分布



$$P(X \leq a) = \int_{-\infty}^a f(\tau) d\tau$$

累积分布函数

- 总概率:

$$P(\Omega) = \int_{-\infty}^{\infty} f(x) dx = 1$$

- 概率密度函数 (PDF):

$$\frac{d}{dx}F(x) = f(x)$$

- 性质:

$$P(a \leq x \leq b) = \int_b^a f(x) dx = F(b) - F(a)$$

极限性质:

$$\lim_{x \rightarrow -\infty} F(x) = 0$$

$$\lim_{x \rightarrow \infty} F(x) = 1$$

单调性:

$$F(a) \geq F(b) \forall a \geq b$$

常用分布

定义 (二项分布)

若随机变量 X 服从参数为 $n \in \mathbb{N}$ 和 $p \in [0, 1]$ 的二项分布, 记作 $X \sim \mathcal{B}(n, p)$, 则

$$P[X = k] = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n.$$

定义 (正态 (高斯) 分布)

若随机变量 X 服从参数为 $\mu \in \mathbb{R}$ 和 $\sigma > 0$ 的正态 (高斯) 分布, 记作 $X \sim \mathcal{N}(\mu, \sigma^2)$, 则其概率密度函数为

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

当 $\mu = 0, \sigma = 1$ 时称为标准正态分布。

定义 (拉普拉斯分布)

若随机变量 X 服从位置参数为 $\mu \in \mathbb{R}$ 、尺度参数为 $b > 0$ 的拉普拉斯分布, 记作 $X \sim \text{Laplace}(\mu, b)$, 则其概率密度函数为

$$f_X(x) = \frac{1}{2b} \exp\left(-\frac{|x - \mu|}{b}\right).$$

定义 (泊松分布)

若随机变量 X 服从参数为 $\lambda > 0$ 的泊松分布, 记作 $X \sim \text{Poisson}(\lambda)$, 则

$$P[X = k] = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k \in \mathbb{N}.$$

常用分布

定义 (指数分布)

若随机变量 X 服从参数为 $\lambda > 0$ 的指数分布, 记作 $X \sim \text{Exp}(\lambda)$, 则其概率密度函数为

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0.$$

定义 (伽马分布)

若随机变量 X 服从形状参数为 $k > 0$ 、尺度参数为 $\theta > 0$ 的伽马分布, 记作 $X \sim \text{Gamma}(k, \theta)$, 则其概率密度函数为

$$f(x) = \frac{1}{\Gamma(k)\theta^k} x^{k-1} e^{-x/\theta}, \quad x > 0,$$

其中 $\Gamma(k)$ 为伽马函数。

常用分布

定义 (贝塔分布)

随机变量 X 服从形状参数为 $\alpha > 0, \beta > 0$ 的贝塔分布, 记作 $X \sim \text{Beta}(\alpha, \beta)$,

$$f(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1,$$

其中 $B(\alpha, \beta) = \Gamma(\alpha)\Gamma(\beta)/\Gamma(\alpha + \beta)$ 为贝塔函数。

定义 (χ^2 分布)

具有 k 个自由度的 χ^2 分布是 k 个遵循标准正态分布 $Z_1, \dots, Z_k \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$ 的随机变量平方和

$$Q = \sum_{i=1}^k Z_i^2 \sim \chi^2(k),$$

1 概率基本理论

- 概率定义
- 概率分布函数
- 条件概率
- 联合概率
- 统计理论
- 统计模型

2 贝叶斯学习

3 密度估计:MAP,MLE

4 信息学理论

条件概率


定义 (条件概率)

事件 B 已发生的前提下，事件 A 的条件概率定义为


$$P[A \mid B] = \frac{P[A \cap B]}{P[B]},$$

其中要求 $P[B] \neq 0$ 。

$P(A = 0.2)$



$P(A|B = 0.5)$



条件概率

先验概率：在缺乏任何其他信息的情况下，对某事件的信念程度
在某些情况下，了解一个或多个随机变量可以改善我们对另一个随机变量的先前信念。

$$P(\text{slept in movie}) = 0.5$$

$$P(\text{slept in movie} \mid \text{liked movie}) = \frac{1}{4}$$

$$P(\text{didn't sleep in movie} \mid \text{liked movie}) = \frac{3}{4}$$

Slept	Liked
1	0
0	1
1	1
1	0
0	0
1	0
0	1
0	1

条件概率

定义 (独立性)

两个事件 A 、 B 称为相互独立，若

$$P[A \cap B] = P[A] P[B].$$

等价地，当 $P[B] \neq 0$ 时， A 、 B 独立当且仅当 $P[A | B] = P[A]$ 。

若一系列随机变量既相互独立又服从同一分布，则称其独立同分布 (i.i.d.)。

定义 (联合概率)

对于同一概率空间中的任意两个事件 A 与 B ，其联合概率定义为 $P[A \cap B]$ ，或 $P[A, B]$ ，即事件 A 与事件 B 同时发生的概率。

- 如果我们假设事件 A 与事件 B 独立，那么 $P(A, B) = P(A)P(B)$ 。

1 概率基本理论

- 概率定义
- 概率分布函数
- 条件概率
- **联合概率**
- 统计理论
- 统计模型

2 贝叶斯学习

3 密度估计:MAP,MLE

4 信息学理论

$$P(\text{class size} > 20) = 0.6$$

$$P(\text{summer}) = 0.4$$

$$P(\text{class size} > 20, \text{summer}) = 0.1$$

Size	Time	Eval
30	R	2
70	R	1
12	S	2
8	S	3
56	R	1
24	S	2
10	S	3
23	R	3
9	R	2
45	R	1

基本概率公式

对任意事件 A, B 及 $A_1, \dots, A_n$; 其中贝叶斯公式需额外满足 $P[B] \neq 0$:

$$P[A \cup B] = P[A] + P[B] - P[A \cap B] \quad (\text{加法公式}) \quad (1)$$

$$P\left[\bigcup_{i=1}^n A_i\right] \leq \sum_{i=1}^n P[A_i] \quad (\text{并集界/布尔不等式}) \quad (2)$$

$$P[A | B] = \frac{P[B | A] P[A]}{P[B]} \quad (\text{贝叶斯公式}) \quad (3)$$

$$P\left[\bigcap_{i=1}^n A_i\right] = P[A_1] P[A_2 | A_1] \cdots P\left[A_n \mid \bigcap_{i=1}^{n-1} A_i\right] \quad (\text{链式法则}) \quad (4)$$

- 加法公式源于 $A \cup B$ 可被分解为互不相交的 A 与 $(B \setminus A \cap B)$ 之并;
- 并集界是加法公式的直接推论
- 贝叶斯公式可由条件概率定义立即得到, 因为

$$P[A | B] P[B] = P[B | A] P[A] = P[A \cap B].$$

- 链式法则的推导类似: $P[A_1] P[A_2 | A_1] = P[A_1 \cap A_2]$, 依此类推即可递归证明前 k 项乘积等于 $P[\bigcap_{i=1}^k A_i]$

若样本空间可划分为互不相交的完备事件组 $\Omega = A_1 \cup A_2 \cup \cdots \cup A_n$ 且 $A_i \cap A_j = \emptyset$ ($i \neq j$), 则对任一事件 B 有

$$P[B] = \sum_{i=1}^n P[B | A_i] P[A_i] \quad (\text{全概率公式})$$

贝叶斯规则

因为, $P(A, B) = P(A|B)P(B) = P(B|A)P(A)$, 可得

$$\begin{aligned} P(A|B) &= \frac{P(B|A)P(A)}{P(B)} \\ &= \frac{P(B|A)P(A)}{\sum_A P(B|A)P(A)} \end{aligned}$$



Thomas Bayes was an English clergyman who set out his theory of probability in 1764.

连续分布的贝叶斯定理


- 标准形式：

$$f(x|y) = \frac{f(y|x)f(x)}{f(y)}$$


- 替代形式：

$$f(x|y) = \frac{f(y|x)f(x)}{\int f(y|x)f(x)dx}$$

$P(B, A=1)$



$P(B, A=0)$



基于贝叶斯定理的 AIDS 检测

- AIDS 是 HIV 感染的晚期阶段，免疫系统严重受损。
- 事件 a : 是否患有 AIDS，若 $a=1$ 表示患病。
- 事件 t : 检测是否呈阳性，若 $t=1$ ，阳性。
- 大约 0.1% 的人被感染
- 测试检测到所有感染—— $P(t = 1|a = 1) = 1$
- 测试报告中 1% 健康人呈阳性。—— $P(t = 1|a = 0) = 0.1$

如果测试结果为阳性，则患有 AIDS 的概率为多少？

基于贝叶斯定理的 AIDS 检测

$$\begin{aligned}P(a = 1 \mid t = 1) &= \frac{P(t = 1 \mid a = 1)P(a = 1)}{P(t = 1)} \\&= \frac{P(t = 1 \mid a = 1)P(a = 1)}{P(t = 1 \mid a = 1)P(a = 1) + P(t = 1 \mid a = 0)P(a = 0)} \\&= \frac{1 \cdot 0.001}{1 \cdot 0.001 + 0.01 \cdot 0.999} = 0.091\end{aligned}$$

仅有 9%!

1 概率基本理论

- 概率定义
- 概率分布函数
- 条件概率
- 联合概率
- **统计理论**
- 统计模型

2 贝叶斯学习

3 密度估计:MAP,MLE

4 信息学理论

定义 (期望)

随机变量 X 的期望 (或均值) 记作 $\mathbb{E}[X]$, 定义为

$$\mathbb{E}[X] = \sum_x x P[X = x].$$

当 X 服从某分布 D 时, 也可显式写作 $\mathbb{E}_{x \sim D}[x]$ 。

- 线性性: 对任意随机变量 X, Y 及 $a, b \in \mathbb{R}$,

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y].$$

- 若 X 与 Y 独立, 则

$$\mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y].$$

统计量：方差

定义 (方差)

随机变量 X 的方差记为 $\text{Var}[X]$, 定义为

$$\text{Var}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2].$$

随机变量 X 的标准差记为 σ_X , 定义为 $\sigma_X = \sqrt{\text{Var}[X]}$.

对任意随机变量 X 及任意 $a \in \mathbb{R}$, 方差满足以下基本性质:

•

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2, \quad (5)$$

$$\text{Var}[aX] = a^2 \text{Var}[X]. \quad (6)$$


• 若 X 与 Y 独立, 则

$$\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y].$$

独立变量期望和方差的证明

$$\begin{aligned}\mathbb{E}[XY] &= \sum_x \sum_y xy P[X = x, Y = y] \\ &= \sum_x \sum_y xy P[X = x] P[Y = y] \\ &= \left(\sum_x x P[X = x] \right) \left(\sum_y y P[Y = y] \right) = \mathbb{E}[X] \mathbb{E}[Y],\end{aligned}$$

$$\begin{aligned}\text{Var}[X + Y] &= \mathbb{E}[(X + Y)^2] - (\mathbb{E}[X + Y])^2 \\ &= \mathbb{E}[X^2 + Y^2 + 2XY] - (\mathbb{E}[X]^2 + \mathbb{E}[Y]^2 + 2\mathbb{E}[XY]) \\ &= (\mathbb{E}[X^2] - \mathbb{E}[X]^2) + (\mathbb{E}[Y^2] - \mathbb{E}[Y]^2) + 2(\mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[XY]) \\ &= \text{Var}[X] + \text{Var}[Y].\end{aligned}$$



定义 (协方差)

两个随机变量 X 与 Y 的协方差记作 $\text{Cov}(X, Y)$, 定义为

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

- 对称性: 对任意随机变量 X, Y 有 $\text{Cov}(X, Y) = \text{Cov}(Y, X)$;
- 双线性: 对任意随机变量 X, X', Y 及任意 $a \in \mathbb{R}$ 有

$$\text{Cov}(X + X', Y) = \text{Cov}(X, Y) + \text{Cov}(X', Y)$$

$$\text{Cov}(aX, Y) = a \text{Cov}(X, Y)$$

- 半正定性: 对任意随机变量 X 有 $\text{Cov}(X, X) = \text{Var}[X] \geq 0$

弱大数定律

定理 (弱大数定律)

设 $(X_n)_{n \in \mathbb{N}}$ 为独立同分布的随机变量序列, 其共同均值为 μ , 方差 $\sigma^2 < \infty$. 记样本均值为

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i,$$

则对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P[|\bar{X}_n - \mu| \geq \varepsilon] = 0.$$

证明: 由于诸 X_i 相互独立, 可得

$$\text{Var}[X_n] = \sum_{i=1}^n \text{Var}\left[\frac{X_i}{n}\right] = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

于是, 由切比雪夫不等式 (取 $t = \varepsilon / \sqrt{\text{Var}[\bar{X}_n]}$) 得

$$P[|\bar{X}_n - \mu| \geq \varepsilon] \leq \frac{\sigma^2}{n\varepsilon^2},$$

令 $n \rightarrow \infty$ 即得。

中心极限定理

定理 (中心极限定理)

设 $X_1, \dots, X_n$ 为独立同分布随机变量序列, 均值为 μ , 标准差为 σ 。记

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad \sigma_n = \frac{\sigma}{\sqrt{n}}.$$

则标准化统计量

$$\frac{\bar{X}_n - \mu}{\sigma_n}$$

依分布收敛于标准正态分布 $\mathcal{N}(0, 1)$, 即对任意 $t \in \mathbb{R}$, 有

$$\lim_{n \rightarrow \infty} P\left[\frac{\bar{X}_n - \mu}{\sigma_n} \leq t\right] = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx.$$

1 概率基本理论

- 概率定义
- 概率分布函数
- 条件概率
- 联合概率
- 统计理论
- 统计模型

2 贝叶斯学习

3 密度估计:MAP,MLE

4 信息学理论

- 统计模型试图描述感兴趣的总体特性
- 例如，我们可能认为重复测量遵循某个均值为 μ 和方差为 σ^2 的正态分布（高斯分布）， $x \sim \mathcal{N}(\mu, \sigma^2)$


$$P(x|\Theta) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x-\mu)^2}{2\sigma^2}} \quad (7)$$

其中 $\Theta = (\mu, \sigma^2)$ 定义了模型的均值和方差参数

学生在睡觉上花了多少时间？



让我们尝试估算学生在课堂之外花费在睡眠上的时间分布。

- X : 睡眠时间
- $E(X)$?
- $Var(X)$?



统计模型的参数

- 统计模型是一个分布集合；参数指定各个分布
- 我们需要调整参数，以使得结果分布与数据很好地吻合。



- 1 概率基本理论
 - 概率定义
 - 概率分布函数
 - 条件概率
 - 联合概率
 - 统计理论
 - 统计模型
- 2 贝叶斯学习
- 3 密度估计:MAP,MLE
- 4 信息学理论

示例：你的咨询任务

一位来自西雅图郊区的亿万富翁问你一个问题：

—他问：我有一枚硬币，如果我翻它，它正面朝上的概率是多少？

—你说：请翻几次看看。



—你说：概率是： $3/5$ ，因为……所有翻转中出现正面的频率

—他说：但我可以把钱押在这个估计上吗？


—你说：嗯……也许不行。翻转次数不足（低于样本复杂度）

什么是先验知识？

-亿万富翁说：等一下，我知道这个硬币的结果接近 50-50。你现在能为我做些什么？

-你说：我可以用贝叶斯的方法来学习……

我们不是估计一个单一的 θ ，而是得到一个关于 θ 可能值的分布。





使用贝叶斯规则：

$$P(\theta \mid \mathcal{D}) = \frac{P(\mathcal{D} \mid \theta)P(\theta)}{P(\mathcal{D})}$$

或者等价地：

$$P(\theta \mid \mathcal{D}) \propto P(\mathcal{D} \mid \theta)P(\theta)$$

其中， $P(\theta \mid \mathcal{D})$ 是后验概率（posterior）， $P(\mathcal{D} \mid \theta)$ 是似然函数（likelihood）， $P(\theta)$ 是先验概率（prior）。

先验分布

- 我们从哪里获得先验？

- 代表专家知识（哲学方法）：临床医生、金融分析师、领域专家给出经验区间或典型值

例：新药有效率 p 的先验 $\text{Beta}(9, 1)$ 表示“九成把握认为有效率高于 50%”。

- 简单的后验形式（工程师方法）：为了得到解析可写的后验，选择与似然“代数匹配”的共轭先验。

- 无信息先验

- 均匀分布： $\theta \sim U(0, 1)$
- Jeffreys 先验： $p(\theta) \propto \sqrt{I(\theta)}$ ，在重参数化下不变
- 参考先验（Bernardo）：最大化数据信息增益，减少主观影响

- 共轭先验

- 后验的闭式表示

- $P(q)$ 和 $P(q|D)$ 作为 θ 的函数具有相同的代数形式

共轭先验

$P(q)$ 和 $P(q|D)$ 作为 θ 的函数具有相同的代数形式

Eg. 1: 硬币翻转



1. 给定伯努利模型的似然函数:

$$P(\mathcal{D} \mid \theta) = \theta^{\alpha_H} (1 - \theta)^{\alpha_T}$$


2. 如果先验是 Beta 分布:

$$P(\theta) = \frac{\theta^{\beta_H-1} (1 - \theta)^{\beta_T-1}}{B(\beta_H, \beta_T)} \sim \text{Beta}(\beta_H, \beta_T)$$

3. 那么后验也是 Beta 分布:

$$P(\theta \mid \mathcal{D}) \sim \text{Beta}(\beta_H + \alpha_H, \beta_T + \alpha_T)$$


Beta 分布



Beta 共轭先验

$$P(\theta) \sim \text{Beta}(\beta_H, \beta_T)$$

$$P(\theta \mid \mathcal{D}) \sim \text{Beta}(\beta_H + \alpha_H, \beta_T + \alpha_T)$$



随着我们获得更多样本，先前的影响会被“洗掉”。

共轭先验

$P(q)$ 和 $P(q|D)$ 作为 θ 的函数具有相同的代数形式

Eg. 2

1. 似然函数（假设是多项式分布）：

$$P(\mathcal{D} \mid \theta) = \theta_1^{\alpha_1} \theta_2^{\alpha_2} \cdots \theta_k^{\alpha_k}$$

2. 如果先验是 Dirichlet 分布：

$$P(\theta) = \frac{\prod_{i=1}^k \theta_i^{\beta_i - 1}}{B(\beta_1, \dots, \beta_k)} \sim \text{Dirichlet}(\beta_1, \dots, \beta_k)$$

3. 那么后验也是 Dirichlet 分布：

$$P(\theta \mid \mathcal{D}) \sim \text{Dirichlet}(\beta_1 + \alpha_1, \dots, \beta_k + \alpha_k)$$

对多项式而言，共轭先验是狄利克雷分布。

共轭先验：经典配对

似然分布	共轭先验	后验分布
Bernoulli(p)	Beta(α, β)	Beta($\alpha + \sum x_i, \beta + n - \sum x_i$)
Binomial(N, p)	Beta(α, β)	Beta($\alpha + \sum x_i, \beta + nN - \sum x_i$)
Poisson(λ)	Gamma(α, β)	Gamma($\alpha + \sum x_i, \beta + n$)
Exponential(λ)	Gamma(α, β)	Gamma($\alpha + n, \beta + \sum x_i$)
Normal(μ, σ^2) (σ^2 已知)	Normal(μ_0, τ_0^2)	Normal(μ_n, τ_n^2)
Normal(μ, σ^2) (μ 已知)	InverseGamma(α, β)	InverseGamma($\alpha + \frac{n}{2}, \beta + \frac{1}{2} \sum (x_i - \mu)^2$)
Multinomial($K, \mathbf{p}$)	Dirichlet($\boldsymbol{\alpha}$)	Dirichlet($\boldsymbol{\alpha} + \mathbf{n}$)
Geometric(p)	Beta(α, β)	Beta($\alpha + n, \beta + \sum x_i - n$)

- 到目前为止看到的方法被称为贝叶斯方法
- 先验信息以参数可能值的分布形式编码
- 使用贝叶斯规则，你可以得到一个更新的后验分布
- 但亿万富翁并不感兴趣分布
 - 只需要具体的值：是 $3/5$ ， $1/2$ ，是什么？

我们如何从参数的分布转变为对真实参数的单一估计？

最大后验估计

1. 选择使后验概率最大化的 θ :

$$\begin{aligned}\hat{\theta}_{MAP} &= \arg \max_{\theta} P(\theta \mid \mathcal{D}) \\ &= \arg \max_{\theta} P(\mathcal{D} \mid \theta) P(\theta)\end{aligned}$$

2. 概率头的 MAP 估计:

$$P(\theta \mid \mathcal{D}) \sim \text{Beta}(\beta_H + \alpha_H, \beta_T + \alpha_T)$$

3. MAP 估计的公式:


$$\hat{\theta}_{MAP} = \frac{\alpha_H + \beta_H - 1}{\alpha_H + \beta_H + \alpha_T + \beta_T - 2}$$

- 1 概率基本理论
 - 概率定义
 - 概率分布函数
 - 条件概率
 - 联合概率
 - 统计理论
 - 统计模型
- 2 贝叶斯学习
- 3 密度估计:MAP,MLE
- 4 信息学理论

密度估计

密度估计器学习将一组属性映射到概率的关系。

- 估计随机变量的分布（或条件分布）
- 变量类型：
 - 二元：抛硬币、警报
 - 离散：骰子、汽车型号
 - 连续：身高、体重、温度。



我们何时需要估计密度？

- 密度估计器是我们将讨论的多个机器学习算法的关键组成部分
- 在某些情况下，它们与其他推断类型结合以用于更复杂的算法（例如 EM），而在其他情况下，它们是更一般过程的一部分（贝叶斯网络和隐马尔可夫模型中的学习）。

离散变量的密度估计器

$$P[x_i = u] = \frac{\text{出现 } x_i = u \text{ 的记录数}}{\text{总记录数}}$$

只需计数即可 (频率近似概率)

为什么它是正确的？

最大似然原理 (Maximum Likelihood Principle)

定义模型 M 下数据集的似然:

$$P[\mathcal{D} \mid M] = P[x^{(1)}, x^{(2)}, \dots, x^{(N)} \mid M] = \prod_{k=1}^N P[x^{(k)} \mid M],$$

其中 M 表示模型 (通常是一组参数), 例如:

- 掷硬币出现“正面”的概率;
- 掷骰子出现 1, 2, 3, 4, 5 各面的概率;

最大似然原理

$$\hat{P}(\text{数据集} \mid M) = \hat{P}(x_1 \wedge x_2 \dots \wedge x_n \mid M) = \prod_{k=1}^n \hat{P}(x_k \mid M)$$

- **目标：**选择使观测样本出现概率最大的参数 M 。
- 我们可以通过最大化生成观测样本的概率来实现这一点
- 例如，设 Θ 为硬币翻转的概率
- 然后

$$L(x_1, \dots, x_n \mid \Theta) = p(x_1 \mid \Theta) \cdots p(x_n \mid \Theta)$$

- 观测值（不同的翻转）假设为独立
- 对于这样的硬币翻转，其中 $P(H) = q$ ， Θ_h 的最佳赋值是

$$\arg \max_q \frac{X = H}{\text{总样本数}}$$

为什么？



最大似然原理

对于二元随机变量 A : $P(A = 1) = q$, $\operatorname{argmax}_q = \frac{A=1 \text{ 的样本数}}{\text{总样本}}$, 证明如下

1. 数据似然函数:

$$P(D \mid M) = q^{n_1}(1 - q)^{n_2}$$

2. 我们希望找到:

$$\operatorname{argmax}_q q^{n_1}(1 - q)^{n_2}$$

3. 求导并设为 0:

$$\frac{\partial}{\partial q} q^{n_1}(1 - q)^{n_2} = n_1 q^{n_1-1}(1 - q)^{n_2} - q^{n_1} n_2 (1 - q)^{n_2-1}$$

最大似然定理

续:

$$\frac{\partial}{\partial q} = 0 \Rightarrow n_1 q^{n_1-1} (1-q)^{n_2} - q^{n_1} n_2 (1-q)^{n_2-1} = 0 \Rightarrow$$

$$q^{n_1-1} (1-q)^{n_2-1} (n_1(1-q) - qn_2) = 0 \Rightarrow$$

$$n_1(1-q) - qn_2 = 0 \Rightarrow$$

$$n_1 = n_1 q + n_2 q \Rightarrow$$

$$q = \frac{n_1}{n_1 + n_2}$$

, 证毕。

对数似然

当处理产品时，整个数据集的概率往往变得太小。一个可能的解决方案是使用概率的对数，通常称为“对数似然”。

$$\log \hat{P}(\text{数据集} \mid M) = \log \prod_{k=1}^n \hat{P}(x_k \mid M) = \sum_{k=1}^n \log \hat{P}(x_k \mid M)$$

最大化这个似然函数与最大化 $P(\text{数据集} \mid M)$ 是相同的。

最大似然定理

- 我们可以通过最大化生成观测样本的概率来拟合统计模型：

$$L(x_1, \dots, x_n \mid \Theta) = p(x_1 \mid \Theta) \cdots p(x_n \mid \Theta) \quad (\text{假设样本是独立的})$$

- 在高斯情况下，我们简单地将均值和方差设置为样本均值和样本方差：

$$\bar{\mu} = \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{\mu})^2$$

为什么？

MLE V.S. MAP

- 最大似然估计 (MLE)
选择最大化观察数据概率的值

$$\hat{\theta}_{MLE} = \arg \max_{\theta} P(D | \theta)$$

- 最大后验估计 (MAP)
选择在给定观察数据和先验信念的情况下最可能的值

$$\hat{\theta}_{MAP} = \arg \max_{\theta} P(\theta | D) = \arg \max_{\theta} P(D | \theta) P(\theta)$$

- 1 概率基本理论
 - 概率定义
 - 概率分布函数
 - 条件概率
 - 联合概率
 - 统计理论
 - 统计模型
- 2 贝叶斯学习
- 3 密度估计:MAP,MLE
- 4 信息学理论

随机变量 X 具有分布 p ，其熵表示为 $\mathbb{H}(X)$ 或有时表示为 $\mathbb{H}(p)$ ，是其不确定性的度量。特别地，对于具有 K 个状态的离散变量，其定义为

$$\mathbb{H}(X) \triangleq - \sum_{k=1}^K p(X = k) \log_2 p(X = k)$$

通常使用以 2 为底的对数，在这种情况下，单位称为比特 (bits，二进制数字的简称)。

如果我们使用以 e 为底的对数，单位称为纳特 (nats)。

例如，如果随机变量 $X \in \{1, \dots, 5\}$ 且具有直方图分布 $p = [0.25, 0.25, 0.2, 0.15, 0.15]$ ，我们可以计算其熵 H 如下：

$$H(X) = - \sum_{k=1}^5 p(x = k) \log_2 p(x = k)$$


具体计算如下：

$$\begin{aligned} H(X) &= -[p(1) \log_2 p(1) + p(2) \log_2 p(2) + p(3) \log_2 p(3) \\ &\quad + p(4) \log_2 p(4) + p(5) \log_2 p(5)] \\ &= -[0.25 \log_2 0.25 + 0.25 \log_2 0.25 + 0.2 \log_2 0.2 \\ &\quad + 0.15 \log_2 0.15 + 0.15 \log_2 0.15] \\ &= -[0.25 \times (-2) + 0.25 \times (-2) + 0.2 \times (-2.3219) \\ &\quad + 0.15 \times (-2.7369) + 0.15 \times (-2.7369)] \\ &= 0.5 + 0.5 + 0.4644 + 0.4105 + 0.4105 \\ &= 2.2855 \end{aligned}$$

熵

对于二元随机变量的特殊情况, $X \in \{0, 1\}$, 我们可以写出 $p(X=1) = \theta$ 和 $p(X=0) = 1 - \theta$ 。因此熵变为

$$\begin{aligned} \mathbb{H}(X) &= -[p(X=1) \log_2 p(X=1) + p(X=0) \log_2 p(X=0)] \\ &= -[\theta \log_2 \theta + (1 - \theta) \log_2 (1 - \theta)] \end{aligned}$$



我们看到当分布均匀时, 即 $\theta = 0.5$, 最大值 1 出现。

- 对于 K 个随机变量, 当 $p(x=k) = 1/K$ 时, 熵达到最大值; 在这种情况下, $\mathbb{H}(X) = \log_2 K$ 。

KL 散度

一种测量两个概率分布 p 和 q 不相似度的方法是 Kullback-Leibler 散度 (KL 散度或相对熵)。它定义如下:

$$\mathbb{KL}(p||q) \triangleq \sum_{k=1}^K p_k \log \frac{p_k}{q_k}$$

其中求和可以被概率密度函数 (pdfs) 的积分替换。我们可以将其重写为

$$\mathbb{KL}(p||q) = \sum_k p_k \log p_k - \sum_k p_k \log q_k = -\mathbb{H}(p) + \mathbb{H}(p, q)$$

其中 $\mathbb{H}(p, q)$ 称为交叉熵。

$$\mathbb{H}(p, q) \triangleq - \sum_k p_k \log q_k$$

KL 散度

由于 KL 散度不是距离度量，它是不对称的。
KL 散度的对称版本是 Jensen-Shannon 散度

$$J^S(p_1, p_2) = 0.5\mathbb{KL}(p_1||q) + 0.5\mathbb{KL}(p_2||q)$$

其中 $q = 0.5p_1 + 0.5p_2$ 。

定理 2.8.1 (信息不等式) $\mathbb{KL}(p||q) \geq 0$ ，当且仅当 $p = q$ 时等号成立。

证明：为了证明这个定理，我们需要使用 Jensen 不等式。它表明，对于任何凸函数 f ，我们有

$$f\left(\sum_{i=1}^n \lambda_i x_i\right) \leq \sum_{i=1}^n \lambda_i f(x_i)$$

其中 $\lambda_i \geq 0$ 且 $\sum_{i=1}^n \lambda_i = 1$ 。这显然对于 $n = 2$ (根据凸性的定义) 是成立的，并且可以通过归纳法证明对于 $n > 2$ 也成立。

证明：遵循 (Cover and Thomas 2006, p28)。设 $A = \{x: p(x) > 0\}$ 为 $p(x)$ 的支持集。则

$$\begin{aligned} -\text{KL}(p||q) &= -\sum_{x \in A} p(x) \log \frac{p(x)}{q(x)} = \sum_{x \in A} p(x) \log \frac{q(x)}{p(x)} \\ &\leq \log \sum_{x \in A} p(x) \frac{q(x)}{p(x)} = \log \sum_{x \in A} q(x) \leq \log 1 = 0 \end{aligned}$$

其中第一个不等式遵循 Jensen 不等式。由于 $\log(x)$ 是一个严格凸函数，我们在等式中只有在 $p(x) = cq(x)$ 对于某个 c 时才相等。我们在等式中只有在 $\sum_{x \in A} q(x) = \sum_{x \in X} q(x) = 1$ 时才相等，这意味着 $c = 1$ 。因此 $\text{KL}(p||q) = 0$ 当且仅当 $p(x) = q(x)$ 对于所有 x 成立。

求证：主张在没有其他理由偏向一个分布而不是另一个分布时，使用均匀分布。
因为：设 $u(x) = 1/|\mathcal{X}|$ 。则

$$\begin{aligned} 0 \leq \text{KL}(p||u) &= \sum_x p(x) \log \frac{p(x)}{u(x)} \\ &= \sum_x p(x) \log p(x) - \sum_x p(x) \log u(x) = -\mathbb{H}(X) + \log |\mathcal{X}| \end{aligned}$$

因为： $\mathbb{H}(X) \leq \log |\mathcal{X}|$ ，其中 $|\mathcal{X}|$ 是 X 的状态数，当且仅当 $p(x)$ 是均匀分布时等号成立。所以离散分布中最大熵是均匀分布。证毕。

考虑两个随机变量 X 和 Y 。一个变量对了解另一个变量有多少帮助？

- 相关系数：

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

皮尔逊相关系数的取值范围在 $[-1, 1]$ 之间，如果两个变量之间的关系是非线性的，相关系数可能无法准确反映其关系。

- 互信息 (MI)：

确定联合分布 $p(X, Y)$ 与分解的分布 $p(X)p(Y)$ 有多相似。

$$I(X; Y) \triangleq \text{KL}(p(X, Y) || p(X)p(Y)) = \sum_x \sum_y p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

我们有 $I(X; Y) \geq 0$ ，当且仅当 $p(X, Y) = p(X)p(Y)$ 时等号成立。也就是说，当变量独立时 MI 为零。

互信息的解释

$$I(X; Y) = \mathbb{H}(X) - \mathbb{H}(X|Y) = \mathbb{H}(Y) - \mathbb{H}(Y|X)$$

其中 $\mathbb{H}(Y|X)$ 是条件熵，定义为 $\mathbb{H}(Y|X) = \sum_x p(x) \mathbb{H}(Y|X=x)$ 。
在观察 Y 后关于 X 的不确定性减少，或者通过对称性，在观察 X 后关于 Y 的不确定性减少。

- 点互信息 (PMI)

对于两个事件（非随机变量） x 和 y ，定义：

$$PMI(x, y) \triangleq \log \frac{p(x, y)}{p(x)p(y)} = \log \frac{p(x|y)}{p(x)} = \log \frac{p(y|x)}{p(y)}$$

衡量了这些事件一起发生与偶然发生之间的差异。显然， X 和 Y 的 MI 只是 PMI 的期望值。

最大信息系数


尝试许多不同的箱大小和位置，并计算实现的最大 MI，经过适当标准化后，称为最大信息系数（MIC），定义：

$$m(x, y) = \frac{\max_{G \in \mathcal{G}(x, y)} I(X(G); Y(G))}{\log \min(x, y)}$$

其中 $G(x, y)$ 是大小为 $x \times y$ 的 2D 网格集合， $X(G), Y(G)$ 表示将变量离散化到这个网格上。

$$MIC \triangleq \max_{x, y: xy \leq B} m(x, y)$$

最大信息系数



- 标记为 C 的点具有低相关系数 (CC) 和低 MIC。相应的散点图清楚地表明这两个变量 (因伤死亡的百分比和人口中牙医的密度) 之间没有关系。
- 标记为 D 和 H 的点具有高 CC (绝对值) 和高 MIC, 因为它们表示几乎线性的关系。
- 标记为 E、F 和 G 的点具有低 CC 和高 MIC。这是因为它们对应于非线性 (有时是 E 和 F 的情况) 和非功能性的变量关系。

Feedback welcome!

The End