

统计机器学习基础

Foundations of Statistical Machine Learning

——回归算法

Kai Chen

kaichen6@csu.edu.cn

24th September 2025



中南大学
CENTRAL SOUTH UNIVERSITY

数学与统计学院
SCHOOL OF MATHEMATICS AND STATISTICS

1 线性回归

- 线性回归定义
- 求解线性回归方程
- 线性回归的扩展
- 改进：局部回归
- 改进：鲁棒回归
- 改进：岭回归

2 用于分类的回归

3 逻辑回归

1 线性回归

- 线性回归定义
- 求解线性回归方程
- 线性回归的扩展
- 改进：局部回归
- 改进：鲁棒回归
- 改进：岭回归

2 用于分类的回归

3 逻辑回归

示例：选择一个餐馆

- 在日常生活中，我们需要考虑许多因素来做决定
- 问题在于我们对每个因素赋予多少权重（它们相对于目标的重要性如何）
- 假设我们想根据个人的偏好为潜在餐厅建立一个推荐系统
- 如果我们有很多观测数据，我们可能能够恢复权重

Reviews	\$	Distance	Cuisine	score
4	30	21	7	8.5
2	15	12	8	7.8
5	27	53	9	6.7
3	20	5	6	5.4



?



线性回归

- 给定输入 x , 我们希望计算输出 y
- 一元线性回归: X 是一维变量 (一个输入)

- 从 Yahoo 的价格预测 Google 的价格

$$Y = wx + \varepsilon$$



- 多元线性回归: X 是多维变量 (多个输入)

- 用 Yahoo、Microsoft 和 Ebay 的股票价格预测 Google 股票价格任务

$$y = w_0 + w_1X_1 + \cdots + w_kX_k + \varepsilon$$

$$Y = \mathbf{w}^T \mathbf{x} + \varepsilon$$

注意现在 Y 可以是连续的





线性回归

给定输入 x ，我们希望计算输出 y
在线性回归中我们假设以下方程：

$$Y = \mathbf{w}^T \mathbf{x} + \varepsilon$$

$$p(y|\mathbf{x}, \theta) = \mathcal{N}(y|\mathbf{w}^T \mathbf{x}, \sigma^2)$$

X 是观测值，输入向量，自变量
 $\mathbf{w}$ 是参数，也被称作线性方程的系数
 ε 表示噪声， $\varepsilon \sim \mathcal{N}(0, \sigma^2)$
“线性”：模型在参数 $\mathbf{w}$ 中是线性的



1 线性回归

- 线性回归定义
- **求解线性回归方程**
- 线性回归的扩展
- 改进：局部回归
- 改进：鲁棒回归
- 改进：岭回归

2 用于分类的回归

3 逻辑回归

最大似然估计 (MLE) 求解回归方程

$$\hat{\theta} \triangleq \arg \max_{\theta} \log p(\mathcal{D}|\theta)$$

通常假设训练样本是独立同分布的，通常缩写为 iid。这意味着我们可以将对数似然写成如下形式：

$$\ell(\theta) \triangleq \log p(\mathcal{D}|\theta) = \sum_{i=1}^N \log p(y_i|\mathbf{x}_i, \theta)$$

效地最小化负对数似然或 NLL：

$$\text{NLL}(\theta) \triangleq - \sum_{i=1}^N \log p(y_i|\mathbf{x}_i, \theta)$$

最大似然估计 (MLE) 求解回归方程

线性回归:

$$p(y|\mathbf{x}, \boldsymbol{\theta}) = \mathcal{N}(y|\mathbf{w}^T\mathbf{x}, \sigma^2)$$

$$\begin{aligned}\ell(\boldsymbol{\theta}) &= \sum_{i=1}^N \log \left[\left(\frac{1}{2\pi\sigma^2} \right)^{\frac{1}{2}} \exp \left(-\frac{1}{2\sigma^2} (y_i - \mathbf{w}^T\mathbf{x}_i)^2 \right) \right] \\ &= -\frac{1}{2\sigma^2} \text{RSS}(\mathbf{w}) - \frac{N}{2} \log(2\pi\sigma^2)\end{aligned}$$

RSS 代表残差平方和, 也可记作 SSE, SSE/N 称为均方误差或 MSE。RSS 定义为

$$\text{RSS}(\mathbf{w}) \triangleq \sum_{i=1}^N (y_i - \mathbf{w}^T\mathbf{x}_i)^2$$

其中 $\epsilon_i = (y_i - \mathbf{w}^T\mathbf{x}_i)$ 。


最大似然估计 (MLE) 求解回归方程

$$\arg \min_w \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2$$

该方法也被称为最小二乘法。

优点：

- 最小化测量值与预测线之间的平方距离
- 具有良好的概率解释，易于计算



最大似然估计 (MLE) 求解回归方程

对于一元线性回归，非常容易计算：

$$\arg \min_w \sum_i (y_i - wx_i)^2$$

我们只需对 W 求导并令其为 0：

$$\frac{\partial}{\partial w} \sum_i (y_i - wx_i)^2 = 2 \sum_i x_i (y_i - wx_i) \implies$$

$$2 \sum_i x_i (y_i - wx_i) = 0 \implies$$

$$\sum_i x_i y_i = \sum_i wx_i^2 \implies$$

$$w = \frac{\sum_i x_i y_i}{\sum_i x_i^2}$$

最大似然估计 (MLE) 求解回归方程

对于多元线性回归，重写目标函数为矩阵形式：

$$\text{NLL}(\mathbf{w}) = \frac{1}{2}(\mathbf{y} - \mathbf{X}\mathbf{w})^T(\mathbf{y} - \mathbf{X}\mathbf{w}) = \frac{1}{2}\mathbf{w}^T(\mathbf{X}^T\mathbf{X})\mathbf{w} - \mathbf{w}^T(\mathbf{X}^T\mathbf{y})$$

梯度：

$$g(\mathbf{w}) = [\mathbf{X}^T\mathbf{X}\mathbf{w} - \mathbf{X}^T\mathbf{y}] = \sum_{i=1}^N \mathbf{x}_i(\mathbf{w}^T\mathbf{x}_i - y_i)$$

将其设为零，我们得到


$$\mathbf{X}^T\mathbf{X}\mathbf{w} = \mathbf{X}^T\mathbf{y}$$

这被称为正规方程。相应的解 $\mathbf{w}$ 到这个线性方程组被称为普通最小二乘法或 OLS 解，由下式给出：

$$\hat{\mathbf{w}}_{\text{OLS}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$


例子

- 生成: $w = 2$
- 恢复: $w = 2.03$
- 噪声: 标准差 = 1




例子

- 生成: $w = 2$
- 恢复: $w = 2.05$
- 噪声: 标准差 = 2



例子

- 生成: $w = 2$
- 恢复: $w = 2.08$
- 噪声: 标准差 = 4




对于一元线性回归

- 到目前为止我们假设直线通过原点
- 如果直线不通过原点怎么办？
- 没问题，只需将模型改为：

$$y = W_0 + W_1X + \varepsilon$$

- 可以使用最小二乘法确定 W_0, W_1

$$w_0 = \frac{\sum_i y_i - w_1 x_i}{n}, \quad w_1 = \frac{\sum_i x_i (y_i - w_1)}{\sum_i x_i^2}$$



对于多元线性回归

- 模型仍写作：

$$y = w_0 + w_1x_1 + w_2x_2 + \cdots + w_Dx_D$$

$$Y = \mathbf{w}^T \mathbf{X} + \varepsilon$$

$$X = \begin{pmatrix} 1 & x_{1,1} & x_{1,2} & \cdots & x_{1,D} \\ 1 & x_{2,1} & x_{2,2} & \cdots & x_{2,D} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N,1} & x_{N,2} & \cdots & x_{N,D} \end{pmatrix}$$

- 最大似然估计量

$$\mathbf{w} = (X^T X)^{-1} X^T y$$

1 线性回归

- 线性回归定义
- 求解线性回归方程
- **线性回归的扩展**
- 改进：局部回归
- 改进：鲁棒回归
- 改进：岭回归

2 用于分类的回归

3 逻辑回归

线性回归的扩展

- 使用核或其他形式的基函数扩展进行增强时，可以对非线性关系进行建模。

$$p(y|\mathbf{x}, \theta) = \mathcal{N}(y|\mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}), \sigma^2)$$

如：

$$y = 10 + 3x_1^2 - 2x_2^2 + \epsilon$$

- 当高斯输出被伯努利或多努利分布替换时，可以用于分类
只要系数是线性的，方程仍然是线性回归问题！

非线性基函数

到目前为止我们只使用了观测值 x

然而，线性回归可以同样应用于这些值的函数 $\phi(x)$

只要这些函数可以直接从观测值计算，参数在数据中仍然是线性的，问题仍然是线性回归问题

- 一些常见的非线性基函数：

- 多项式： $\phi_j(x) = x^j, j = 0, \dots, n$
- 高斯： $\phi_j(x) = \frac{\exp(-(x-\mu_j)^2/(2\sigma_j^2))}{2\sigma_j^2}$
- Sigmoid： $\phi_j(x) = \frac{1}{1+\exp(-s_j x)}$

一般线性回归问题

- 使用我们新的基函数符号，线性回归可以写为：

$$y = \sum_{j=0}^n w_j \phi_j(x)$$

或

$$y = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x} + \epsilon$$

- 其中 $\phi_j(X)$ 可以是多元回归的 x_j 或我们定义的非线性基函数
- 再次，我们可以使用“最小二乘”找到最优解。

最小均方求解一般线性回归

我们的目标是最小化以下损失函数：

$$\mathcal{J}(\mathbf{w}) = \sum_i (y^i - \sum_j w_j \phi_j(x^i))^2$$

转换为向量符号：

$$y = \sum_{j=0}^k w_j \phi_j(x)$$

w 是维度为 $k+1$ 的向量， $\phi(x)$ 是维度为 $k+1$ 的向量， y^i 是标量

$$J(\mathbf{w}) = \sum_i (y^i - \mathbf{w}^T \phi(x^i))^2$$

对 w 求导：

$$\frac{\partial}{\partial \mathbf{w}} \sum_i (y^i - \mathbf{w}^T \phi(x^i))^2 = 2 \sum_i (y^i - \mathbf{w}^T \phi(x^i)) \phi(x^i)^T$$

最小均方求解一般线性回归

对 $\mathbf{w}$ 求导:

$$\frac{\partial}{\partial \mathbf{w}} \sum_i (y^i - \mathbf{w}^T \phi(\mathbf{x}^i))^2 = 2 \sum_i (y^i - \mathbf{w}^T \phi(\mathbf{x}^i)) \phi(\mathbf{x}^i)^T$$

令其为 0:

$$\sum_i y^i \phi(\mathbf{x}^i)^T = \mathbf{w}^T \sum_i \phi(\mathbf{x}^i) \phi(\mathbf{x}^i)^T$$


定义:

$$\Phi = \begin{pmatrix} \phi_0(\mathbf{x}^1) & \phi_1(\mathbf{x}^1) & \cdots & \phi_k(\mathbf{x}^1) \\ \phi_0(\mathbf{x}^2) & \phi_1(\mathbf{x}^2) & \cdots & \phi_k(\mathbf{x}^2) \\ \vdots & \vdots & \cdots & \vdots \\ \phi_0(\mathbf{x}^n) & \phi_1(\mathbf{x}^n) & \cdots & \phi_k(\mathbf{x}^n) \end{pmatrix}$$


则解得:

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{y}$$



例：多项式回归



degree = 1, $CV = 0.6$



degree = 3, $CV = 1.5$



线性回归模型总结

- 线性回归模型结构简单，容易理解和解释。模型的参数（权重和截距）可以直接反映各个特征对目标变量的影响程度。
- 线性回归的计算过程相对简单，可以快速地在大规模数据集上进行训练和预测。
- 线性回归模型可以通过添加更多的特征来扩展，以适应更复杂的数据关系。
- 线性回归对异常值非常敏感，异常值可能会显著影响模型的参数估计。
- 然而，我们为这个模型学习的参数是全局的；无论输入 x 的值如何，它们都是相同的

1 线性回归

- 线性回归定义
- 求解线性回归方程
- 线性回归的扩展
- **改进：局部回归**
- 改进：鲁棒回归
- 改进：岭回归

2 用于分类的回归

3 逻辑回归

方法 1: 样条回归

改进: 根据我们处理的输入区域调整其参数

- 不拟合整个区域的单一函数, 而是拟合一组分段 (通常是三次) 多项式, 满足连续性和平滑性约束
- 结果得到平滑且灵活的函数, 而无需太多参数
- 需要预先定义区域 (通常是均匀的)



$$y = a_1x^3 + b_1x^2 + c_1x + d_1,$$

$$y = a_2x^3 + b_2x^2 + c_2x + d_2,$$

$$y = a_3x^3 + b_3x^2 + c_3x + d_3$$


方法 2：局部核函数回归

- 房间的温度是多少？在位置 x ？



$$\frac{1}{n} \sum_{i=1}^n Y_i \quad \text{全局平均}$$

$$\hat{f}(x) = \frac{\sum_{i=1}^n Y_i \mathbf{1}_{|x-X_i|<h}}{\sum_{i=1}^n \mathbf{1}_{|x-X_i|<h}} \quad \text{局部平均}$$



$$\begin{aligned}\hat{f}_n(X) &= \hat{\beta} = \sum_{i=1}^n w_i Y_i \\ &= \frac{1}{n_X^h} \sum_{i=1}^n Y_i \mathbf{1}_{|X-X_i| \leq h}\end{aligned}$$


n_X^h : X 为中心, h 为半径的球内点的数量。

几何意义: $\hat{f}_n(X)$ 估计为该球内对应 Y 的平均值。

比较:

- 非参数估计器, 类似于 kNN
- NN 分类器用多数投票, 这里我们用平均值

局部核函数回归



标准形式:

$$\hat{f}_n(x) = \hat{\beta} = \sum_{i=1}^n w_i Y_i, \quad w_i(X) = \frac{K\left(\frac{x - X_i}{h}\right)}{\sum_{j=1}^n K\left(\frac{x - X_j}{h}\right)}$$


当使用 boxcar kernel:

$$K\left(\frac{x - X_i}{h}\right) = \mathbf{1}_{|x - X_i| \leq h}$$

式子等价于 $\frac{1}{n^h} \sum_{i=1}^n Y_i \mathbf{1}_{|x - X_i| \leq h}$

boxcar kernel :

$$K(x) = \frac{1}{2} I(x),$$



推导：局部核函数回归

- Nadaraya-Watson 核估计器

$$f(x) = \mathbb{E}[y | x] = \int y p(y | x) dy = \frac{\int y p(x, y) dy}{\int p(x, y) dy}.$$

我们用 KDE 来近似联合密度 $p(x, y)$:

$$p(x, y) \approx \frac{1}{N} \sum_{i=1}^N \kappa_h(x - x_i) \kappa_h(y - y_i).$$

于是

$$f(x) = \frac{\frac{1}{N} \sum_{i=1}^N \kappa_h(x - x_i) \int y \kappa_h(y - y_i) dy}{\frac{1}{N} \sum_{i=1}^N \kappa_h(x - x_i) \int \kappa_h(y - y_i) dy} = \frac{\sum_{i=1}^N \kappa_h(x - x_i) y_i}{\sum_{i=1}^N \kappa_h(x - x_i)}.$$

局部核函数回归

- 将结果进一步写成

$$\hat{f}_n(X) = \sum_{i=1}^n w_i Y_i, \quad w_i(X) = \frac{K\left(\frac{X-X_i}{h}\right)}{\sum_{i=1}^n K\left(\frac{X-X_i}{h}\right)}$$


- 预测值是训练点输出的加权平均，权重取决于待测点 x 与训练点的相似程度。
- Boxcar 核得到局部平均
- 高斯核是平滑的，并且随着距离的增加迅速减小，适用于大多数情况。它能够很好地处理数据中的噪声。

核函数


$$K(x) \geq 0,$$
$$\int K(x)dx = 1$$

boxcar kernel :

$$K(x) = \frac{1}{2}I(x),$$





$$K\left(\frac{X_j - x}{\Delta}\right)$$



Gaussian kernel :


$$K(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$$






内核带宽的选择: h

只有一个可调参数 h

Too small




$h=10$ Too small



内核带宽的选择: h

- 应取决于 N , 训练数据数量 (决定方差)
- 应取决于函数的平滑度 (决定偏差)
- 大带宽——平均更多数据点, 减少噪声 (更低方差)
- 小带宽——更少平滑, 更准确拟合 (更低偏差)
- 偏差-方差权衡



内核带宽的选择: h

Bowman 与 Azzalini (1997) 指出, 对于一维数据, 在真实密度为高斯且使用高斯核时, 最优带宽为

$$h = \left(\frac{4}{3N} \right)^{1/5} \hat{\sigma}.$$


稳健的 $\hat{\sigma}$ 可先计算平均绝对离差

$$\text{MAD} = \text{median}(|x - \text{median}(x)|),$$

再取

$$\hat{\sigma} = 1.4826 \text{ MAD} = \frac{1}{0.6745} \text{ MAD}.$$

空间自适应回归



如果函数的平滑度在空间上变化，我们希望允许带宽 h 依赖于 X
局部多项式、样条曲线、小波、回归树……

1 线性回归

- 线性回归定义
- 求解线性回归方程
- 线性回归的扩展
- 改进：局部回归
- **改进：鲁棒回归**
- 改进：岭回归

2 用于分类的回归


3 逻辑回归

鲁棒线性回归

在回归模型中，使用均值为零且方差恒定的高斯分布来模拟噪声

$$\epsilon_i \sim \mathcal{N}(0, \sigma^2)$$

如果我们的数据中有离群值，这可能导致拟合效果不佳



鲁棒线性回归

- 用具有重尾分布的分布替换响应变量的高斯分布
- 为离群值分配更高的可能性，而无需扰动直线来“解释”它们

$$p(y|\mathbf{x}, \mathbf{w}, b) = \text{Lap}(y|\mathbf{w}^T\mathbf{x}, b) \propto \exp\left(-\frac{1}{b}|y - \mathbf{w}^T\mathbf{x}|\right)$$

- 损失函数：设 $r_i \triangleq y_i - \mathbf{w}^T\mathbf{x}_i$ 为第 i 个残差。

$$\ell(\mathbf{w}) = \sum_i |r_i(\mathbf{w})|$$

- 参数估计（非线性目标函数，难以优化，通过施加不等式约束）：


$$\min_{\mathbf{w}, r^+, r^-} \sum_i (r_i^+ + r_i^-) \quad \text{s.t.} \quad r_i^+ \geq 0, r_i^- \geq 0, \mathbf{w}^T\mathbf{x}_i + r_i^+ + r_i^- = y_i$$

- Huber 损失函数

$$L_H(r, \delta) = \begin{cases} r^2/2 & \text{if } |r| \leq \delta \\ \delta|r| - \delta^2/2 & \text{if } |r| > \delta \end{cases}$$

- 对小于 δ 的误差使用 ℓ_2 ，对较大的误差使用 ℓ_1 。
- 在任何地方都是可微的，使用标准的平滑优化方法（如拟牛顿法）

鲁棒线性回归



1 线性回归


- 线性回归定义
- 求解线性回归方程
- 线性回归的扩展
- 改进：局部回归
- 改进：鲁棒回归
- 改进：岭回归

2 用于分类的回归

3 逻辑回归

岭回归

- 最大似然估计 (MLE) 的一个问题是它可能导致过拟合
- 如果数据有噪声，MLE 选择的参数往往会导致复杂的函数。曲线非常“波动”。



岭回归

- 通过使用零均值高斯先验来鼓励参数值小，从而得到更平滑的曲线，即

$$p(\mathbf{w}) = \prod_j \mathcal{N}(w_j | 0, \tau^2)$$

其中 $1/\tau^2$ 控制先验的强度。

$$\arg \max_{\mathbf{w}} \sum_{i=1}^N \log \mathcal{N}(y_i | w_0 + \mathbf{w}^T \mathbf{x}_i, \sigma^2) + \sum_{j=1}^D \log \mathcal{N}(w_j | 0, \tau^2)$$

- 等价于最小化：

$$J(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (y_i - (w_0 + \mathbf{w}^T \mathbf{x}_i))^2 + \lambda \|\mathbf{w}\|_2^2$$

其中 $\lambda \triangleq \sigma^2/\tau^2$ 且 $\|\mathbf{w}\|_2^2 = \sum_j w_j^2 = \mathbf{w}^T \mathbf{w}$ 是平方二范数。这里第一项与 MLE/NLL 相同，第二项 $\lambda \geq 0$ ，是一个复杂度惩罚。

- 参数解：

$$\hat{\mathbf{w}} = (\lambda \mathbf{I} + \mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- 线性回归 - 基本模型, 输入的函数
- 最大似然估计 (MLE) 求解线性回归
- 改进的回归模型
 - 样条
 - 局部线性回归
 - 鲁棒线性回归
 - 岭回归

1 线性回归

- 线性回归定义
- 求解线性回归方程
- 线性回归的扩展
- 改进：局部回归
- 改进：鲁棒回归
- 改进：岭回归

2 用于分类的回归

3 逻辑回归

回到分类

- ① 基于实例的分类器
直接使用观测值（无模型）——例如 K 近邻
- ② 生成式分类器
构建一个生成式统计模型——例如贝叶斯网络
- ③ 判别式分类器
直接估计决策规则/边界——例如决策树


生成式分类器 vs 判别式分类器

- 生成式分类器: 创建形式为 $p(y, \mathbf{x})$ 的联合模型, 然后对 $\mathbf{x}$ 进行条件化, 从而得到 $p(y|\mathbf{x})$ 。
- 判别式分类器: 直接拟合形式为 $p(y|\mathbf{x})$ 的模型
- 使用生成式分类器时, 我们依赖所有点来学习生成式模型
- 使用判别式分类器时, 我们主要关注边界
- 与生成式分类器不同, 判别式分类器不计算 $P(X|Y)$

线性回归

- 我们的目标是利用训练数据 $\langle x_i, y_i \rangle$ 对来估计 w
- 找到这种关系的一种方法是极小化最小二乘误差：

$$\arg \min_w \sum_i (y_i - wx_i)^2$$



用于分类的回归

- 在某些情况下，线性回归可以用来确定合适的分类边界。
- 然而，由于输出通常是二值或离散的，存在更高效的回归方法。
- 回顾一下，对于分类问题，我们关注的是条件概率 $p(y | \mathbf{X}; \theta)$ ，其中 θ 是模型参数。
- 当使用回归模型时， θ 表示回归系数 $\mathbf{w}$ 的值。

1 线性回归


- 线性回归定义
- 求解线性回归方程
- 线性回归的扩展
- 改进：局部回归
- 改进：鲁棒回归
- 改进：岭回归

2 用于分类的回归

3 逻辑回归

用于分类的回归

- 假设我们希望用线性回归来学习 $p(y | X; \theta)$ 的参数
- $w^T X \geq 0 \Rightarrow$ 分类为 1
- $w^T X < 0 \Rightarrow$ 分类为 -1



Sigmoid 函数


- 为了用回归模型进行分类，我们将线性函数替换为 sigmoid 函数：

$$g(h) = \frac{1}{1 + e^{-h}}$$

- 始终在 0 与 1 之间
- 使用 sigmoid 时，我们设（对于二分类问题）：

$$p(y = 0 \mid X; \theta) = g(\mathbf{w}^\top X) = \frac{1}{1 + e^{\mathbf{w}^\top X}}$$

$$p(y = 1 \mid X; \theta) = 1 - g(\mathbf{w}^\top X) = \frac{e^{\mathbf{w}^\top X}}{1 + e^{\mathbf{w}^\top X}}$$




参数在指数中，而不是线性回归！

注意我们直接用 $p(y \mid X)$ 来定义概率，这里不需要贝叶斯公式！

逻辑回归 vs 线性回归

$$p(y = 0 \mid X; \theta) = g(w^\top X) = \frac{1}{1 + e^{w^\top X}}$$

$$p(y = 1 \mid X; \theta) = 1 - g(w^\top X) = \frac{e^{w^\top X}}{1 + e^{w^\top X}}$$



确定逻辑回归问题的参数

逻辑回归：

$$p(y|\mathbf{x}, \mathbf{w}) = \text{Ber}(y|\text{sign}(\mathbf{w}^T \mathbf{x}))$$

- 逻辑回归名称来自 logit 变换：

$$\log \frac{p(y = i | X; \theta)}{p(y = k | X; \theta)} = \log \frac{g(z_i)}{g(z_k)} = w_i^0 + w_i^1 x^1 + \cdots + w_i^d x^d$$

- 那么我们如何学习参数？
- 与其他回归问题类似，我们寻找 w 的极大似然估计
- 给定模型的数据似然是：

$$L(y | X; w) = \prod_i (1 - g(X_i; w))^{y_i} g(X_i; w)^{(1-y_i)}$$

求解逻辑回归问题

$$g(X; w) = \frac{1}{1 + e^{w^\top X}}$$

- 数据的似然：

$$L(y | X; w) = \prod_i (1 - g(X_i; w))^{y_i} g(X_i; w)^{(1-y_i)}$$

- 取对数得到：


$$\begin{aligned}\ell(y | X; w) &= \sum_{i=1}^N y_i \ln(1 - g(X_i; w)) + (1 - y_i) \ln g(X_i; w) \\ &= \sum_{i=1}^N y_i \ln \frac{1 - g(X_i; w)}{g(X_i; w)} + \ln g(X_i; w) \\ &= \sum_{i=1}^N y_i w^\top X_i - \ln(1 + e^{w^\top X_i})\end{aligned}$$

极大似然估计

$$\begin{aligned}\frac{\partial}{\partial w^j} l(w) &= \frac{\partial}{\partial w^j} \sum_{i=1}^N \left\{ y_i w^\top X_i - \ln(1 + e^{w^\top X_i}) \right\} \\ &= \sum_{i=1}^N X_i^j \{ y_i - (1 - g(X_i; w)) \} \\ &= \sum_{i=1}^N X_i^j \{ y_i - p(y^j = 1 \mid X_i; w) \}\end{aligned}$$


- 对每个分量 w^j 求偏导
- 坏消息：没有闭式解！
- 好消息：函数是凹的

梯度上升



- 沿着梯度方向移动会使 z 变大
- 但不能太大，否则会越过最优 w

梯度下降



- 沿着梯度相反方向移动会使 z 变小
- 但不能太大，否则会越过最优 w

逻辑回归的梯度上升

$$\frac{\partial}{\partial w^j} \ell(w) = \sum_{i=1}^N X_i^j \{y_i - (1 - g(X_i; w))\}$$

我们使用梯度来调整 w 的值:

$$w^j \leftarrow w^j + \varepsilon \sum_{i=1}^N X_i^j \{y_i - (1 - g(X_i; w))\}$$

其中 ε 是一个很小的常数, 称为该算法的学习率

逻辑回归算法

- 1 选择 ε
- 2 对 w 给出一个初始猜测
- 3 对所有 j 设置:

$$w^j \leftarrow w^j + \varepsilon \sum_{i=1}^N X_i^j \{y_i - (1 - g(X_i; w))\}$$

- 4 如果没有改进则停止, 则

$$\ell(y | X; w) = \sum_{i=1}^N y_i \ln(1 - g(X_i; w)) + (1 - y_i) \ln g(X_i; w)$$

否则回到第 3 步

- 与其他数据估计问题类似，我们可能没有足够的样本为逻辑回归分类学习出好的模型
- 克服这一问题的一种方法是“正则化”模型，对我们拟合的参数施加额外约束
- 例如，假设 w_j 来自均值为 0、方差为 σ^2 的高斯分布 (σ^2 是用户定义参数): $w_j \sim \mathcal{N}(0, \sigma^2)$
- 这样我们就对参数有了先验，因此：

$$p(y = 1, \theta \mid X) \propto p(y = 1 \mid X; \theta) p(\theta)$$

正则化

- 如果我们正则化参数，在计算参数后验时需要考虑先验

$$p(y = 1, \theta \mid X) \propto p(y = 1 \mid X; \theta) p(\theta)$$

- 这里我们使用高斯模型作为先验，于是对数似然变为（假设均值为 0 并删除不依赖于 w 的项）：

$$\ell(y; w \mid X) = \sum_{i=1}^N y_i w^\top X_i - \ln(1 + e^{w^\top X_i}) - \sum_j \frac{(w^j)^2}{2\sigma^2}$$

- 新的更新规则（对 w_j 求导后）：

$$w^j \leftarrow w^j + \varepsilon \sum_{i=1}^N X_i^j \{y_i - (1 - g(X_i; w))\} - \varepsilon \frac{w^j}{\sigma^2}$$

也称为最大后验估计（MAP estimate）。其中, σ^2 是我们先验模型的方差

正则化

- 还有很多其他方式对逻辑回归进行正则化
- 高斯模型导致 L2 正则化（我们试图最小化 w 的平方值）

$$J_{L2}(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N \log(1 + \exp(-y_i \mathbf{w}^T \mathbf{x}_i)) + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

- 另一种流行的正则化是 L1，它试图最小化 $|w|$

$$J_{L1}(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N \log(1 + \exp(-y_i \mathbf{w}^T \mathbf{x}_i)) + \lambda \|\mathbf{w}\|_1$$

多分类的逻辑回归

- 逻辑回归可用于多于两类数据的分类。假设我们有 k 个类别：
- 对 $i < k$ 我们设：

$$p(y = i | X; \theta) = g(w_i^0 + w_i^1 x^1 + \cdots + w_i^d x^d) = g(\mathbf{w}_i^\top X)$$

其中

$$g(z_i) = \frac{e^{z_i}}{1 + \sum_{j=1}^{k-1} e^{z_j}}, \quad z_i = w_i^0 + w_i^1 x^1 + \cdots + w_i^d x^d$$

- 对第 k 类：

$$p(y = k | X; \theta) = 1 - \sum_{i=1}^{k-1} p(y = i | X; \theta)$$

$$p(y = k | X; \theta) = \frac{1}{1 + \sum_{j=1}^{k-1} e^{z_j}}$$

- 二元逻辑回归是该规则的一个特例

多类逻辑回归的更新规则

$$\frac{\partial}{\partial w_m^j} \ell(\mathbf{w}) = \sum_{i=1}^N X_i^j \{ \delta_m(y_i) - p(y_i = m \mid X_i; \mathbf{w}) \}$$

其中 $\delta_m(y_i) = 1$ 若 $y_i = m$, 否则 $\delta_m(y_i) = 0$
更新规则变为:

$$w_m^j \leftarrow w_m^j + \varepsilon \sum_{i=1}^N X_i^j \{ \delta_m(y_i) - p(y_i = m \mid X_i; \mathbf{w}) \}$$

逻辑回归的扩展

- 与线性回归类似，我们可以将逻辑回归扩展到数据的其他变换：

$$p(y = 1 \mid X; w) = g(w_1^0 + w_1^1 \phi^1(X) + \cdots + w_1^d \phi^d(X))$$

- 我们可以自由选择基函数

- 多项式基函数： $[1, X, X^2, X^3, \dots]$
- 高斯径向基函数： $\exp\left(-\frac{(X-c)^2}{2\sigma^2}\right)$
- 正弦和余弦函数： $[\sin(X), \cos(X)]$
- 分段线性函数（例如 ReLU）： $\max(0, X)$
- Sigmoid 函数： $\frac{1}{1+e^{-X}}$
- Tanh 函数： $\tanh(X)$

- 逻辑回归相对于线性回归在分类中的优势
- Sigmoid 函数
- 梯度上升/下降
- 正则化
- 多类逻辑回归

Feedback welcome!

The End