

统计机器学习基础

Foundations of Statistical Machine Learning

——混合模型与期望最大

Kai Chen

kaichen6@csu.edu.cn

25th September 2025



中南大学
CENTRAL SOUTH UNIVERSITY

数学与统计学院
SCHOOL OF MATHEMATICS AND STATISTICS

- 1 回顾：分布的 MLE
- 2 混合模型
 - 高斯混合模型
- 3 期望最大化 (EM) 算法
- 4 隐马尔可夫模型的 EM

回顾：指示变量与离散分布

- 伯努利分布: $Ber(p)$

$$P(x) = \begin{cases} 1-p & \text{for } x=0 \\ p & \text{for } x=1 \end{cases} \Rightarrow P(x) = p^x(1-p)^{1-x}$$

- 多项分布:

$$X = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \\ X_4 \\ X_5 \\ X_6 \end{bmatrix},$$

$$X_j \in [0, 1], \quad \text{and} \quad \sum_{j \in \{1, \dots, 6\}} X_j = 1$$

$$X_j = 1 \text{ w.p. } \theta_j, \quad \sum_{j \in \{1, \dots, 6\}} \theta_j = 1.$$



其中 $\sum_{k=1}^K x_k = n, x_k \geq 0$

回顾：指示变量与离散分布

对于多项分布，概率 $P(x_i)$ 可以表示为：

$$P(x_i) = P(\{x_{n,k} = 1, \text{ where } k \text{ index the die-side of the } n\text{th roll}\}) \quad (1)$$

$$= \theta_k = \theta_1^{x_{n,1}} \times \theta_2^{x_{n,2}} \times \cdots \times \theta_K^{x_{n,K}} = \prod_{k=1}^K \theta_k^{x_{n,k}} \quad (2)$$

可以证明：


$$\hat{\theta}_{k,MLE} = \frac{n_k}{N} \quad \text{or} \quad \hat{\theta}_{k,MLE} = \frac{1}{N} \sum_n x_{n,k}$$

回顾：连续变量与高斯分布

- 正态（高斯）概率密度函数

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$$

- 分布对称，常表现为钟形曲线
- 两个参数 μ （均值）与 σ （标准差）决定位置与形状
- 正态曲线最高点在均值处，同时也是中位数和众数
- 均值可取任意实数值：负、零或正



回顾：多元高斯

$$p(x; \mu, \Sigma) = \frac{1}{(2\pi)^{m/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\}$$


可以证明， μ 与 Σ 的 MLE 为

$$\hat{\mu}_{\text{MLE}} = \frac{1}{N} \sum_n x_n, \quad \hat{\Sigma}_{\text{MLE}} = \frac{1}{N} \sum_n (x_n - \hat{\mu})(x_n - \hat{\mu})^T$$

其中散度矩阵

$$S = \sum_n (x_n - \hat{\mu})(x_n - \hat{\mu})^T$$


充分统计量为 $\sum_n x_n$ 与 $\sum_n x_n x_n^T$
请注意， $X^T X = \sum_n x_n x_n^T$ 可能不是满秩的
如 $N < D$ ，在这种情况下， Σ_{ML} 是不可逆的。



回顾：条件高斯

数据：

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$



- y 为类别指示向量

$$p(y_n) = \text{Mult}(y_n; \pi) = \prod_k \pi_k^{y_{n,k}}$$

- X 为条件高斯变量，具有类别特定均值

$$p(x_n | y_{n,k} = 1, \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x_n - \mu_k)^2}{2\sigma^2}\right\}$$

$$p(x | y, \mu, \sigma) = \prod_n \left(\prod_k N(x_n; \mu_k, \sigma)^{y_{n,k}} \right)$$

回顾：条件高斯的 MLE

数据对数似然：

$$\ell(\theta; D) = \log \prod_n p(x_n, y_n) = \log \prod_n p(y_n | \pi) p(x_n | y_n, \mu, \sigma)$$

MLE：

$$\hat{\pi}_{k,MLE} = \arg \max_{\pi} \ell(\theta; D),$$

$\hat{\pi}_{k,MLE} = \frac{\sum_n y_{n,k}}{N} = \frac{n_k}{N}$ ，表示类别 m 的样本比例。

$$\hat{\mu}_{k,MLE} = \arg \max_{\mu} \ell(\theta; D),$$


$\hat{\mu}_{k,MLE} = \frac{\sum_n y_{n,k} x_n}{\sum_n y_{n,k}} = \frac{\sum_n y_{n,k} x_n}{n_k}$ ，表示类别 m 的样本的平均值。

Outline


- 1 回顾：分布的 MLE
- 2 混合模型
 - 高斯混合模型
- 3 期望最大化 (EM) 算法
- 4 隐马尔可夫模型的 EM

混合模型

- 密度模型可能是多峰的
- 我们可以将其建模为多个单峰分布（例如高斯）的混合
- 每个模式可能对应不同的子群体（例如男性和女性）
- 未观察到指标变量 Z !



(a)



(b)

变量可能因为以下原因未观测（潜在）：

- 它是为提供对数据生成过程的简化和抽象视图而设想的量，例如语音识别模型、混合模型……
- 它是真实世界的对象或现象，但难以或无法测量，例如恒星温度、疾病原因、进化祖先……
- 它是真实世界的对象或现象，但有时由于传感器故障而未测量，或测量时存在噪声，例如交通广播、雷达屏幕上的飞机信号……
- 离散潜在变量可用于将数据划分为/聚类到子组中（混合模型）
- 连续潜在变量（因子）可用于降维（因子分析）

Outline



- 1 回顾：分布的 MLE
- 2 混合模型
 - 高斯混合模型
- 3 期望最大化 (EM) 算法
- 4 隐马尔可夫模型的 EM

高斯混合模型 (GMM)

- 考虑 K 个高斯分量的混合:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

π_k 表示混合比例



- 该模型可用于无监督聚类
- 该模型 (由 AutoClass 拟合) 已用于在天文数据中发现新星等

GMM 似然

- 考虑 K 个高斯分量的混合:
- z 为潜在类别指示向量:

$$p(z_n) = \text{multi}(z_n; \pi) = \prod_k \pi_k^{z_n^k}$$

- X 为具有类别特定均值/协方差的条件高斯变量

$$p(x_n | z_n^k, \mu, \Sigma) = \quad (3)$$

$$\frac{1}{(2\pi)^{m/2} |\Sigma_k|^{1/2}} \exp \left\{ -\frac{1}{2} (x_n - \mu_k)^T \Sigma_k^{-1} (x_n - \mu_k) \right\} \quad (4)$$

- 样本的似然:

$$p(x_n | \mu, \Sigma) = \sum_k p(z^k = 1 | \pi) p(x_s | z^k = 1, \mu, \Sigma) \quad (5)$$

$$= \sum_{z_n} \prod_k \left((\pi_k)^{z_n^k} \mathcal{N}(x_n; \mu_k, \Sigma_k)^{z_n^k} \right) = \sum_k \pi_k \mathcal{N}(x_s | \mu_k, \Sigma_k) \quad (6)$$



为什么学习更难？

- 在完全观测的 i.i.d 设置中，对数似然可分解为局部项之和

$$\ell_c(\theta; D) = \log p(x, z | \theta) = \log p(z | \theta_z) + \log p(x | z, \theta_x)$$

- 引入潜在变量后，所有参数通过边缘化耦合在一起

$$\ell_c(\theta; D) = \log \sum_z p(x, z | \theta) = \log \sum_z p(z | \theta_z) p(x | z, \theta_x)$$



混合模型的梯度学习

我们可以使用对数似然的梯度下降来学习混合密度。

$$\ell(\theta) = \log p(x | \theta) = \log \sum_k \pi_k p_k(x | \theta_k) \quad (7)$$

$$\frac{\partial \ell}{\partial \theta} = \frac{1}{p(x | \theta)} \sum_k \pi_k \frac{\partial p_k(x | \theta_k)}{\partial \theta} \quad (8)$$

$$= \sum_k \frac{\pi_k}{p(x | \theta)} p_k(x | \theta_k) \frac{\partial \log p_k(x | \theta_k)}{\partial \theta} \quad (9)$$

$$= \sum_k \pi_k \frac{p_k(x | \theta_k)}{p(x | \theta)} \frac{\partial \log p_k(x | \theta_k)}{\partial \theta_k} = \sum_k r_k \frac{\partial \ell_k}{\partial \theta_k} \quad (10)$$

换句话说，梯度是各个对数似然梯度的责任加权和。
可以将其传递给共轭梯度

参数约束

- 通常对参数有约束, 例如 $\sum_k \pi_k = 1$, Σ 对称正定
- 可使用约束优化, 或使用无约束参数重新参数化
- 对归一化权重使用 softmax 变换
- 对协方差矩阵使用 Cholesky 分解

$$\Sigma^{-1} = \mathbf{A}^T \mathbf{A}$$

其中 $\mathbf{A}$ 是正定的上三角矩阵

$$\mathbf{A}_{ii} = \exp(\lambda_i) > 0 \quad \mathbf{A}_{ij} = \eta_{ij} \ (j > i) \quad \mathbf{A}_{ij} = 0 \ (j < i)$$

参数 $\gamma_i, \lambda_i, \eta_{ij} \in \mathbb{R}$ 是无约束的

- 使用链式规则进行计算

$$\frac{\partial \ell}{\partial \pi}, \quad \frac{\partial \ell}{\partial \mathbf{A}}$$

Outline

- 1 回顾：分布的 MLE
- 2 混合模型
 - 高斯混合模型
- 3 期望最大化 (EM) 算法
- 4 隐马尔可夫模型的 EM

GMM 似然函数

如: K 个高斯混合模型

- Z 是一个潜在类别指示向量

$$p(z_n) = \text{multi}(z_n : \pi) = \prod_k (\pi_k)^{z_n^k}$$

- X 是一个具有类别特定均值/协方差的条件高斯变量

$$p(x_n | z_n^k) = \frac{1}{(2\pi)^{m/2} |\Sigma_k|^{1/2}} \exp \left\{ -\frac{1}{2} (x_n - \mu_k)^T \Sigma_k^{-1} (x_n - \mu_k) \right\} \quad (11)$$


$$= 1, \mu, \Sigma) = \frac{1}{(2\pi)^{m/2} |\Sigma_k|^{1/2}} \exp \left\{ -\frac{1}{2} (x_n - \mu_k)^T \Sigma_k^{-1} (x_n - \mu_k) \right\} \quad (12)$$

- 一个样本的似然函数:

$$\begin{aligned} p(x_n | \mu, \Sigma) &= \sum_k p(z^k = 1 | \pi) p(x, | z^k = 1, \mu, \Sigma) \\ &= \sum_{z_n} \prod_k \left((\pi_k)^{z_n^k} N(x_n : \mu_k, \Sigma_k)^{z_n^k} \right) = \sum_k \pi_k N(x_n | \mu_k, \Sigma_k) \end{aligned}$$

GMM 的 EM 启发式

开始: “猜测” 每个 K 簇的质心 k 和方差 Σ_k
循环



回顾 K-means

- 开始：猜测每个 K 聚类的质心 μ_k 和协方差 Σ_k


- 循环：

- 计算聚类标签：

$$z_n^{(t)} = \arg \min_k (x_n - \mu_k^{(t)})^T \Sigma_k^{-1(t)} (x_n - \mu_k^{(t)})$$

- 对每个聚类 $k = 1 : K$:


$$\mu_k^{(t+1)} = \frac{\sum_n \delta(z_n^{(t)}, k) x_n}{\sum_n \delta(z_n^{(t)}, k)}$$



- EM 是一种优化策略，用于可解释为带缺失数据的似然的目标函数
- 比梯度方法简单得多：
 - 无需选择步长
 - 自动强制执行约束
 - 调用推理和完全观测学习作为子程序
- EM 是一个具有两个关联步骤的迭代算法：
 - E 步：用推理填充隐藏值 $p(z|x, \theta^t)$
 - M 步：用标准 MLE/MAP 方法更新参数
- 我们将证明该程序单调地提高似然（或保持不变），因此总是收敛到局部最优

不可识别性

- 混合模型诱导多峰似然
- 因此梯度上升只能找到局部最大值
- 混合模型不可识别，因为我们总是可以交换隐藏标签而不影响似然
- 因此我们在尝试解释潜在变量的“含义”时应小心



- 完整似然

$$p(x_n, z_n^k = 1 \mid \mu, \Sigma) = p(z_n^k = 1 \mid \pi) p(x_n \mid z_n^k = 1, \mu, \Sigma) \quad (13)$$

$$= \pi_k \mathcal{N}(x_n \mid \mu_k, \Sigma_k) \quad (14)$$

$$p(x_n, z_n \mid \mu, \Sigma) = \prod_k [\pi_k \mathcal{N}(x_n \mid \mu_k, \Sigma_k)]^{z_n^k} \quad (15)$$

- 但这是一个随机变量！不是一个好的目标函数

- 完整对数似然:

$$\begin{aligned}\ell(\theta; D) &= \log \prod_n p(z_n, x_n) = \log \prod_n p(z_n | \pi) p(x_n | z_n, \mu, \sigma) \\ &= \sum_n \log \prod_k \pi_k^{z_n^k} + \sum_n \log \prod_k N(x_n; \mu_k, \sigma)^{z_n^k} \\ &= \sum_n \sum_k z_n^k \log \pi_k - \sum_n \sum_k z_n^k \frac{1}{2\sigma^2} (x_n - \mu_k)^2 + C\end{aligned}\tag{16}$$

- 期望完整对数似然:

$$\begin{aligned}\langle \ell_c(\theta; \mathbf{X}, \mathbf{Z}) \rangle &= \sum_n \langle \log p(\mathbf{z}_n | \pi) \rangle_{p(\mathbf{z}|\mathbf{X})} + \sum_n \langle \log p(\mathbf{x}_n | \mathbf{z}_n, \mu, \Sigma) \rangle_{p(\mathbf{z}|\mathbf{X})} \\ &= \sum_n \sum_k \langle z_n^k \rangle \log \pi_k - \frac{1}{2} \sum_n \sum_k \langle z_n^k \rangle \left((\mathbf{x}_n - \mu_k)^T \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) \right. \\ &\quad \left. + \log |\Sigma_k| + C \right)\end{aligned}\tag{17}$$

- 我们迭代地最大化以下迭代过程：
计算在给定参数的当前估计值（即 π, μ ）的隐变量（即 z ）的充分统计量的期望值。

$$\tau_n^{k(t)} = \langle z_n^k \rangle_{q^{(t)}} = \frac{\pi_k^{(t)} \mathcal{N}(x_n | \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_j \pi_j^{(t)} \mathcal{N}(x_n | \mu_j^{(t)}, \Sigma_j^{(t)})}$$

- 这里我们实际上在做推理

- 我们通过以下迭代过程迭代地最大化 $\langle \ell_c(\theta) \rangle$:
- 最大化步骤: 在当前隐藏变量期望值的结果下计算参数

$$\pi_k^* = \arg \max \langle \ell_c(\theta) \rangle, \quad \Rightarrow \frac{\partial}{\partial \pi_k} \langle \ell_c(\theta) \rangle = 0, \quad \forall k, \quad \text{s.t.} \sum_k \pi_k = 1$$

$$\Rightarrow \pi_k^* = \frac{\sum_n \langle z_n^k \rangle_{q^{(t)}}}{N} = \frac{\sum_n \tau_n^{k(t)}}{N} = \langle n_k \rangle / N$$

$$\mu_k^* = \arg \max \langle \ell(\theta) \rangle, \quad \Rightarrow \mu_k^{(t+1)} = \frac{\sum_n \tau_n^{k(t)} x_n}{\sum_n \tau_n^{k(t)}}$$

$$\Sigma_k^* = \arg \max \langle \ell(\theta) \rangle, \quad \Rightarrow \Sigma_k^{(t+1)} = \frac{\sum_n \tau_n^{k(t)} (x_n - \mu_k^{(t+1)})(x_n - \mu_k^{(t+1)})^T}{\sum_n \tau_n^{k(t)}}$$

- 这与 MLE 同构, 除了隐藏变量被它们的期望值替换 (一般来说, 它们将被它们对应的“充分统计量”替换)


比较: K-means

- 高斯混合的 EM 算法类似于 K-means 算法的“软版本”
- 在 K-means 的“E 步”中我们进行硬分配:

$$z_n^{(t)} = \arg \min_k (x_n - \mu_k^{(t)})^T \Sigma_k^{-1(t)} (x_n - \mu_k^{(t)})$$

- 在 K-means 的“M 步”中我们更新均值, 权重为 0 或 1:

$$\mu_k^{(t+1)} = \frac{\sum_n \delta(z_n^{(t)}, k) x_n}{\sum_n \delta(z_n^{(t)}, k)}$$



EM 背后的理论

回顾 MLE，我们打算学习使数据似然最大的模型参数。
但 z 未观测，因此计算困难！

$$\ell(\theta; D) = \log \sum_z p(x, z | \theta) = \log \sum_z p(z | \theta_z) p(x | z, \theta_x)$$

我们该怎么办？

完整与不完整对数似然

- 完整对数似然：

- 令 X 表示可观测变量， Z 表示潜在变量。如果 Z 可以被观测到，那么

$$\ell_c(\theta; x, z) \stackrel{\text{def}}{=} \log p(x, z \mid \theta)$$

- 通常，给定 z 和 x 优化 $\ell_c()$ 是直接的（参见完全观测模型的 MLE）。
- 回忆一下，在这种情况下，目标函数（例如，MLE）分解为若干因子的和，每个因子的参数可以单独估计。
- 但是，由于 Z 未被观测到， $\ell_c()$ 是一个随机量，不能直接最大化。
- 不完整对数似然：当 z 未被观测到时，我们的目标变为边际概率的对数：

$$\ell_c(\theta; x) = \log p(x \mid \theta) = \log \sum_z p(x, z \mid \theta)$$


该目标不会分解

期望完整对数似然

对任意分布 $q(z)$ 定义期望完整对数似然：

$$\langle \ell_c(\theta; x, z) \rangle_q = \sum_z q(z|x, \theta) \log p(x, z|\theta)$$

- 线性于 ℓ_c ——继承其可分解性
- 最大化这个代理是否能最大化似然？
- Jensen 不等式：



$$\begin{aligned}\ell(\theta; x) &= \log p(x|\theta) \\ &= \log \sum_z p(x, z|\theta) \\ &= \log \sum_z q(z|x) \frac{p(x, z|\theta)}{q(z|x)}\end{aligned}\tag{20}$$

$$\geq \sum_z q(z|x) \log \frac{p(x, z|\theta)}{q(z|x)}\tag{21}$$


下界与自由能

对固定数据 x ，定义称为自由能的泛函：

$$\mathcal{F}(q, \theta) = \sum_z q(z|x) \log \frac{p(x, z|\theta)}{q(z|x)} < \ell(\theta; x)$$

EM 算法是对 $\mathcal{F}$ 的坐标上升：

- E 步： $q^{t+1} = \arg \max_q \mathcal{F}(q, \theta^t)$
- M 步： $\theta^{t+1} = \arg \max_{\theta} \mathcal{F}(q^{t+1}, \theta)$



E 步：关于 q 的期望 ℓ_c 的最大化

- 声明：

$$q^{t+1} = \arg \max_q \mathcal{F}(q, \theta^t) = p(z \mid x, \theta^t)$$

- 这是给定数据和参数下潜在变量的后验分布。通常我们在测试时需要这个（例如，进行分类）。
- 证明（简单）：这种设置达到了界限 $l(\theta, x) \geq \mathcal{F}(q, \theta)$

$$\begin{aligned} \mathcal{F}(p(z \mid x, \theta'), \theta') &= \sum_z p(z \mid x, \theta') \log \frac{p(x, z \mid \theta')}{p(z \mid x, \theta')} \\ &= \sum_z p(z \mid x, \theta') \log p(x \mid \theta') \\ &= \log p(x \mid \theta') = \ell(\theta'; x) \end{aligned}$$

- 也可以使用变分法或以下事实来证明这个结果：

$$\ell(\theta; x) - \mathcal{F}(q, \theta) = \text{KL}(q \parallel p(z \mid x, \theta))$$

E 步：插入潜在变量的后验期望

- 无一般性损失：假设 $p(x, z | \theta)$ 是一个广义指数族分布：

$$p(x, z | \theta) = \frac{1}{Z(\theta)} h(x, z) \exp \left\{ \sum_i \theta_i f_i(x, z) \right\}$$

- 特殊情况：如果 $p(X | Z)$ 是广义线性模型 (GLIMs)，则

$$f_i(x, z) = \eta_i^T(z) \zeta_i(x)$$

- 在 $q^{t+1} = p(z | x, \theta^t)$ 下的期望完整对数似然是

$$\begin{aligned} \langle \ell_c(\theta^t; x, z) \rangle_{q^{t+1}} &= \sum_z q(z | x, \theta^t) \log p(x, z | \theta^t) - \mathcal{A}(\theta) \\ &= \sum_i \theta_i^t \langle f_i(x, z) \rangle_{q(z|x, \theta^t)} - \mathcal{A}(\theta) \\ &= \sum_i \theta_i^t \langle \eta_i(z) \rangle_{q(z|x, \theta^t)} \zeta_i(x) - \mathcal{A}(\theta) \end{aligned}$$

M 步：关于 θ 的期望 ℓ_c 的最大化

- 注意自由能分为两项：

$$\begin{aligned}\mathcal{F}(q, \theta) &= \sum_z q(z | x) \log \frac{p(x, z | \theta)}{q(z | x)} \\&= \sum_z q(z | x) \log p(x, z | \theta) - \sum_z q(z | x) \log q(z | x) \\&= \langle \ell_c(\theta; x, z) \rangle_q + H_q\end{aligned}$$

- 第一项是期望的完整对数似然（能量），第二项不依赖于 θ ，是熵。
- 因此，在 M 步中，对于固定的 q 最大化关于 θ 我们只需要考虑第一项：

$$\theta^{t+1} = \arg \max_{\theta} \langle \ell_c(\theta; x, z) \rangle_{q^{t+1}} = \arg \max_{\theta} \sum_z q(z | x) \log p(x, z | \theta)$$

- 在最优 q^{t+1} 下，这等价于求解完全观测模型 $p(x, z | \theta)$ 的标准 MLE，其中涉及 z 的充分统计量被它们关于 $p(z | x, \theta)$ 的期望值替换。

- 一种最大化潜在变量模型似然函数的方法。当原始（困难）问题可以分解为两个（简单）部分时，找到参数的最大似然估计（MLE）：
 - ① 从观测数据和当前参数估计一些“缺失”或“未观测”的数据。
 - ② 使用这些“完整”的数据，找到最大似然参数估计。
- 在使用最佳猜测（后验）填充潜在变量和基于此猜测更新参数之间交替进行：
 - E 步: $q^{t+1} = \arg \max_q \mathcal{F}(q, \theta^t)$
 - M 步: $\theta^{t+1} = \arg \max_{\theta} \mathcal{F}(q^{t+1}, \theta^t)$
- 在 M 步中，我们优化似然的下界。在 E 步中，我们缩小差距，使界限 = 似然。

- 稀疏 EM

不要在所有模型下精确地重新计算每个数据点的后验概率，因为它几乎为零。相反，保留一个“活动列表”，您每隔一段时间更新一次

- 广义（不完整）EM

即使给定完整的数据，也可能很难在 M 步中找到 ML 参数。我们仍然可以通过做一个稍微提高可能性的 M 步（例如梯度步）来取得进展。回想一下专家混合模型中的 IRLS 步骤

- 优点：

- 无学习率（步长）参数
- 自动强制执行参数约束
- 低维时非常快
- 每次迭代保证提高似然

- 缺点：



- 可能陷入局部最小值
- 接近收敛时可能比共轭梯度慢
- 需要昂贵的推理步骤
- 是最大似然/MAP 方法

Outline



- 1 回顾：分布的 MLE
- 2 混合模型
 - 高斯混合模型
- 3 期望最大化 (EM) 算法
- 4 隐马尔可夫模型的 EM

从静态到动态混合模型

Static mixture




Dynamic mixture



隐马尔可夫模型

序列：观测序列底层源：CGH 信号、基因组实体、掷骰子序列……



马尔可夫性质：

$$P(y_t | y_{t-1}, y_{t-2}, \dots) = P(y_t | y_{t-1})$$

赌场问题


游戏：

- 1 你下注 \$1
- 2 你掷骰子（总是使用公平的骰子）
- 3 赌场玩家掷骰子（可能使用公平的骰子，可能使用有偏的骰子）
- 4 最大的数字赢得 \$2

问题：

12345526462146146136136661664661636
6763661636165156151151461235623444

哪次游戏使用的是哪个骰子？




更多问题

当然，数据点一次到达一个

除了数据值本身之外，排序索引是否携带（额外的）聚类信息？


示例：肿瘤细胞染色体：

拷贝数测量（称为 CGH）




阵列 CGH (比较基因组杂交)

- CGH 实验的基本假设是测试和对照 DNA 的结合比与两个样品中序列拷贝数的比对比。
- 但各种噪音使真实的观察结果不太容易解释.....




乳腺癌中的 DNA 拷贝数畸变类型


60-70 fold amplification of CMYC region



Copy number profile for chromosome 1 from 600 MPE cell line



Copy number profile for chromosome 8 from COLO320 cell line



Copy number profile for chromosome 8 in MDA-MB-231 cell line

deletion

关于不诚实赌场的谜题

一个赌场有两个骰子：


- 公平骰子：

$$P(1) = P(2) = P(3) = P(5) = \\ P(6) = \frac{1}{6}$$

- 有偏骰子：

$$P(1) = P(2) = P(3) = P(5) = \frac{1}{10} \\ P(6) = \frac{1}{2}$$

赌场玩家每 20 轮在公平骰子和有偏骰子之间交替切换一次。



关于不诚实赌场的谜题

已知：赌场玩家掷骰子的一系列结果

1245526462146146136661163661636165156151151461235623444

问题

- 给定我们对赌场运作模式的模型，这个序列有多可能？
- 这是**评估**问题
- 序列中有多少部分是由公平骰子生成的，有多少部分是由有偏骰子生成的？
- 这是**解码**问题
- 有偏骰子有多“有偏”？公平骰子有多“公平”？赌场玩家从公平到有偏，再回到公平的频率如何？
- 这是**学习**问题

HMM 的三大问题

1 评估

- 已知一个隐马尔可夫模型 M 和一个序列 x , 找到 $P(x | M)$
- 算法: 前向算法

2 解码

- 已知一个隐马尔可夫模型 M 和一个序列 x , 找到最大化 $P(y | x, M)$ 的状态序列 y , 或最可能的状态子序列
- 算法: Viterbi, 前向-后向算法

3 学习

- 已知一个隐马尔可夫模型 M , 其转移/发射概率未指定, 和一个序列 x , 找到参数 $\theta = (\pi_i, a_{ij}, \eta_k)$ 以最大化 $P(x | \theta)$
- 算法: Baum-Welch (EM)

HMM 定义

- 观测空间
- 字母表: $C = \{c_1, c_2, \dots, c_K\}$
- 欧几里得空间: $\mathbb{R}^d$
- 隐藏状态的索引集: $I = \{1, 2, \dots, M\}$
- 任意两个状态之间的转移概率:

$$p(y_i^j = 1 \mid y_{i-1}^j = 1) = a_{i,j},$$

或者

$$p(y_i \mid y_{i-1}^j = 1) \sim \text{Multinomial}(a_{i,1}, a_{i,2}, \dots, a_{i,M}),$$

- 起始概率:


$$p(y_1) \sim \text{Multinomial}(\pi_1, \pi_2, \dots, \pi_M)$$

- 与每个状态相关的发射概率:

$$p(x_i \mid y_i^j = 1) \sim \text{Multinomial}(b_{j,1}, b_{j,2}, \dots, b_{j,k}),$$

或者一般形式:

$$p(x_i \mid y_i^j = 1) \sim f(\cdot \mid \theta_j) \quad \forall i \in 1, \dots, T$$



State automata

学习 HMM：两种场景

- 监督学习：当“正确答案”已知时的估计

- 示例：

- 已知：一个基因组区域 $x = x_1 \cdots x_{1,000,000}$ ，我们有 CpG 岛的良好（实验）注释
 - 已知：赌场玩家允许我们观察他一个晚上，因为他换骰子并产生 10,000 次掷骰子

- 无监督学习：当“正确答案”未知时的估计

- 示例：

- 已知：猪的基因组；我们不知道 CpG 岛出现的频率，也不知道它们的组成
 - 已知：赌场玩家的 10,000 次掷骰子，但我们看不到他何时换骰子

- 问题：更新模型参数 θ 以最大化 $R_X(\theta)$ ——最大似然（ML）估计

- 给定 $x = x_1 \dots x_N$ 且真实的状态路径 $y = y_1 \dots y_N$ 已知,
- 定义:
 - A_{ij} = 在 y 中状态转移 $i \rightarrow j$ 出现的次数
 - B_{ik} = 在 y 中状态 i 发出 k 的次数
- 我们可以证明最大似然参数 θ 是:

$$a_{ij}^{ML} = \frac{\#(i \rightarrow j)}{\#(i \rightarrow \bullet)} = \frac{\sum_n \sum_{t=2}^T y_{n,t-1}^i y_{n,t}^j}{\sum_n \sum_{t=2}^T y_{n,t-1}^i} = \frac{A_{ij}}{\sum_j A_{ij}}$$

$$b_{ik}^{ML} = \frac{\#(i \rightarrow k)}{\#(i \rightarrow \bullet)} = \frac{\sum_n \sum_{t=1}^T y_{n,t}^i x_{n,t}^k}{\sum_n \sum_{t=1}^T y_{n,t}^i} = \frac{B_{ik}}{\sum_k B_{ik}}$$

- 如果 x 是连续的? 我们可以将 $\{(x_{n,t}, y_{n,t}) : t = 1 : T, n = 1 : N\}$ 视为 N 个观测值, 例如高斯分布, 并应用高斯的学习规则...

- 给定 $x = x_1 \dots x_N$ 且真实的状态路径 $y = y_1 \dots y_N$ 未知,
- 期望最大化
 - 从我们对模型 M , 参数 θ 的最佳猜测开始。在训练数据中估计 A_{ij}, B_{ik}
 - 如何?
 - 根据 A_{ij}, B_{ik} 更新 θ
 - 现在是一个“监督学习”问题
 - 重复 1 & 2, 直到收敛
- 这被称为 Baum-Welch 算法
- 我们可以得到一个可能更 (或同样) 可能的参数集 θ (每次迭代)

Baum-Welch 算法——EM 算法

- 完整的对数似然

$$\ell_c(\boldsymbol{\theta}; \mathbf{x}, \mathbf{y}) \quad (23)$$

$$= \log p(\mathbf{x}, \mathbf{y}) = \log \prod_n \left(p(\mathbf{y}_{n,1}) \prod_{t=2}^T p(\mathbf{y}_{n,t} | \mathbf{y}_{n,t-1}) \prod_{t=1}^T p(\mathbf{x}_{n,t} | \mathbf{x}_{n,t}) \right) \quad (24)$$

- 期望的完整对数似然

$$\langle \ell_c(\boldsymbol{\theta}; \mathbf{x}, \mathbf{y}) \rangle = \sum_n \langle \mathbf{y}_{n,1}^i \rangle \log \pi_i \quad (25)$$

$$+ \sum_n \sum_{t=2}^T \left(\langle \mathbf{y}_{n,t-1}^j \mathbf{y}_{n,t}^i \rangle \log a_{i,j} \right) + \sum_n \sum_{t=1}^T \langle \mathbf{x}_{n,t}^k (\mathbf{y}_{n,t}^i) \rangle \log b_{i,k} \quad (26)$$

Baum-Welch 算法——EM 算法

- EM

- E 步骤

$$\gamma_{n,t}^i = \langle \mathbf{y}_{n,t}^i \rangle = p(\mathbf{y}_{n,t}^i = 1 \mid \mathbf{x}_n)$$

$$\xi_{n,t}^{i,j} = \langle \mathbf{y}_{n,t-1}^i \mathbf{y}_{n,t}^j \rangle = p(\mathbf{y}_{n,t-1}^i = 1, \mathbf{y}_{n,t}^j = 1 \mid \mathbf{x}_n)$$

- M 步骤 (“符号上” 与 MLE 相同)

$$\pi_i^{ML} = \frac{\sum_n \gamma_{n,1}^i}{N}$$

$$a_{ij}^{ML} = \frac{\sum_n \sum_{t=2}^T \xi_{n,t}^{i,j}}{\sum_n \sum_{t=1}^{T-1} \gamma_{n,t}^i}$$

$$b_{ik}^{ML} = \frac{\sum_n \sum_{t=1}^T \gamma_{n,t}^i x_{n,t}^k}{\sum_n \sum_{t=1}^T \gamma_{n,t}^i}$$