

统计机器学习基础

Foundations of Statistical Machine Learning

——图模型和贝叶斯网络

Kai Chen

kaichen6@csu.edu.cn

24th September 2025



中南大学
CENTRAL SOUTH UNIVERSITY

数学与统计学院
SCHOOL OF MATHEMATICS AND STATISTICS

- 1 贝叶斯网络定义
- 2 贝叶斯网络构建
- 3 贝叶斯网络结构解释
- 4 贝叶斯网络推理
 - 枚举法
 - 随机推理法
 - 变量消除
 - 树转换

独立性

- 在密度估计课（以及朴素贝叶斯分类器课）中，我们详细讨论了独立性假设的用处
假设各个特征之间是相互独立的，那么联合概率密度函数就可以表示为各个特征概率密度函数的乘积。

$$P(C_k | \mathbf{x}) = P(C_k) \times \prod_{i=1}^n P(x_i | C_k)$$

其中 n 是特征的数量

- 然而，我们也提到了它的缺点
独立性假设忽略了特征间的相关性，可能导致模型对数据的描述不够准确，对某些数据点的分类或预测不够准确。
可能会导致模型对训练数据的拟合过于简单，泛化性不佳


独立性

- 独立性允许更简单的模型、学习和推理
例如，对于 3 个二元变量，我们只需要 3 个参数而无需考虑复杂的联合概率分布，不需要 7 个参数
如果有更多变量，节省更大……
大规模数据集和高维特征
- 在许多情况下，即使并非真实情况，假设独立性也很有用
- 是否存在中间地带？
考虑变量之间一定相关性的同时，又不至于使模型变得过于复杂？


- 1 贝叶斯网络定义
- 2 贝叶斯网络构建
- 3 贝叶斯网络结构解释
- 4 贝叶斯网络推理
 - 枚举法
 - 随机推理法
 - 变量消除
 - 树转换

贝叶斯网络

- 贝叶斯网络是有向图，节点表示随机变量，边表示依赖假设
- 让我们用一个电影示例：我们想确定电影长度、喜欢和睡觉的联合概率



贝叶斯网络是有向无环图



贝叶斯网络

贝叶斯网络 (BN) 是一个有向无环图 (DAG), DAG 满足:

有序马尔可夫性质:

一个节点仅依赖于其直接父节点, 而不是顺序中的所有前驱节点

$$x_s \perp\!\!\!\perp X_{\text{pred}(s) \setminus \text{pa}(s)} \mid X_{\text{pa}(s)}$$

其中 $\text{pa}(s)$ 是节点 s 的父节点, $\text{pred}(s)$ 是节点 s 在排序中的前驱节点。 $\perp\!\!\!\perp$ 用于表示条件独立性。

一般而言, 我们有:

$$p(\mathbf{x}_{1:V} | G) = \prod_{t=1}^V p(x_t | X_{\text{pa}(t)})$$

其中每一项 $p(x_t | X_{\text{pa}(t)})$ 是一个条件概率分布 (CPD)。

如果每个节点有 $O(F)$ 个父节点和 K 个状态, 模型中的参数数量是 $O(VK^F)$

贝叶斯网络


- 贝叶斯网络表示以下联合概率分布：

$$p(\text{Le}, \text{Li}, \text{S}) = P(\text{Le})P(\text{Li}|\text{Le})P(\text{S}|\text{Le})$$

- 更一般地，贝叶斯网络表示：

$$p(x_1, \dots, x_n) = \prod_i p(x_i | \text{Pa}(x_i))$$

其中 $\text{Pa}(x_i)$ 为 x_i 在图中的父节点集合



- 1 贝叶斯网络定义
- 2 贝叶斯网络构建
- 3 贝叶斯网络结构解释
- 4 贝叶斯网络推理
 - 枚举法
 - 随机推理法
 - 变量消除
 - 树转换

构建贝叶斯网络

我们如何为特定问题构建网络？

- 步骤 1：识别随机变量
- 步骤 2：确定条件依赖
- 步骤 3：填充条件概率表 CPT

可以从观测数据中学习

示例

- 问题：一个报警系统
 - B——是否发生盗窃？
 - E——是否发生地震？
 - A——报警是否响起？
 - M——玛丽是否打电话？
 - J——约翰是否打电话？

我们如何为该问题重建网络？

联合分布分解

- 使用链式法则，我们总可以将联合分布分解为：

$$\begin{aligned}P(A, B, E, J, M) &= \\&= P(A \mid B, E, J, M)P(B, E, J, M) \\&= P(A \mid B, E, J, M)P(B \mid E, J, M)P(E, J, M) \\&= P(A \mid B, E, J, M)P(B \mid E, J, M)P(E \mid J, M)P(J, M) \\&= P(A \mid B, E, J, M)P(B \mid E, J, M)P(E \mid J, M)P(J \mid M)P(M)\end{aligned}$$


- 这种类型的条件依赖也可以用图形表示

贝叶斯网络

$$P(A \mid B, E, J, M)P(B \mid E, J, M)P(E \mid J, M)P(J \mid M)P(M)$$

参数数量:

- A: $2^4 = 16$
B: $2^3 = 8$
E: 4
J: 2
M: 1
- 总共 31 个参数



依然对于问题：假设一个警报系统

- B —是否发生了入室盗窃？
- E —是否发生了地震？
- A —警报是否响起？
- M —玛丽打了电话
- J —约翰打了电话

领域知识（Domain Knowledge）是指在特定领域或行业中积累的专业知识、经验、规则、模式和最佳实践。

让我们使用领域知识！

重建网络


- B —是否发生了入室盗窃？
- E —是否发生了地震？
- A —警报是否响起？
- M —玛丽打了电话
- J —约翰打了电话

参数数量：

- A: 4
- B: 1
- E: 1
- J: 2
- M: 2
- 总共 10 个参数

通过依靠领域知识，我们节省了 21

个参数！




构建贝叶斯网络

- 步骤 1: 识别随机变量
- 步骤 2: 确定条件依赖
 - 选择变量顺序
 - 一次添加一个变量
 - 对每个新变量 X , 选择最小节点子集作为父节点, 使得 X 在给定其父节点条件下独立于网络中所有其他节点
- 步骤 3: 填充条件概率表 CPT
使用数据样本使用密度估计


获得正确顺序至关重要!

重建网络


- 假设我们想向网络添加一个新变量：
R——广播是否宣布发生地震？
- 我们应如何插入它？



示例：癌症检测的贝叶斯网络



示例：基因表达网络



Outline

- 1 贝叶斯网络定义
- 2 贝叶斯网络构建
- 3 贝叶斯网络结构解释
- 4 贝叶斯网络推理
 - 枚举法
 - 随机推理法
 - 变量消除
 - 树转换

条件独立性


- 两个变量 x, y 在给定第三个变量 z 下条件独立, 如果

$$p(x, y | z) = p(x | z)p(y | z)$$

- 在贝叶斯网络中, 一个变量在给定其马尔可夫毯的条件下独立于所有其他变量

要完全确定 X 的概率分布, 只需要考虑其马尔可夫毯中的节点, 而不需要考虑网络中的其他节点


- 马尔可夫毯 (Markov Blanket): 一个节点的所有相关节点集合, 包括其父节点、子节点以及子节点的父节点。



Markov blanket: 示例

一个节点的马尔可夫毯包含了所有直接影响该节点的节点，以及所有被该节点直接影响的节点。

- 父节点
- 子节点
- 子节点的父节点
- B 的 Markov blanket: E, A
- A 的 Markov blanket: B, E, J, M



d-分离

- 在某些情况下，了解两个变量在什么条件下彼此独立很有用有助于推理和确定结构中的因果关系
- 如果两个变量 x, y 在给定变量集 Z 下 d-分离，那么它们在给定 Z 的条件下是条件独立的。这种有条件的独立性称为 $I(x, y | Z)$

$$p(x, y | z) = p(x | z)p(y | z)$$


- 如果在给定变量集 Z 的条件下，所有从 x 到 y 的路径都被阻断，那么 x 和 y 在给定 Z 下是 d-分离的。

d-分离

用于确定 x, y 在给定 Z 下是否 d-连接的三个规则：
(若不是 d-连接的变量则是 d-分隔的)

- ① 若 Z 为空，则 x 和 y 是 d-连接的，当且仅当存在一条不包含碰撞节点的路径。
- ② x 和 y 在给定 Z 的条件下是 d-连接的，当且仅当存在一条既不包含碰撞节点也不包含 Z 中任何成员的路径。
- ③ 若 Z 包含碰撞节点或其后代，且路径上没有其他节点，则只要路径包含此节点， x 和 y 就是 d-连接的。

A collider node:



假设我们有一个路径 $X \rightarrow Z \leftarrow Y$, 其中 Z 是路径上的中间节点。在这种情况下, Z 被称为碰撞节点

- 1 贝叶斯网络定义
- 2 贝叶斯网络构建
- 3 贝叶斯网络结构解释
- 4 贝叶斯网络推理**
 - 枚举法
 - 随机推理法
 - 变量消除
 - 树转换


- 一旦网络构建完毕，我们就可以使用算法来推断未观察到的变量的值
- 例如，在我们以前的网络中，唯一观察到的变量是电话和无线电公告。然而，我们真正感兴趣的是是否发生了入室盗窃。
- 我们如何确定这一点？
答案：使用网络

让我们从一个更简单的问题开始：如何从网络计算联合分布？

例如 $P(B, \neg E, A, J, \neg M)$ ？

计算: $P(B, \neg E, A, J, \neg M)$

$$\begin{aligned} P(B, \neg E, A, J, \neg M) &= P(B)P(\neg E)P(A \mid B, \neg E)P(J \mid A)P(\neg M \mid A) \\ &= 0.05 \times 0.9 \times 0.85 \times 0.7 \times 0.2 \\ &= 0.005355 \end{aligned}$$




我们可以轻松计算出完整的联合分布。部分分布呢？条件分布？
我们感兴趣的：

$$P(B|J, \neg M)$$

这也可写成联合形式：

$$P(B|J, \neg M) = \frac{P(B, J, \neg M)}{P(B, J, \neg M) + P(\neg B, J, \neg M)}$$

如何计算新联合？



贝叶斯网络中的推理

几种方法包括：

- ① 枚举：通过遍历所有可能的情况来计算概率，适用于变量较少的网络。
- ② 随机推理：利用随机抽样技术来估计概率，适用于大规模网络。
- ③ 变量消除：通过消除不相关的变量来简化计算，提高效率。
- ④ 树转换：将贝叶斯网络转换为树形结构，简化推理过程。

Outline

- 1 贝叶斯网络定义
- 2 贝叶斯网络构建
- 3 贝叶斯网络结构解释
- 4 贝叶斯网络推理
 - 枚举法
 - 随机推理法
 - 变量消除
 - 树转换

计算部分联合


部分联合概率 (partial joint probabilities), 即在给定某些变量值的情况下, 计算其他变量的联合概率

$$P(B|J, \neg M) = \frac{P(B, J, \neg M)}{P(B, J, \neg M) + P(\neg B, J, \neg M)}$$

在计算 $P(B, J, \neg M) + P(\neg B, J, \neg M)$ 时, 需要对变量 E 和 A 的所有可能取值进行求和。

计算: $P(B, J, \neg M)$

$$\begin{aligned} P(B, J, \neg M) &= P(B, J, \neg M, A, E) + P(B, J, \neg M, \neg A, E) \\ &\quad + P(B, J, \neg M, A, \neg E) + P(B, J, \neg M, \neg A, \neg E) \\ &= 0.0007 + 0.00001 + 0.005 + 0.0003 = 0.00601 \end{aligned}$$



$$P(B|J, \neg M) = \frac{P(B, J, \neg M)}{P(B, J, \neg M) + P(\neg B, J, \neg M)}$$

对所有这些设置的实例求和（对 E 和 A 的可能赋值求和）

- 这种方法可以通过重复使用计算来改进（类似于动态规划）
- 在未观察到的变量中，可能的赋值数量仍然是指数级的？
- 不幸的是，这是我们能做的最好的事情。贝叶斯网络的通用查询是 NP-complete(目前没有已知的算法可以在多项式时间内解决所有实例的这个问题)

3SAT 问题

3SAT 问题是一个经典的 NP-complete 问题

问题描述： 给定一个由多个子句组成的布尔公式，其中每个子句包含恰好三个文字（变量或其否定形式）。目标是确定是否存在一种变量赋值，使得整个公式为真（即满足所有子句）。

形式化定义： 设 $\{x_1, x_2, \dots, x_n\}$ 是一组布尔变量，每个子句 C_i 包含三个文字，可以是变量或其否定。3SAT 问题可以表示为：

$$C_1 \wedge C_2 \wedge \dots \wedge C_m$$

其中每个子句 C_i 的形式为：

$$(x_{i_1} \vee \neg x_{i_2} \vee x_{i_3})$$


这里， $\vee$ 表示逻辑或 (OR)， $\neg$ 表示逻辑非 (NOT)。

目标： 找到一组变量赋值 $\{x_1, x_2, \dots, x_n\}$ ，使得上述公式为真，即所有子句 C_i 都至少有一个文字为真。

贝叶斯网络中的推理是 NP-complete

- 通过 3SAT 问题归约证明：在一般贝叶斯网络里做精 3SAT 一样难，因此是 NP-complete。
- 回顾 3SAT：给定如下形式的子句

$$(a \vee b \vee c) \wedge (d \vee \neg b \vee \neg c) \wedge \dots,$$



寻找一组满足所有子句的变量赋值。

- 设定

$$P(x_i = 1) = 0.5,$$

$$P(Y = 1) = (x_1 \wedge x_2 \wedge x_3 \wedge x_4)$$

问： $P(Y = 1)$ 是多少？


Outline

- 1 贝叶斯网络定义
- 2 贝叶斯网络构建
- 3 贝叶斯网络结构解释
- 4 贝叶斯网络推理**
 - 枚举法
 - 随机推理法**
 - 变量消除
 - 树转换

可以轻松地从联合分布中采样，得到一组可能的实例。

- 对自由变量进行采样；
- 对其余每个变量：
若其所有父变量均已采样，则依据条件分布进行采样。
- 最终得到变量 B, E, A, J, M 的一组赋值，这是来自联合分布的随机样本。

为何总能执行上述采样？



利用采样进行推理

- 回到问题：计算 $P(B \mid J, \neg M)$ 。
- 在样本中统计：
 - N ：总样本数；
 - N_c ：满足条件 $(J, \neg M)$ 的样本数；
 - N_B ：同时满足 $(B, J, \neg M)$ 的样本数。
- 当 N 足够大时：

$$\frac{N_c}{N} \approx P(J, \neg M), \quad \frac{N_B}{N} \approx P(B, J, \neg M).$$


- 于是

$$P(B \mid J, \neg M) = \frac{P(B, J, \neg M)}{P(J, \neg M)} \approx \frac{N_B}{N_c}.$$

问题：若条件极少出现怎么办？
需要海量样本，且大部分样本都浪费掉了。

加权采样

- 目标：计算 $P(B \mid J, \neg M)$ 。
- 人为把 J 设为 1，把 M 设为 0。
- 这样所有样本都包含正确的条件变量值。
- 带来的问题？
可能改变原分布，需要校正。




用于计算 $P(B \mid J, \neg M)$ 的加权采样

- 始终令 $J = 1, M = 0$ 。
- 其余变量仍按前述方式采样。
- 记录该赋值在整个网络下的似然（权重），即该组合出现的可能性

$$w = P(v(B), v(E), v(A), J, \neg M),$$

其中， $v(X)$ 表示变量 X 的一个特定值。

- 用 w 对样本加权。



加权采样算法（计算 $P(B \mid J, \neg M)$ ）

- 1 初始化 $N_B = 0, N_c = 0$ 。
- 2 采样联合分布，固定 $J = 1, M = 0$ ，计算权重 w 。
- 3 更新：
总样本数： $N_c \leftarrow N_c + w$ ；
若当前 $B = 1$ ，则 $N_B \leftarrow N_B + w$ 。
- 4 重复多轮后，估计

$$P(B \mid J, \neg M) = \frac{N_B}{N_c}.$$


Outline

- 1 贝叶斯网络定义
- 2 贝叶斯网络构建
- 3 贝叶斯网络结构解释
- 4 贝叶斯网络推理**
 - 枚举法
 - 随机推理法
 - 变量消除**
 - 树转换

变量消除

$$\begin{aligned} P(B, J, \neg M) &= P(B, J, \neg M, A, E) + P(B, J, \neg M, \neg A, E) \\ &\quad + P(B, J, \neg M, A, \neg E) + P(B, J, \neg M, \neg A, \neg E) \\ &= 0.0007 + 0.00001 + 0.005 + 0.0003 = 0.00601 \end{aligned}$$

重复计算 $(\neg M, A), (\neg M, \neg A)$ 组合



$$\begin{aligned} &P(B, J, \neg M) \\ &= P(B, J, \neg M, A, E) + P(B, J, \neg M, \neg A, E) \\ &\quad + P(B, J, \neg M, A, \neg E) + P(B, J, \neg M, \neg A, \neg E) \\ &= \sum_a \sum_e P(B)P(e)P(a \mid B, e)P(M \mid a)P(J \mid a) \end{aligned}$$

- 重用计算而非重新计算概率
- 将中间结果存储为函数，需要时调用（无需每次重新计算）

变量消除


$$\begin{aligned} P(B, J, M) &= \sum_a \sum_e P(B)P(e)P(a \mid B, e)P(M \mid a)P(J \mid a) \\ &= P(B) \sum_e P(e) \sum_a P(a \mid B, e)P(M \mid a)P(J \mid a) \end{aligned}$$

$$P(B, J, M) = P(B) \sum_e P(e) \sum_a P(a \mid B, e) f_M(a) f_J(a)$$

Set:

$$f_M(A) = \begin{pmatrix} P(M \mid A) \\ P(M \mid \neg A) \end{pmatrix}$$

$$f_J(A) = \begin{pmatrix} P(J \mid A) \\ P(J \mid \neg A) \end{pmatrix}$$



变量消除

$$P(B, J, M) = P(B) \sum_e P(e) \sum_a P(a \mid B, e) f_M(a) f_J(a)$$

让我们继续使用这些函数：


$$f_A(a, B, e) = P(a \mid B, e)$$

我们现在可以定义以下函数：

$$f_{A,J,M}(B, e) = \sum_a f_A(a, B, e) f_J(a) f_M(a)$$

因此我们可以写出：

$$P(B, J, M) = P(B) \sum_e P(e) f_{A,J,M}(B, e)$$



变量消除


$$P(B, J, M) = P(B) \sum_e P(e) f_{A,J,M}(B, e)$$

让我们继续使用另一个函数：

$$f_{E,A,J,M}(B) = \sum_e P(e) f_{A,J,M}(B, e)$$


最后我们可以写出：

$$P(B, J, M) = P(B) f_{E,A,J,M}(B)$$



示例：变量消除

$$\begin{aligned}P(B, J, M) &= P(B)f_{E,A,J,M}(B) \\&= 0.05 \sum_e P(e)f_{A,J,M}(B, e) \\&= 0.05(0.1f_{A,J,M}(B, e) + 0.9f_{A,J,M}(B, \\&= 0.05(0.1(0.95f_J(a)f_M(a) + 0.05f_J(\neg a)f_M(\neg a)) + \\&\quad 0.9(.85f_J(a)f_M(a) + .15f_J(\neg a)f_M(\neg a)))\end{aligned}$$



计算式多次调用同一函数： f_J, f_M

变量算法

- 定义证据 (e):
证据 (e) 是指那些已知的变量值。
- 确定变量 (vars):
变量 (vars) 是指从贝叶斯网络中, 按照从下到上的顺序推导出的条件概率。
- 为每个变量生成因子:
 - 使用 `make_factor(var, e)` 生成一个因子 (factor)
 - 如果 `var` 是一个隐藏变量 (即我们不知道它的值), 则通过求和消去 (summing out) `var` 来创建一个新的因子
- 计算所有因子的乘积
将所有生成的因子相乘, 得到一个联合概率分布
- 归一化
对得到的联合概率分布进行归一化处理, 确保所有概率之和为 1

- 我们正在重用计算，因此我们减少了运行时间。
- 然而，仍然存在一些情况，这些情况会导致该算法的运行时间呈指数增长。考虑 $f_x(y_1 \dots y_n)$ 的情况。当分解 x 时，我们需要考虑 y 的所有可能值。
- 对于任意图，找到一个最小化 $w(\prec)$ 的消除顺序 $\prec$ 是 NP-hard (Arnborg et al. 1987)。在实践中，贪婪搜索技术被用来找到合理的顺序 (Kjaerulff 1990)
- 变量消除可以显著节省成本，但其效率取决于网络结构。例如，对于链和树结构的网络，由于没有填充边的引入，树宽 w 为 1，因此推理可以在 $O(VK^2)$ 时间内完成



- 1 贝叶斯网络定义
- 2 贝叶斯网络构建
- 3 贝叶斯网络结构解释
- 4 贝叶斯网络推理**
 - 枚举法
 - 随机推理法
 - 变量消除
 - 树转换**

树转换

让原来 NP-complete 的精确推理变成线性或低阶多项式时间的可解问题。

- 将网络转换为多树

- 多树中任意两节点间仅有一条路径
- 可通过聚类（分组）节点将任意网络转换为多树
- 树转换可能会增加 CPT 的大小，这取决于树的宽度。树宽越大，CPT 的大小可能增长得越快。
- 找到最优的连接树（即最小化树宽）是一个 NP-hard 问题，这使得在实践中找到最优解变得困难。用近似方法或启发式算法



- 贝叶斯规则
- 联合分布、独立性、条件独立
- 贝叶斯网络的属性
- 构建贝叶斯网络
- 贝叶斯网络中的推理

Feedback welcome!

The End