

1、

- 各书机器学习定义及差异

- *Foundations of Machine Learning*: 从理论角度, 基于统计学习理论, 强调通过优化算法最小化期望风险, 数学上多围绕经验风险最小化、一致收敛等理论展开, 注重泛化界等理论保证, 应用上更偏向理论方法的推导与分析。
- *Machine Learning: A Probabilistic Perspective*: 以概率为核心, 将机器学习视为对概率分布的建模与推断问题, 大量运用贝叶斯理论、概率图模型等, 数学工具侧重概率论、贝叶斯统计, 应用上适合不确定性建模的场景, 如自然语言处理、计算机视觉等。
- 《统计学习方法》: 从统计学习的角度, 定义机器学习为从数据中学习模型, 用于预测或分析, 涵盖监督学习、无监督学习等, 数学上结合了优化、概率论、统计等, 应用面向实际工程问题, 如分类、聚类、回归等。
- *Pattern Recognition and Machine Learning*: 结合模式识别, 从概率角度定义机器学习为从数据中推断概率模型, 用于模式分类、回归等任务, 数学上深入讲解了贝叶斯方法、高斯过程等, 应用于模式识别相关领域。
- *The Elements of Statistical Learning: Data Mining, Inference, and prediction*: 从统计学习、数据挖掘角度, 强调通过统计方法从数据中学习预测模型, 数学上涉及大量统计理论 (如正则化、降维、ensemble 方法等), 应用广泛, 包括数据挖掘、生物信息学等领域。

- 个人数学定义: 机器学习是通过从数据样本 $\mathcal{D} = \{(x_i, y_i)\}, i = 1, 2, \dots, n$ 中, 利用数学优化、概率论、统计推断等工具, 学习一个映射函数 $f: \mathcal{X} \rightarrow \mathcal{Y}$ (或概率分布 $P(Y|X)$), 使得该函数在未见过的样本上能准确预测 (泛化), 其中 $\mathcal{X}$ 是输入空间, $\mathcal{Y}$ 是输出空间。

2、

从统计角度, **经验**是指从有限的样本数据中获取的信息与规律。在统计机器学习中, **经验**通常通过经验分布来体现, 设样本集为 $\mathcal{D} = \{x_1, x_2, \dots, x_n\}$, 经验分布 $\hat{P}_n(x)$ 满足 $\hat{P}_n(x) = \frac{1}{n} \sum_{i=1}^n I(x = x_i)$ (I 为指示函数)。经验是构建经验风险 (如

$\frac{1}{n} \sum_{i=1}^n L(f(x_i), y_i)$, L 为损失函数) 的基础, 统计学习通过最小化经验风险来逼近真实风险, 经验的质量 (样本量、代表性等) 直接影响模型的泛化能力。

3、

- **统计角度的交叉验证**: 交叉验证是一种统计方法, 用于评估模型在独立于训练数据的测试集上的泛化性能, 以减少因数据划分随机性导致的评估偏差。其核心思想是将数据集多次划分为训练集和验证集, 多次训练和评估模型, 最后综合评估结果。
- **scikit - learn 交叉验证内容的数学描述**
 - **KFold**: 将数据集 $\mathcal{D}$ 随机划分为 k 个大小近似相等的子集 (folds)。每次选取 $k - 1$ 个子集作为训练集 $\mathcal{D}_{train}$, 剩下 1 个子集作为验证集 $\mathcal{D}_{val}$ 。重复 k 次, 使得每个子集都作为一次验证集。数学上, 若数据集大小为 n , 则每个子集大小约为 $\lfloor \frac{n}{k} \rfloor$ 或 $\lceil \frac{n}{k} \rceil$ 。最终模型性能为 k 次验证结果的平均值, 即 $E = \frac{1}{k} \sum_{i=1}^k E_i$, 其中 E_i 是第 i 次验证的性能指标。
 - **StratifiedKFold**: 针对分类问题, 保证每个子集 (fold) 中各类别的样本比例与原始数据集大致相同。设数据集有 C 个类别, 第 c 类样本数为 n_c , 则在每个 fold 中, 第 c 类样本数约为 $\lfloor \frac{n_c}{k} \rfloor$ 或 $\lceil \frac{n_c}{k} \rceil$ 。其他过程同KFold, 目的是避免因类别分布不均导致的验证偏差。
 - **LeaveOneOut (LOO)**: 是 $k = n$ 时的 KFold 特例。每次选取 $n - 1$ 个样本作为训练集, 剩下 1 个样本作为验证集。共进行 n 次验证, 模型性能为 n 次验证结果的平均值, 即 $E = \frac{1}{n} \sum_{i=1}^n E_i$ 。这种方法充分利用数据, 但计算成本高 (需训练 n 次模型)。

4、

- **定义**
 - **参数化模型**: 模型假设具有固定数量的参数, 这些参数确定了模型的形式。一旦参数确定, 模型就被完全定义。例如线性回归模型 $y = \beta_1 x + \beta_0$, 参数为 β_1 和 β_0 。
 - **非参数化模型**: 模型不预先假设固定数量的参数, 参数数量可随数据量增加而增加, 模型复杂度由数据决定。例如 k 近邻 (k-NN) 模型, 无需预先确定参数数量, 而是根据测试样本的邻居数量来预测。

- **区别**

- **参数数量**：参数化模型参数数量固定；非参数化模型参数数量不固定，与数据相关。
- **模型假设**：参数化模型对数据分布或模型形式有较强假设；非参数化模型假设较弱，更依赖数据本身。
- **计算复杂度**：参数化模型训练后预测通常较快；非参数化模型训练可能较快，但预测时需计算与部分或全部训练样本的关系，计算复杂度较高。

- **选择依据**

- 若数据量较小，且对数据分布有一定先验知识，适合选择参数化模型，如线性回归、逻辑回归等。
- 若数据量较大，且无明确先验知识，或数据分布复杂，适合选择非参数化模型，如 k-NN、决策树（非参数化时）、支持向量机（在某些情况下可视为非参数化）等。