

(1) 高斯分布的概率密度函数及其微分

• 单变量高斯分布

- 概率密度函数：若随机变量 $X \sim N(\mu, \sigma^2)$ ，则概率密度函数为：

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

其中， μ 是均值， σ 是方差， $\sigma > 0$ 是标准差。

- 对 x 求微分（求导）：

$$p'(x) = -\frac{x-\mu}{\sqrt{2\pi}\sigma^3} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)。$$

• 多变量高斯分布

- 概率密度函数：若 n 维随机向量 $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ ，其中 $\boldsymbol{\mu}$ 是均值向量， $\boldsymbol{\Sigma}$ 是协方差矩阵（正定），则概率密度函数为：

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} |\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

- 对 $\mathbf{x}$ 求微分（求梯度）：

$$\nabla_{\mathbf{x}} p(\mathbf{x}) = -\frac{1}{(2\pi)^{\frac{n}{2}} |\boldsymbol{\Sigma}|^{\frac{1}{2}}} \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

(2) 两个服从高斯分布的随机变量的条件概率密度

给定两个随机变量 x_1 和 x_2 ，且它们服从联合高斯分布。

记联合均值为 $\boldsymbol{\mu} = [\mu_1, \mu_2]^T$ ，协方差矩阵为： $\boldsymbol{\Sigma} = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$ 。

其中 Σ_{11} 是 x_1 的方差， Σ_{22} 是 x_2 的方差， $\Sigma_{12} = \Sigma_{21}$ 是 x_1 和 x_2 的协方差。

则条件概率密度函数 $p(x_1|x_2)$ 也服从高斯分布，其条件均值和条件方差为：

- 条件均值： $\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2)$
- 条件方差： $\Sigma_{1|2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$

因此，条件概率密度表达式为：

$$p(x_1|x_2) = \frac{1}{\sqrt{2\pi\Sigma_{1|2}}} \exp\left(-\frac{(x_1 - \mu_{1|2})^2}{2\Sigma_{1|2}}\right)$$

(3) 各概念描述随机变量关系的差异及哪种更好

- **KL 散度**：衡量两个概率分布 p 和 q 之间的差异。它是非对称的，主要用于度量分布间的“不相似性”，可用于模型选择、变分推断等，但不能直接反映变量间的依赖关系。

$$KL(p||q) = \sum_{k=1}^K p_k \log \frac{p_k}{q_k}$$

- **互信息 (Mutual Information)**：表示两个随机变量共享的信息。用于衡量变量间的依赖程度（包括线性和非线性），值越大，依赖越强。

$$I(X;Y) = KL(p(X,Y)||p(X)p(Y)) = \sum_x \sum_y p(x,y) \log \frac{p(x,y)}{p(x)p(y)}$$

- **条件概率 (Conditional Probability)**：描述在已知 $Y = y, X = x$ 时的概率，反映变量间的条件依赖关系，是局部的依赖描述。

$$p(x|y) = \frac{p(x,y)}{p(y)}$$

- **联合概率 (Joint Probability)**：表示 $X = x$ 且 $Y = y$ 同时发生的概率，是变量间关系的基本描述，但单独的联合概率不能直接体现依赖程度。

$$p(x,y)$$

- **协方差 (Covariance)**：衡量两个变量的线性相关程度，只能捕捉线性关系，对非线性关系不敏感。

$$Cov(X,Y) = E[(X - E[X])(Y - E[Y])]$$

哪种更好：没有绝对的“更好”，需根据具体任务。若关注变量间的一般依赖关系（包括非线性），**互信息**更优，因为它能全面衡量变量间共享的信息；若仅关注线性关系，协方差适用；若需描述条件下的概率，条件概率合适；若要比对分布差异，KL 散度有效；联合概率是基础但不够直接反映依赖。在多数机器学习任务中，互信息因能捕捉更广泛的依赖关系，应用场景更广泛。

(4) 测试结果为阳性时不患 AIDS 的概率

设 $a = 1$ 表示“患 AIDS”， $a = 0$ 表示“不患 AIDS”； $t = 1$ 表示“检测阳性”， $t = 0$ 表示“检测阴性”。

已知：

$$P(a = 1) = 0.0025, \text{ 则 } P(a = 0) = 0.9975$$

$$P(t = 1|a = 1) = 1$$

$$P(t = 1|a = 0) = 0.2$$

由全概率公式：

$$P(t = 1) = P(t = 1|a = 0)P(a = 0) + P(t = 1|a = 1)P(a = 1)$$

可得

$$P(t = 1) = 0.202$$

由贝叶斯定理：

$$P(a = 0|t = 1) = \frac{P(t = 1|a = 0)P(a = 0)}{P(t = 1)}$$

可得

$$P(a = 0|t = 1) \approx 0.9876$$